Milestone List — Milestone 1 Text Mining

Tim: Fauzan · Eka · Hatami Status: On Plan Hold Delay

Prediksi Respons Perusahaan terhadap Pengaduan Konsumen CFPB Menggunakan TF-IDF dan Classical Machine Learning · Mata Kuliah Pembelajaran Mesin · Kelompok A12: Fauzan Ramadhan Harahap (231110937), Eka Satria (231111582), Mhd. Hatami (231111710) · Informatika, Universitas Mikroskil, Medan

Milestone	Tanggal Selesai	Status	Issues/Comments
P1 — Problem Formulation · Pertemuan 1 (14-09-2026)			
Menetapkan masalah, tujuan, dan tipe masalah (klasifikasi multikelas)	17-09-2026	**Selesai**	Target Company response to consumer (5 kelas); Classical ML
Menentukan fitur, target, dan identitas kelompok	19-09-2026	**Selesai**	Kelompok A12; NIM 231110937, 231111582, 231111710 sudah terisi
P2 — Data Understanding & EDA · Pertemuan 2 (21-09-2026)			
Audit struktur, kualitas, dan keterbatasan data	24-09-2026	**Selesai**	1.048.575 baris × 15 kolom; terpotong di batas Excel; tanggal terkonsentrasi 2023 dan 2026
Audit kolom bocor dan EDA	26-09-2026	**Selesai**	Timely response? (V 0,6626) dikeluarkan; imbalance 350,21:1; 1.483 teks unik
P3 — Preprocessing, Feature Representation & Baseline · Pertemuan 3 (28-09-2026)			
Preprocessing dan split 60/20/20 tanpa data leakage	01-10-2026	**Selesai**	180.000 / 60.000 / 60.000; TF-IDF dan One-Hot di dalam Pipeline
Baseline TF-IDF + Logistic Regression dan temuan awal	03-10-2026	**Selesai**	Validation: F1-macro 0,3242; recall monetary relief dan untimely 0,00
P4 — Kandidat Model & Perbandingan Awal · Pertemuan 4 (05-10-2026)			
Melatih kandidat K1–K4	08-10-2026	**Selesai**	K1 F1-macro 0,4866 (+0,1624); K2 balanced acc 0,6339; RF akurasi 0,7137
Tabel perbandingan dan lima temuan	09-10-2026	**Selesai**	Fitur terstruktur sumber peningkatan utama
P5 — Audit Validasi, Kestabilan, Ensemble & Imbalance · Pertemuan 5 (12-10-2026)			
Stratified 5-Fold CV: skor tiap fold, mean, std	14-10-2026	**Selesai**	K1 0,4531 ± 0,0158; baseline 0,3237 ± 0,0110
Ensemble dan analisis imbalance	15-10-2026	**Selesai**	Voting soft 0,4954; sqrt-balanced 0,4994
Stress test group split dan keputusan perbaikan	17-10-2026	**Selesai**	F1-macro K1 turun 0,4531 → 0,3202 pada group split
P6 — Unsupervised Learning & Dimensionality Reduction · Pertemuan 6 (19-10-2026)			
LSA + KMeans: silhouette dan stabilitas (ARI)	21-10-2026	**Selesai**	k = 12; silhouette 0,1599; ARI 0,7561
Interpretasi cluster	23-10-2026	**Perlu tindak lanjut**	NMI 0,0472; k terbaik di batas atas rentang uji
P7 — Feature Selection, Error Analysis & Tuning · Pertemuan 7 (26-10-2026)			
Seleksi fitur chi2 dan tuning RandomizedSearchCV	28-10-2026	**Perlu tindak lanjut**	k = 300 terbaik (0,5026); tuning hanya +0,0001
Error analysis dan interpretabilitas	29-10-2026	**Selesai**	31,0% salah; error kombinasi ambigu 0,491 vs 0,259
UTS — Milestone 1 (Closing) · dikerjakan bersama Pertemuan 7 (26-10-2026)			
Evaluasi akhir test (sekali) dan sintesis	31-10-2026	**Selesai**	Model terbaik sementara: F1-macro 0,5323 (baseline 0,3277); akurasi 0,6891
Laporan jurnal PDF, identitas, dan rencana pasca-UTS	01-11-2026	**Selesai**	Laporan jurnal selesai; angka mengikuti notebook; rencana pasca-UTS 7 butir

Status: hijau = selesai dan terverifikasi di notebook · kuning = selesai dengan catatan/perlu tindak lanjut · merah = belum ada.

Milestone 1 Text Mining — Ringkasan Status Proyek

Tim: Fauzan · Eka · Hatami Status: On Plan Hold Delay

1) Background

Proyek memprediksi kategori tanggapan perusahaan (Company response to consumer) dari pengaduan konsumen laporan kredit CFPB dengan Classical ML: TF-IDF + One-Hot; Logistic Regression (baseline), Multinomial NB, Linear SVM, Random Forest, dan ensemble Voting.

Kelompok A12: Fauzan Ramadhan Harahap (231110937), Eka Satria (231111582), Mhd. Hatami (231111710).

2) Current condition

- Notebook V2 sudah dijalankan penuh (CELL 1–36).
- 41 dari 43 item checkpoint selesai (95%); P1–P5 dan UTS hijau; P6 dan P7 masih bercatatan.
- Laporan jurnal Milestone 1 selesai (identitas kelompok terisi; rencana pasca-UTS 7 butir).
- Test (dibuka sekali): model terbaik sementara F1-macro 0,5323 vs baseline 0,3277; akurasi 0,6891 vs 0,5690.

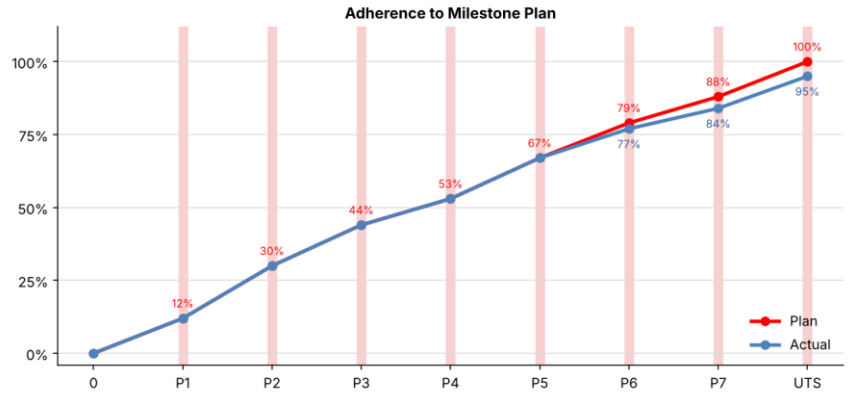
Goal Condition

Notebook Colab utuh yang valid, laporan Milestone 1 (PDF), tabel hasil, sumber dataset, dan rencana pasca-UTS sesuai rubrik.

3) Issues

- File terpotong di batas Excel; tanggal terkonsentrasi di 2023 (564.644) dan 2026 (483.467): sampel bukan acak.
- Tanpa kolom narasi: 1.483 teks unik; 86,32% baris validasi identik dengan baris latih; pada kombinasi fitur ambigu error 49,1% vs 25,9%; presisi kelas kecil rendah (0,24 dan 0,14).
- Tuning P7 hanya +0,0001 F1-macro; cluster P6 lemah (silhouette 0,1599).
- Perbandingan K1–K4 dan ensemble belum setara (tanpa bobot kelas); data uji sudah dibuka satu kali sehingga UAS perlu hold-out baru.

4) Adherence to Milestone Plan



5) Milestone Detail

#	Milestone	Plan Date	Actual Date	Plan / Actual	Status
1	P1 Problem Formulation	14-09-2026	19-09-2026	12% / 12%	Selesai
2	P2 Data Understanding & EDA	21-09-2026	26-09-2026	30% / 30%	Selesai
3	P3 Preprocessing, Fitur & Baseline	28-09-2026	03-10-2026	44% / 44%	Selesai
4	P4 Kandidat Model & Perbandingan	05-10-2026	09-10-2026	53% / 53%	Selesai
5	P5 Validasi, Ensemble & Imbalance	12-10-2026	17-10-2026	67% / 67%	Selesai
6	P6 Unsupervised & Dim. Reduction	19-10-2026	23-10-2026	79% / 77%	Perlu tindak lanjut
7	P7 Feature Selection, Error Analysis & Tuning	26-10-2026	29-10-2026	88% / 84%	Perlu tindak lanjut
8	UTS Milestone 1 (Closing)	26-10-2026	01-11-2026	100% / 95%	Selesai

3G REPORT

PROGRESS	PROBLEM	PLAN
Notebook V2 selesai dijalankan; hasil test akhir F1-macro 0,5323 (baseline 0,3277); laporan jurnal Milestone 1 selesai disusun dari keluaran notebook.	File data terpotong dan tidak acak; teks sangat terbatas; kelas langka sulit diprediksi; tuning dan clustering belum memberi peningkatan berarti.	Unduh ulang dataset CFPB tanpa melalui Excel dan jalankan ulang notebook; setarakan bobot kelas pada semua kandidat; siapkan hold-out baru (rencana pasca-UTS 7 butir).

Plan / Actual = persentase kumulatif item checkpoint (total 43 item). Plan Date = tanggal pertemuan; Actual Date = tanggal penyelesaian milestone.

Status: hijau = selesai dan terverifikasi di notebook · kuning = selesai dengan catatan/perlu tindak lanjut · merah = belum ada.

Milestone 1 Text Mining — P1 Problem Formulation

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Pertemuan 1 (14-09-2026) · Selesai dikerjakan 19-09-2026

1) Background

Biro kredit (TransUnion, Experian, Equifax) menerima ribuan pengaduan konsumen melalui CFPB. Membaca dan mengklasifikasi pengaduan secara manual lambat dan tidak konsisten, sehingga model klasifikasi dapat membantu memprioritaskan pengaduan dan memperkirakan bagaimana pengaduan akan diselesaikan.

2) Current condition

- Rumusan: memprediksi Company response to consumer dari informasi pengaduan dengan Classical ML.
- Tipe masalah: klasifikasi multikelas (5 kelas, tidak seimbang).
- Fitur: teks (Product, Sub-product, Issue, Sub-issue) dan kategori (Company, State, Submitted via, Tags).
- Dikeluarkan: Timely response? dan Company public response (pasca-respons).

Goal Condition

Membangun, membandingkan, dan memvalidasi model berbasis TF-IDF (baseline LR; kandidat NB, SVM, RF) secara terukur, stabil, dan reproducible, serta menjelaskan batas performanya.

3) Issues

- Identitas kelompok sudah terisi: Kelompok A12 (NIM 231110937, 231111582, 231111710).
- Kolom narasi pengaduan tidak ada, sehingga teks hanya berisi jenis masalah; atribut kategorikal ditambahkan sebagai fitur.
- Sumber dataset: CFPB Consumer Complaint Database (diakses Nov. 2026); notebook dan dokumentasi di repositori GitHub Tcerz/ML-UTS_A12Keluhan-Pelanggan. Berkas yang dipakai terpotong di batas baris Excel.
- Dataset dan rumusan masalah tidak diganti setelah melihat hasil awal.

4) Alur Klasifikasi Teks

Alur klasifikasi teks



Kelas target (Company response to consumer), 1.048.573 baris:

- Closed with explanation 481.535 (45,9%)
- Closed with non-monetary relief 288.164 (27,5%)
- In progress 267.769 (25,5%)
- Closed with monetary relief 9.730 (0,9%)
- Untimely response 1.375 (0,13%)

Dibangun dalam Pipeline scikit-learn; TF-IDF dan One-Hot di-fit hanya pada data latih.

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Latar belakang dan urgensi	Teks P1	**Selesai**
2	Rumusan masalah dan tujuan proyek	Teks P1	**Selesai**
3	Tipe masalah: klasifikasi multikelas (Classical ML)	Teks P1	**Selesai**
4	Fitur (X), target (y), dan kolom yang dikeluarkan	Teks P1; CELL 2	**Selesai**
5	Identitas kelompok (nomor, NIM)	Laporan jurnal; notebook	**Selesai**

3G REPORT

PROGRESS	PROBLEM	PLAN
Perumusan masalah lengkap: latar belakang, rumusan, tujuan, tipe masalah, fitur, target, kolom yang dikeluarkan, dan identitas kelompok A12.	Tidak ada kolom narasi; berkas dataset yang dipakai terpotong di batas Excel.	Catat sumber dan tanggal akses dataset (CFPB, Nov. 2026) di laporan dan notebook; gunakan dataset utuh tanpa melalui Excel pada tahap UAS.

Milestone 1 Text Mining — P2 Data Understanding & EDA

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Pertemuan 2 (21-09-2026) · Selesai dikerjakan 26-09-2026

1) Background

Data dipahami lewat audit struktur, kualitas, keterbatasan file, kolom berpotensi bocor, distribusi target, panjang teks, dan kapasitas informasi fitur. Unit observasi: 1 baris = 1 pengaduan konsumen terhadap satu perusahaan (Complaint ID).

2) Current condition

- 1.048.575 baris × 15 kolom; tanpa baris/Complaint ID duplikat; 2 baris tanpa target dibuang (tersisa 1.048.573).
- Missing terbanyak: Tags 95,17%, Company public response 56,86%, Sub-issue 2,37%.
- Target 5 kelas; imbalance ratio 350,21; tebakan mayoritas: akurasi 0,4592, F1-macro 0,1259.
- Teks unik hanya 1.483 (0,141%; duplikasi 99,9%); median 22 kata, maks 36.

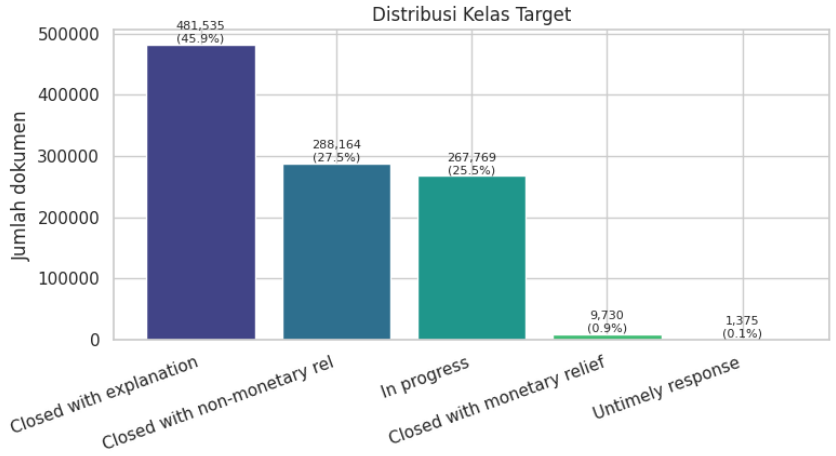
Goal Condition

Data dipahami sebelum dimodelkan: imbalance, keterbatasan file, kolom bocor, dan informasi yang benar-benar tersedia pada fitur.

3) Issues

- Jumlah baris = batas Excel (file kemungkinan terpotong); tanggal tidak terurut dan terkonsentrasi: 2023 (564.644) dan 2026 (483.467) dari 1.048.575, sehingga sampel bukan acak.
- Timely response? (Cramér's V 0,6626) dan Company public response (0,2730) dikeluarkan karena pasca-respons.
- Tabel-lookup: F1-macro 0,367 (teks saja) → 0,548 (+Company); State, Via, Tags tidak menambah (cakupan turun ke 87,2%).

4) Bukti Output Notebook: Distribusi Kelas Target



5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Ukuran data, tipe data, target, missing, duplikasi	CELL 3	Selesai
2	Audit pemotongan file dan rentang tanggal	CELL 4	Selesai
3	Audit kolom berpotensi bocor (Cramér's V)	CELL 5	Selesai
4	Pembentukan teks dan log pembersihan	CELL 6	Selesai
5	Distribusi kelas dan imbalance	CELL 7	Selesai
6	Panjang teks	CELL 8	Selesai
7	Kapasitas informasi fitur dan perusahaan–target	CELL 9–10	Selesai
8	Interpretasi temuan EDA	CELL 11	Selesai

3G REPORT

PROGRESS	PROBLEM	PLAN
EDA lengkap: audit file, audit kebocoran, distribusi kelas, panjang teks, kapasitas informasi, perusahaan–target (Lampiran A).	File terpotong dan tidak acak; teks sangat terbatas; imbalance berat (Untimely response 0,13%).	Gunakan F1-macro, balanced accuracy, MCC, PR-AUC. Unduh ulang dataset dari CFPB dan jalankan ulang notebook tanpa perubahan lain.

Milestone 1 Text Mining — P3 Preprocessing, Fitur & Baseline

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Pertemuan 3 (28-09-2026) · Selesai dikerjakan 03-10-2026

1) Background

Teks dibersihkan, data dibagi train/validation/test (60/20/20) sebelum vektorisasi, dan TF-IDF serta One-Hot di-fit di dalam Pipeline hanya pada data latih. Baseline: TF-IDF (teks saja) + Logistic Regression, dibandingkan dengan dummy mayoritas.

2) Current condition	Goal Condition
• Cleaning stateless; 0 dokumen kosong; stopword tidak dihapus karena negasi bermakna. • Split stratified: 180.000 latih, 60.000 validation, 60.000 test (dikunci). • Baseline (validation): akurasi 0,5698; F1-macro 0,3242; MCC 0,3557; PR-AUC 0,4031. • Dummy: F1-macro 0,1259.	Baseline yang valid dan terdokumentasi, beserta kelemahan yang menentukan fokus perbaikan.

3) Issues

- Baseline tidak pernah benar pada Closed with monetary relief dan Untimely response (recall 0,00 keduanya); recall In progress 0,97, jadi model condong ke kelas besar.
- Selisih akurasi dan F1-macro 0,2456: akurasi menutupi kelemahan kelas kecil.
- Seluruh stopword dipertahankan, sehingga kata umum (credit, reporting, or) mendominasi n-gram (Lampiran B).

4) Bukti Output Notebook

Metrik (validation)	Baseline LR	Dummy
Accuracy	0,5698	0,4592
Balanced Acc	0,3539	0,2000
Precision (macro)	0,3313	0,0918
Recall (macro)	0,3539	0,2000
F1 (macro)	0,3242	0,1259
F1 (weighted)	0,5368	0,2890
MCC	0,3557	0,0000
PR-AUC (macro)	0,4031	0,2000
Waktu latih	17,1 s	-

Preprocessing: case folding · hapus URL dan token XXXX · hapus angka dan tanda baca · normalisasi spasi · stopword tidak dihapus (negasi bermakna) · tanpa stemming.

Split stratified 60/20/20: Train 180.000 · Validation 60.000 · Test 60.000 (dikunci).

Anti-leakage: TF-IDF dan One-Hot di dalam Pipeline, di-fit hanya pada data latih.

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Preprocessing teks (stateless)	CELL 12	Selesai
2	Split stratified 60/20/20, test dikunci	CELL 13	Selesai
3	TF-IDF dan One-Hot di dalam Pipeline	CELL 14	Selesai
4	Baseline TF-IDF + LR dan dummy	CELL 15	Selesai
5	Kata dan bigram teratas (data latih)	CELL 16	Selesai
6	Temuan awal dan kelemahan baseline	CELL 17	Selesai

3G REPORT

PROGRESS	PROBLEM	PLAN
Baseline dan dummy dilatih pada train, dievaluasi pada validation; lima temuan awal dihasilkan dari angka.	Kelas minoritas tidak terdeteksi oleh baseline berbasis teks saja.	Tambahkan fitur kategorikal (feature engineering), bandingkan kandidat model (P4), dan tangani imbalance (P5).

Milestone 1 Text Mining — P4 Kandidat Model & Perbandingan Awal

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Pertemuan 4 (05-10-2026) · Selesai dikerjakan 09-10-2026

1) Background

Empat kandidat (K1 LR + fitur terstruktur, K2 Multinomial NB, K3 Linear SVM, K4 Random Forest) dilatih pada train dan dibandingkan dengan baseline pada validation. Test tidak disentuh.

2) Current condition

- K1 F1-macro tertinggi 0,4866 (+0,1624 dari baseline); akurasi 0,7096.
- K2 (NB): balanced accuracy tertinggi 0,6339, tetapi akurasi 0,5931 dan presisi 0,4116.
- K4 (RF): akurasi dan MCC tertinggi (0,7137; 0,5692), tetapi F1-macro rendah (0,4480).
- Waktu latih: NB 4,9 s; LR 33,9 s; RF 34,0 s; SVM 34,8 s.

Goal Condition

Tabel perbandingan Baseline vs Kandidat, 5 poin temuan, dan pemilihan metrik yang paling informatif.

3) Issues

- Peningkatan terutama berasal dari fitur terstruktur (K1 vs baseline, model sama: F1-macro +0,1624; akurasi +0,1398), bukan dari jenis algoritma.
- Recall Untimely response masih rendah: 0,000 (baseline) menjadi 0,090 (K1); recall monetary relief K1 0,10.
- Peringkat model berbeda antar metrik (akurasi vs F1-macro vs balanced accuracy), sehingga pemilihan akhir memakai cross-validation (P5).

4) Bukti Output Notebook: Tabel Perbandingan (validation, dilatih pada train)

Model (validation)	Acc	Bal Acc	F1 (m)	MCC	PR-AUC	Waktu (s)
Baseline: LR (teks)	0,5698	0,3539	0,3242	0,3557	0,4031	17,1
K1: LR + struktur	0,7096	0,4611	0,4866	0,5540	0,5567	33,9
K2: Multinomial NB	0,5931	0,6339	0,4308	0,4032	0,4665	4,9
K3: Linear SVM	0,7102	0,4544	0,4762	0,5550	0,5506	34,8
K4: Random Forest	0,7137	0,4457	0,4480	0,5692	0,5364	34,0

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Memilih kandidat K1–K4	CELL 18	**Selesai**
2	Tabel perbandingan Baseline vs Kandidat	CELL 18	**Selesai**
3	Lima poin temuan awal	CELL 19	**Selesai**
4	Metrik paling informatif (F1-macro, balanced acc, MCC)	CELL 7; CELL 19	**Selesai**

3G REPORT

PROGRESS	PROBLEM	PLAN
Tabel perbandingan lengkap; lima temuan dihasilkan otomatis dari angka validation.	Peringkat model bergantung pada metrik; kelas minoritas masih lemah.	Pilih model memakai cross-validation pada data dev (P5). Confusion matrix ada di Lampiran C.

Milestone 1 Text Mining — P5 Audit Validasi, Kestabilan, Ensemble & Imbalance

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Pertemuan 5 (12-10-2026) · Selesai dikerjakan 17-10-2026

1) Background

Menguji keabsahan dan kestabilan evaluasi pada data dev (train+val): Stratified 5-Fold CV (60.000 baris), ensemble Voting, strategi bobot kelas, dan stress test group split.

2) Current condition

- CV F1-macro: K1 0,4531 ± 0,0158; K3 0,4497 ± 0,0121; K2 0,4347 ± 0,0069; K4 0,4225 ± 0,0063; baseline 0,3237 ± 0,0110.
- Voting soft (LR+NB) 0,4954 ± 0,0196 (unggul 0,0423 atas K1); Voting hard 0,4617 ± 0,0119.
- Bobot sqrt-balanced terpilih: F1-macro 0,4994 (tanpa bobot 0,4531; balanced 0,4591).
- Overlap validation–train: teks 99,86%; seluruh fitur identik 86,32%.

Goal Condition

Keputusan perbaikan berbasis bukti dan estimasi performa yang realistis, termasuk untuk jenis masalah yang belum pernah terlihat.

3) Issues

- Group split (Skema B): F1-macro turun baseline 0,3237 → 0,1435; K1 0,4531 → 0,3202; NB 0,4347 → 0,2230. Model bergantung pada kategori masalah yang sudah dikenal.
- Bobot balanced menaikkan recall Untimely 0,0125 → 0,5933, tetapi akurasi turun 0,7054 → 0,6288 (trade-off).
- Ensemble terbaik di CV, tetapi belum dibandingkan setara dengan LR berbobot kelas (K1–K4 dan ensemble tidak memakai bobot kelas); tuning P7 memakai LR. Nilai p paired t-test bersifat indikatif.

4) Bukti Output Notebook

Skor F1-macro tiap fold (Stratified 5-Fold)

Model	F1	F2	F3	F4	F5	Mean	Std
Baseline: LR (teks)	0,3186	0,3178	0,3220	0,3170	0,3431	0,3237	0,0110
K1: LR + struktur	0,4595	0,4435	0,4776	0,4384	0,4464	0,4531	0,0158
K2: Multinomial NB	0,4309	0,4334	0,4261	0,4397	0,4433	0,4347	0,0069
K3: Linear SVM	0,4458	0,4299	0,4589	0,4568	0,4568	0,4497	0,0121
K4: Random Forest	0,4241	0,4137	0,4209	0,4227	0,4310	0,4225	0,0063

Strategi imbalance (LR + struktur, CV)

Strategi	F1 (mean)	Std	Bal Acc	Acc	Recall Untimely
tanpa bobot	0,4531	0,0158	0,4417	0,7054	0,0125
balanced	0,4591	0,0062	0,6993	0,6288	0,5933
sqrt-balanced	0,4994	0,0103	0,5907	0,6856	0,2517

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Strategi validasi: Stratified 5-Fold	CELL 20	**Selesai**
2	Skor tiap fold, mean, dan std	CELL 21	**Selesai**
3	Ensemble Voting dan uji paired t	CELL 22	**Selesai**
4	Analisis imbalance dan bobot kelas	CELL 23	**Selesai**
5	Stress test group split (Skema B)	CELL 24	**Selesai**
6	Keputusan perbaikan berbasis bukti	CELL 25	**Selesai**

3G REPORT

PROGRESS	PROBLEM	PLAN
Validasi, kestabilan, ensemble, imbalance, dan stress test group selesai dengan output lengkap (grafik di Lampiran D).	Skor Skema A optimis dibanding Skema B; kelas minoritas tetap sulit; trade-off bobot kelas.	Keputusan: Skema A (Stratified 5-Fold) sebagai evaluasi utama, Skema B sebagai stress test; bobot sqrt-balanced; LR + fitur terstruktur untuk tuning dan model terbaik sementara.

Milestone 1 Text Mining — P6 Unsupervised Learning & Dimensionality Reduction

Tim: Fauzan · Eka · Hatami Status: On Plan Hold Delay

Pertemuan 6 (19-10-2026) · Selesai dikerjakan 23-10-2026

1) Background

Jenis masalah unik (teks) pada data dev dikelompokkan memakai TF-IDF → TruncatedSVD (LSA) → KMeans (dibobot jumlah pengaduan), tanpa label target. NMF dipakai sebagai pembanding topic modeling.

2) Current condition

- 1.140 jenis masalah unik; TF-IDF (1.140 × 1.990) → SVD 50 komponen (variansi 0,5902).
- k = 2–12: silhouette 0,0312 → 0,1599; ARI antar seed 1,0000 (k ≤ 6) → 0,7561 (k = 12).
- k terpilih 12; NMI cluster–target 0,0472.
- Tema NMF: pinjaman/payday, kartu kredit/prepaid, penagihan utang, pelaporan kredit, rekening giro/tabungan, informasi salah.

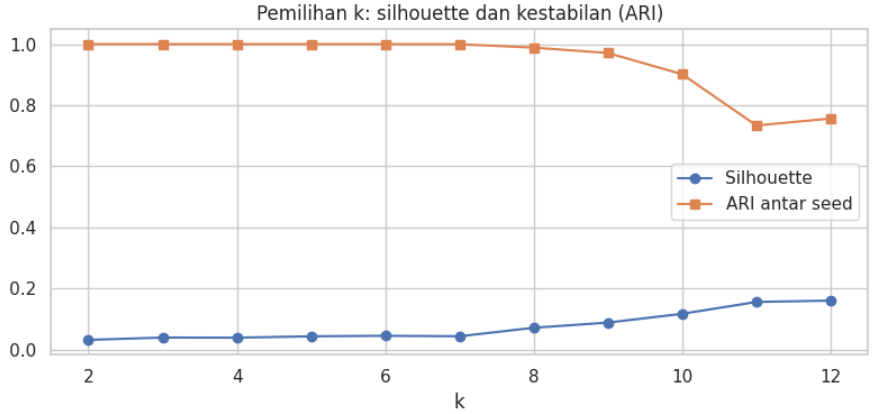
Goal Condition

Memahami karakter kelompok jenis masalah dan menilai kestabilan hasil clustering.

3) Issues

- Silhouette tertinggi hanya 0,1599 (struktur cluster lemah) dan masih naik pada k = 12, batas atas rentang yang diuji; k yang lebih besar belum dicoba. Hasil dibaca sebagai eksplorasi, bukan bukti klaster alami.
- ARI turun saat k naik (0,7334 pada k = 11).
- NMI 0,0472: jenis masalah belum menjelaskan hasil penanganan; cluster 2 heterogen (533 jenis masalah: hipotek, utang, pinjaman).

4) Bukti Output Notebook: Silhouette dan ARI vs k



5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	TF-IDF → TruncatedSVD (LSA)	CELL 26	Selesai
2	KMeans k = 2–12: silhouette dan ARI	CELL 26	Selesai
3	Karakteristik cluster, NMI, dan topik NMF	CELL 27	Selesai
4	Interpretasi hasil clustering	CELL 28	Selesai
5	Rentang k mencakup titik optimal	k = 12 di batas atas	Perlu tindak lanjut

3G REPORT

PROGRESS	PROBLEM	PLAN
LSA, KMeans (k = 2–12), silhouette, ARI antar seed, karakteristik cluster, NMI, dan topik NMF selesai.	Cluster lemah; k terbaik di batas atas; hubungan dengan target rendah.	Perluas rentang k, bandingkan dengan topik NMF, dan nilai manfaat cluster sebagai fitur tambahan pasca-UTS. Gambar tambahan di Lampiran E.

Milestone 1 Text Mining — P7 Feature Selection, Error Analysis & Tuning

Tim: Fauzan · Eka · Hatami Status: On Plan Hold Delay

Pertemuan 7 (26-10-2026) · Selesai dikerjakan 29-10-2026

1) Background

Seleksi fitur (chi2), tuning RandomizedSearchCV (StratifiedKFold) pada subset dev 60.000 baris, serta error analysis dan interpretabilitas pada validation. Test tetap dikunci.

2) Current condition

- Seleksi fitur (626 fitur): k = 300 terbaik, F1-macro 0,5026; semua fitur 0,4949.
- Tuning 12 kombinasi (267,5 s): terbaik F1-macro CV 0,5012 (C ≈ 0,0635; n-gram (1,2); max_features 20.000; min_df = 1; persentil seleksi 100; bobot sqrt-balanced); rentang skor 0,0834.
- Validation: tuned 0,5215 vs tanpa tuning 0,5215 (+0,0001); baseline 0,3242 (+0,1973).
- Error analysis: 31,0% salah (18.608 dari 60.000); kombinasi ambigu (13.302 baris) 49,1% salah vs 25,9% (46.698 baris).

Goal Condition

Fitur dan parameter terpilih dengan bukti, serta pemahaman penyebab kesalahan prediksi.

3) Issues

- Tuning hampir tidak menambah akurasi atau F1-macro (+0,0001); empat kombinasi terbaik semuanya memakai bobot sqrt-balanced. Selisih seleksi fitur k = 300 vs semua fitur lebih kecil dari std antar fold.
- Kesalahan tersering: non-monetary relief → explanation (5.885 kasus) dan explanation → in progress (4.840 kasus). Hanya 4,3% kombinasi validasi belum pernah muncul di data latih; 86,32% baris validasi identik dengan baris latih.
- Error rate per perusahaan: Citibank 0,601, Bank of America 0,546, Wells Fargo 0,440; Equifax 0,423, Experian 0,274, TransUnion 0,257.
- Kasus salah paling yakin: Bread Financial diprediksi Closed with monetary relief (peluang ±0,93), kemungkinan efek bobot kelas besar pada kelas ini.

4) Bukti Output Notebook

Seleksi fitur SelectKBest (chi2), CV 3-fold

k fitur	F1-macro (mean)	Std	Balanced Acc
50	0,4959	0,0185	0,5787
100	0,4983	0,0130	0,5915
300	0,5026	0,0055	0,6033
semua (626)	0,4949	0,0134	0,5809

Error rate per kelas aktual (validation)

Kelas aktual (model tuned)	Salah	Total	Error rate	Rank
Closed with non-monetary relief	7.961	16.489	0,483	1
Untimely response	35	78	0,449	2
Closed with explanation	8.242	27.554	0,299	3
Closed with monetary relief	163	557	0,293	4
In progress	2.207	15.322	0,144	5

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Seleksi fitur SelectKBest (chi2)	CELL 29	Selesai
2	Hyperparameter tuning (RandomizedSearchCV)	CELL 30–31	Perlu tindak lanjut
3	Error analysis dan kasus ambigu	CELL 32	Selesai
4	Interpretabilitas fitur (koefisien LR)	CELL 33	Selesai

3G REPORT

PROGRESS	PROBLEM	PLAN
Seleksi fitur, tuning, error analysis, dan interpretabilitas sudah dijalankan dengan output lengkap.	Tuning tidak informatif; ketidakpastian label pada kombinasi fitur yang sama membatasi performa.	Tetapkan konfigurasi tuned sebagai model terbaik sementara (dibekukan sebelum test). Periksa efek bobot kelas pada Bread Financial dan pertimbangkan penyesuaian ambang per kelas.

Milestone 1 Text Mining — UTS Milestone 1 (Closing)

Tim: Fauzan · Eka · Hatami Status: On Plan · Hold · Delay

Dikerjakan bersama Pertemuan 7 (26-10-2026) · Selesai dikerjakan 01-11-2026

1) Background

Notebook utuh yang berjalan valid dari preprocessing, ekstraksi fitur, validasi kestabilan, hingga analisis temuan. Model terbaik sementara (LR berbobot sqrt-balanced dengan seleksi fitur dan hiperparameter hasil tuning) dan baseline dilatih ulang pada data dev (240.000 baris) lalu dievaluasi satu kali pada test (60.000 baris).

2) Current condition

- Model terbaik sementara (test): akurasi 0,6891; balanced acc 0,7013; F1-macro 0,5323; MCC 0,5328; PR-AUC 0,5765.
- Baseline (test): akurasi 0,5690; F1-macro 0,3277; MCC 0,3534. Dummy F1-macro 0,1259.
- Validation 0,5215 vs test 0,5323 (+0,0108): tidak tampak tanda overfitting terhadap data validasi.
- Hasil tersimpan: berkas CSV dan model_final.joblib; laporan jurnal dan rencana pasca-UTS selesai.

Goal Condition

Notebook utuh, laporan Milestone 1 (PDF), tabel hasil, sumber dataset, dan rencana pasca-UTS sesuai rubrik.

3) Issues

- Presisi kelas kecil rendah pada test: Closed with monetary relief 0,24 dan Untimely response 0,14 (recall keduanya 0,72); Untimely response hanya 78 sampel uji (56 terprediksi benar), sehingga estimasinya tidak stabil.
- File dataset terpotong di batas Excel; generalisasi ke populasi CFPB belum terbukti.
- Perbandingan K1–K4 dan ensemble belum setara dengan LR berbobot kelas; data uji sudah dibuka satu kali sehingga UAS memerlukan hold-out baru.

4) Ringkasan Hasil Test Set (dibuka sekali)

Hasil akhir pada test set (dibuka sekali)

Model (test)	Acc	Bal Acc	F1 (m)	MCC	PR-AUC
Dummy (mayoritas)	0,4592	0,2000	0,1259	0,0000	0,2000
Baseline: LR (teks)	0,5690	0,3554	0,3277	0,3534	0,4090
Model terbaik sementara	**0,6891**	**0,7013**	**0,5323**	**0,5328**	**0,5765**

Laporan klasifikasi per kelas (test)

Kelas (model terbaik sementara)	Precision	Recall	F1	Jumlah
Closed with explanation	0,70	0,70	0,70	27.554
Closed with monetary relief	0,24	0,72	0,36	557
Closed with non-monetary relief	0,81	0,51	0,63	16.489
In progress	0,66	0,86	0,74	15.322
Untimely response	0,14	0,72	0,23	78

5) Milestone Detail

#	Checkpoint	Bukti di notebook	Status
1	Evaluasi akhir satu kali pada test	CELL 34	**Selesai**
2	Sintesis hasil dan checklist audit	CELL 35	**Selesai**
3	Penyimpanan hasil (CSV dan model)	CELL 36	**Selesai**
4	Laporan jurnal PDF Milestone 1	Laporan jurnal	**Selesai**
5	Rencana pasca-UTS dan identitas kelompok	Laporan jurnal bab 6	**Selesai**

3G REPORT

PROGRESS	PROBLEM	PLAN
Evaluasi akhir satu kali, sintesis otomatis, checklist audit, penyimpanan hasil, laporan jurnal, dan rencana pasca-UTS selesai.	Presisi kelas kecil rendah; estimasi Untimely response tidak stabil (78 sampel uji); data uji sudah terpakai.	Jalankan rencana pasca-UTS (halaman berikutnya). Lampiran F memuat confusion matrix test.

Rencana Pasca-UTS Menuju UAS

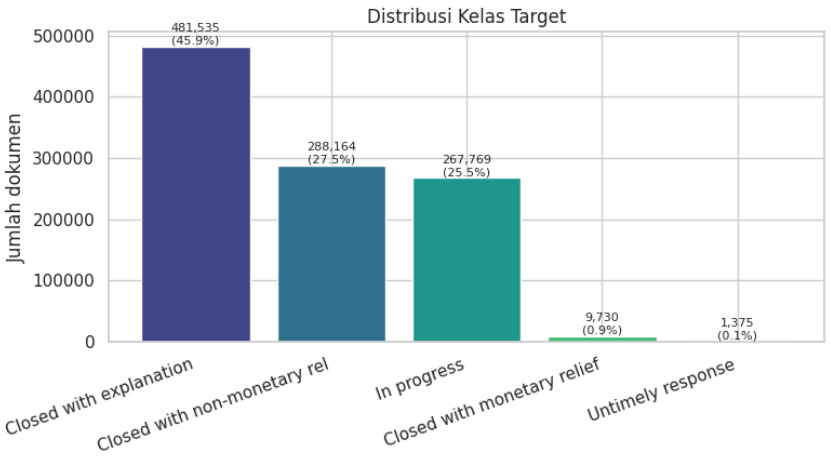
Tim: Fauzan · Eka · Hatami Status: On Plan Hold Delay

Mengikuti bab 6 laporan jurnal (Saran dan Rencana Pasca-UTS)

#	Rencana	Rincian	Temuan yang mendasari
1	**Memperbaiki data**	Mengunduh ulang CSV asli dari CFPB tanpa melalui Excel (atau per tahun/produk lalu digabung), karena Excel memotong berkas yang dianggap terlalu besar; menjalankan ulang notebook agar sampel lebih representatif, lalu memperbarui seluruh angka laporan.	Berkas terpotong di 1.048.575 baris; data terkonsentrasi di 2023 dan 2026 (sampel bukan acak).
2	**Memanfaatkan kolom narasi**	Bila kolom narasi tersedia pada data baru, dipakai sebagai sumber teks (notebook sudah dapat memakainya otomatis). Perubahan dataset atau rumusan target (mis. hanya hasil akhir "Closed...") dikonsultasikan lebih dahulu dengan dosen beserta alasannya.	Hanya 1.483 teks unik dari 1.048.573 baris; 86,32% baris validasi identik dengan baris latih.
3	**Menyiapkan evaluasi baru**	Membuat data hold-out baru atau pemisahan berbasis waktu karena data uji sudah dibuka pada UTS.	Data uji telah dibuka satu kali pada evaluasi akhir.
4	**Menyetarakan perbandingan**	Menerapkan bobot kelas pada semua kandidat dan ensemble agar perbandingan adil, serta memperluas pencarian hiperparameter.	K1–K4 dan ensemble tanpa bobot kelas; tuning hanya +0,0001 F1-macro.
5	**Memperbaiki kelas langka**	Mengkalibrasi probabilitas dan menyesuaikan ambang keputusan per kelas untuk menyeimbangkan presisi dan recall.	Presisi monetary relief 0,24 dan Untimely response 0,14 pada test (recall 0,72).
6	**Eksperimen representasi teks**	Menguji stemming/lematisasi dan variasi n-gram; representasi lanjutan seperti word embedding hanya bila sesuai ketentuan UAS.	Kata umum (credit, reporting, or) mendominasi n-gram; NMI cluster–target hanya 0,0472.
7	**Dokumentasi**	Menyiapkan repositori GitHub dengan README, instruksi menjalankan ulang, catatan eksperimen, dan tabel hasil yang konsisten dengan laporan.	Reprodusibilitas: RANDOM_STATE = 42; notebook Colab dan model_final.joblib.

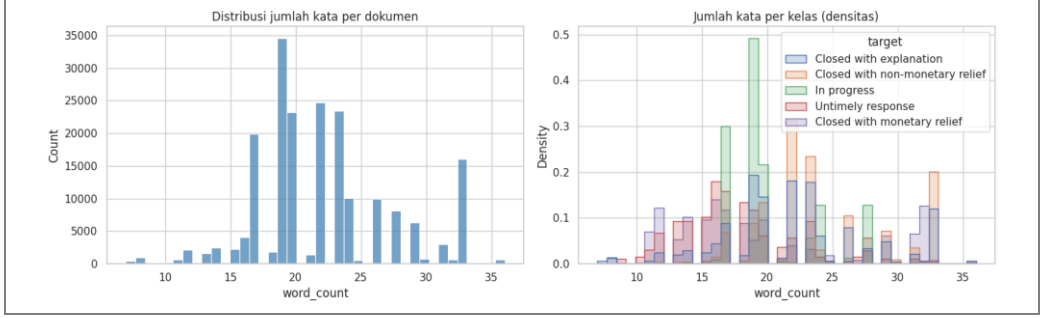
Status: hijau = selesai dan terverifikasi di notebook · kuning = selesai dengan catatan/perlu tindak lanjut · merah = belum ada.

Gambar 1. Distribusi kelas target



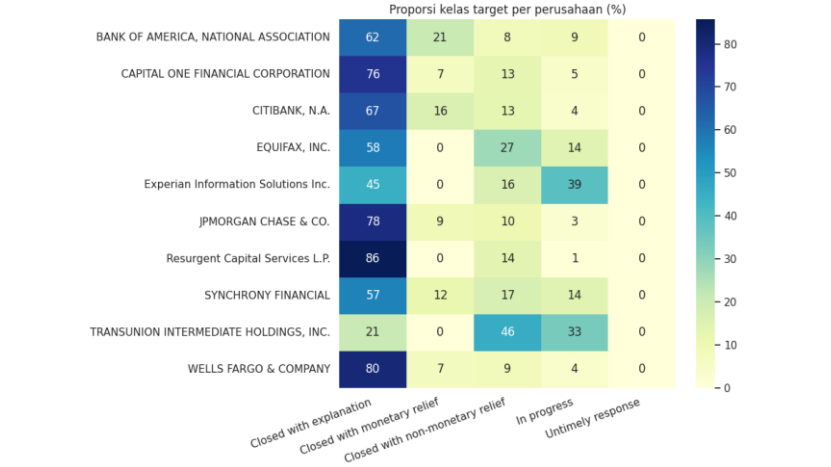
Closed with explanation 45,9%; Untimely response 0,13% (rasio imbalance 350,21:1).

Gambar 2. Distribusi jumlah kata per dokumen



Median 22 kata, maks 36 (200.000 baris sampel); teks gabungan jenis masalah, bukan narasi.

Gambar 3. Proporsi kelas target per perusahaan (%)



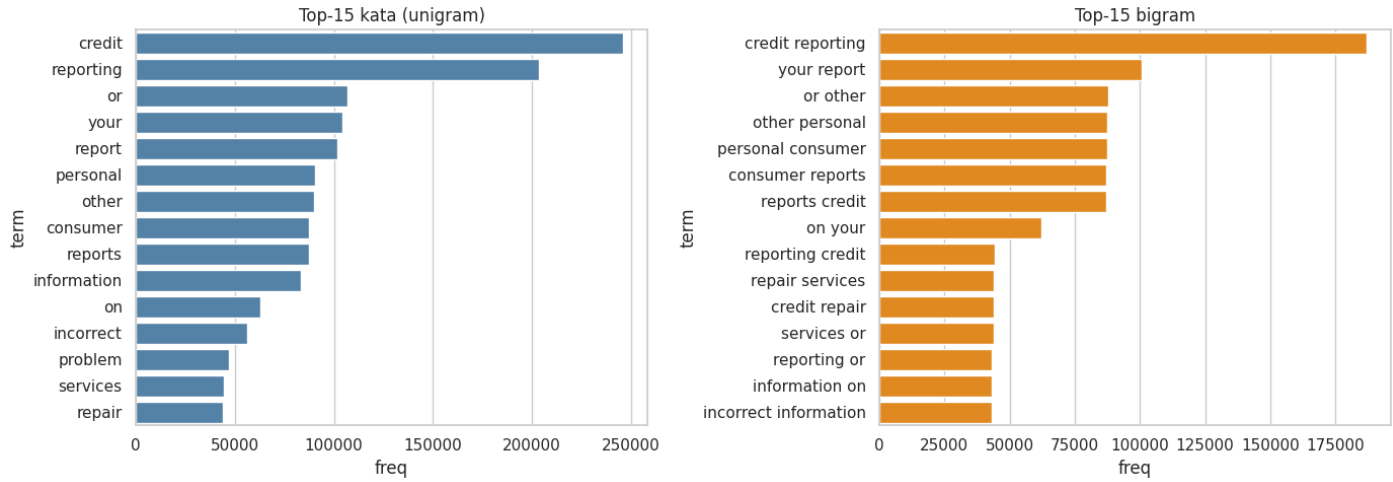
Hasil penanganan berbeda antar perusahaan (mis. Resurgent 86% explanation vs TransUnion 21%); perusahaan informatif sebagai fitur.

Gambar 4. Jumlah pengaduan per bulan



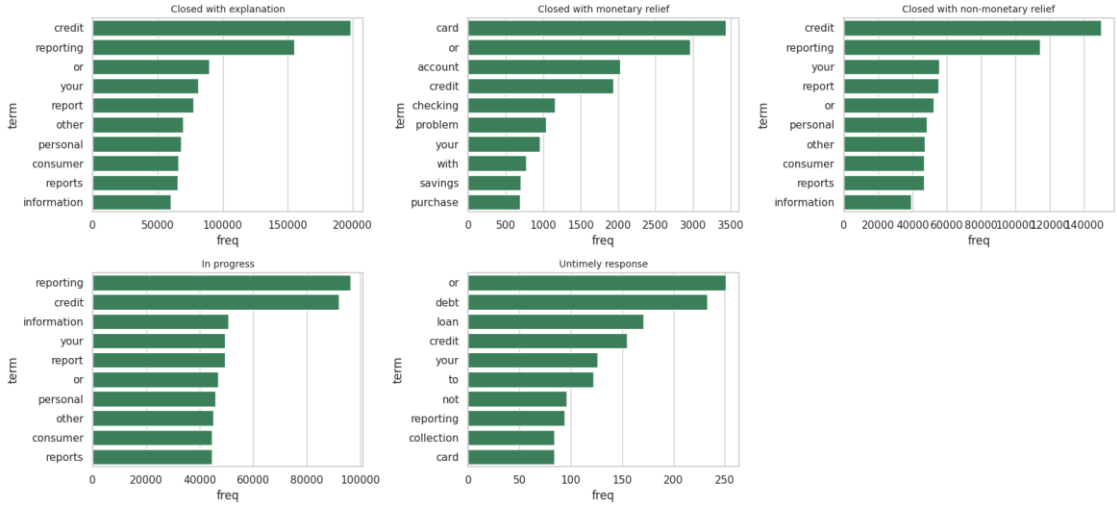
Data terkonsentrasi di 2023 dan 2026; urutan tanggal tidak teratur, konsisten dengan file yang terpotong.

Gambar 5. Top-15 unigram dan bigram (data latih)



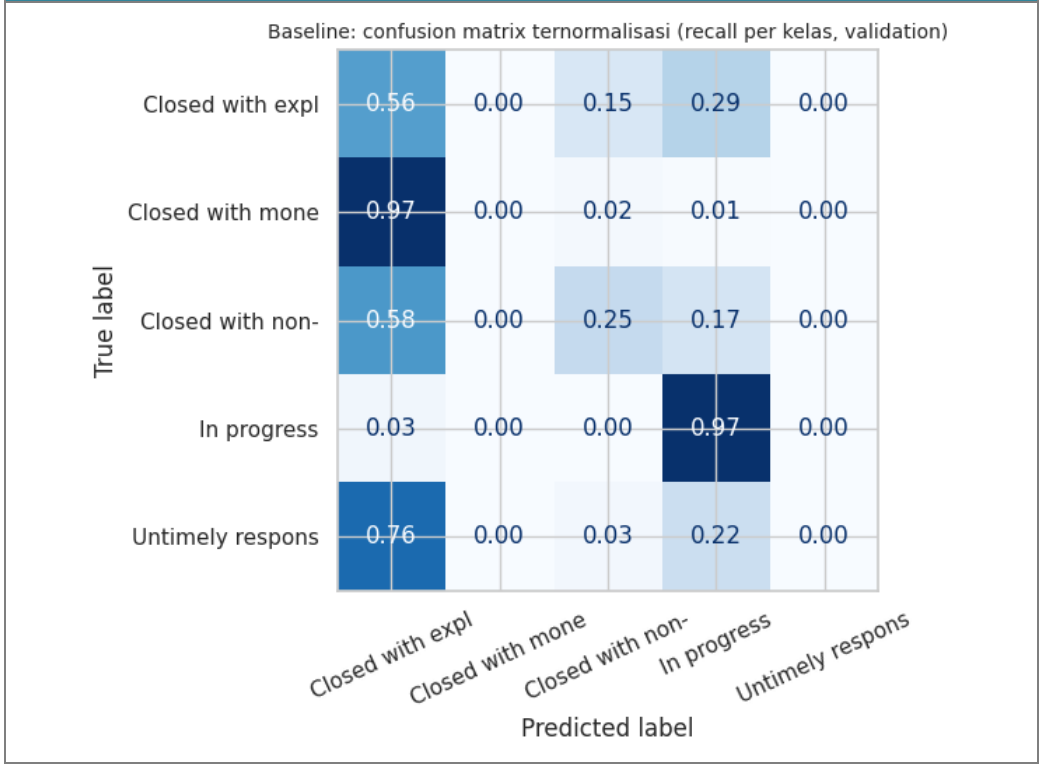
Tanpa penghapusan stopword, kata umum (credit, reporting, or, your) dan bigram credit reporting mendominasi.

Gambar 6. Kata teratas per kelas target



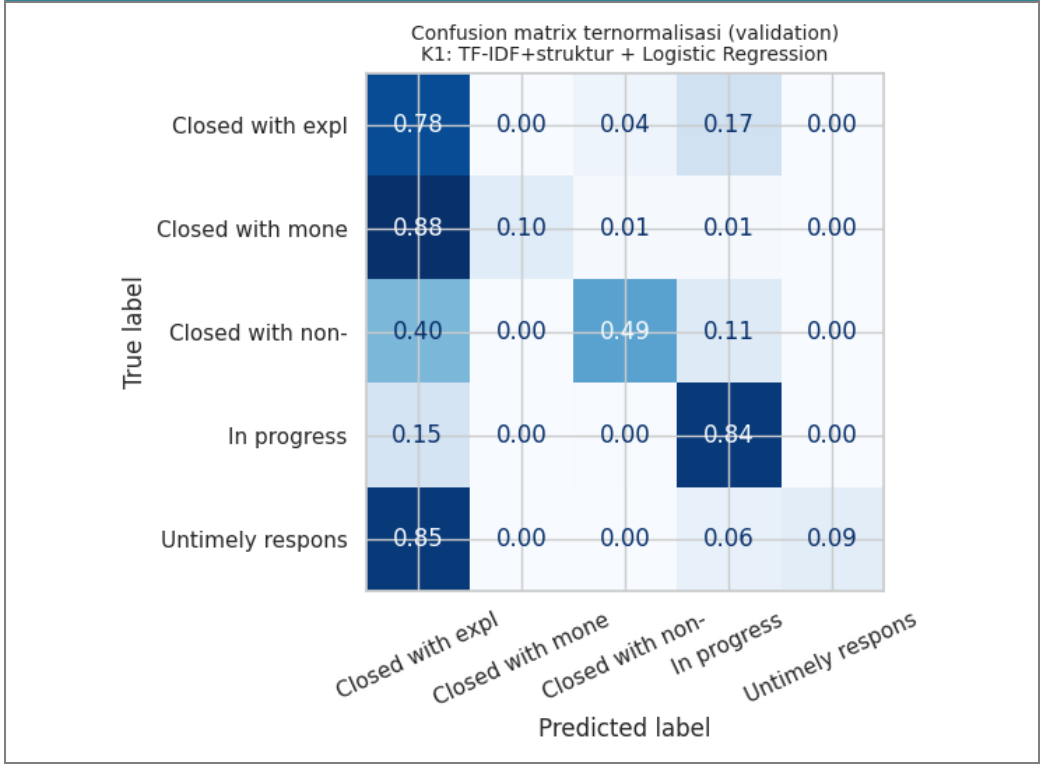
Kelas monetary relief didominasi kata kartu dan rekening (card, account); kelas lain didominasi istilah pelaporan kredit.

Gambar 7. Baseline: confusion matrix ternormalisasi (recall per kelas)



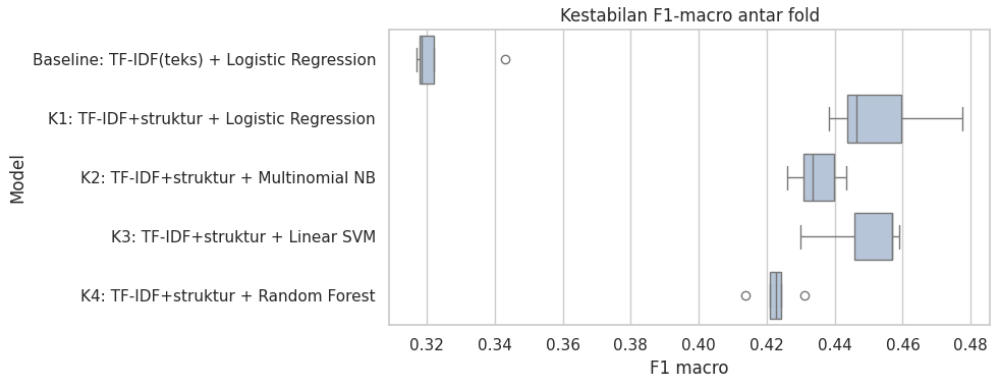
Baseline tidak pernah memprediksi monetary relief dan Untimely response; In progress terdeteksi 0,97.

Gambar 8. K1 (LR + struktur): confusion matrix ternormalisasi



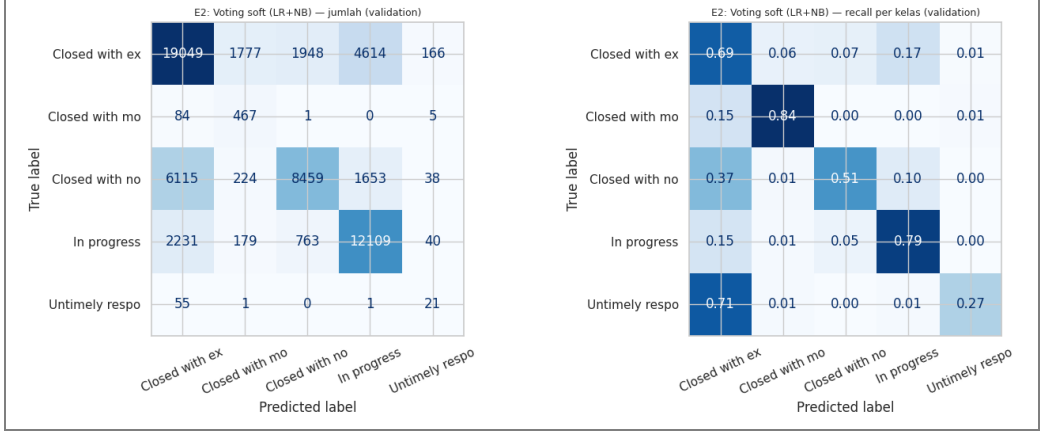
Recall monetary relief 0,10 dan Untimely response 0,09; kelas besar membaik (explanation 0,78; in progress 0,84).

Gambar 9. Kestabilan F1-macro antar fold (Stratified 5-Fold)



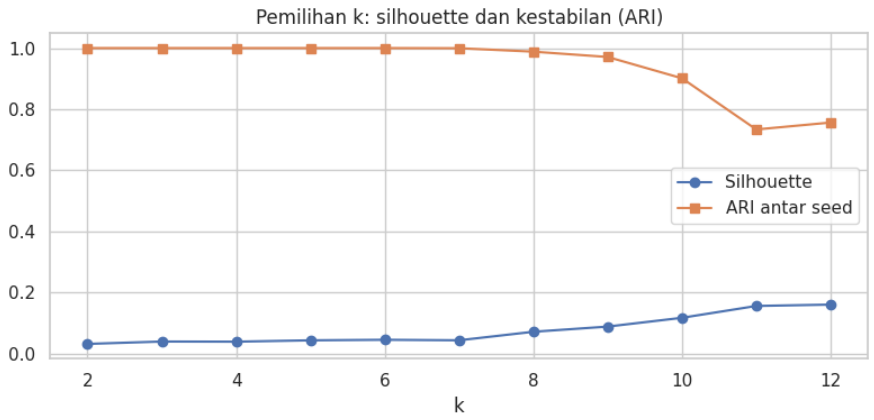
Baseline terendah (0,3237); keempat kandidat berkisar 0,4225–0,4531; std antar fold 0,0063–0,0158.

Gambar 10. Voting soft (LR+NB): confusion matrix pada validation



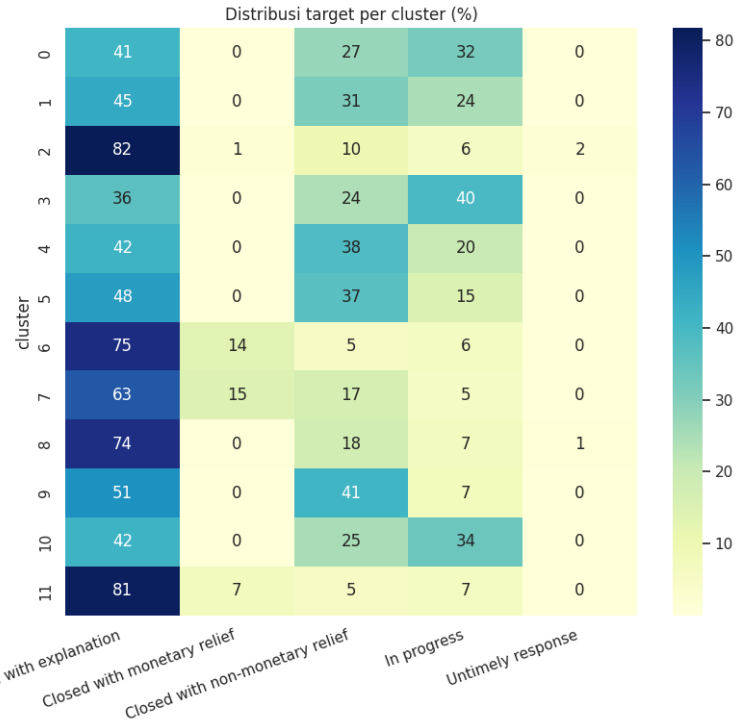
Recall per kelas: explanation 0,69; monetary relief 0,84; non-monetary 0,51; in progress 0,79; untimely 0,27.

Gambar 11. Pemilihan k: silhouette dan ARI



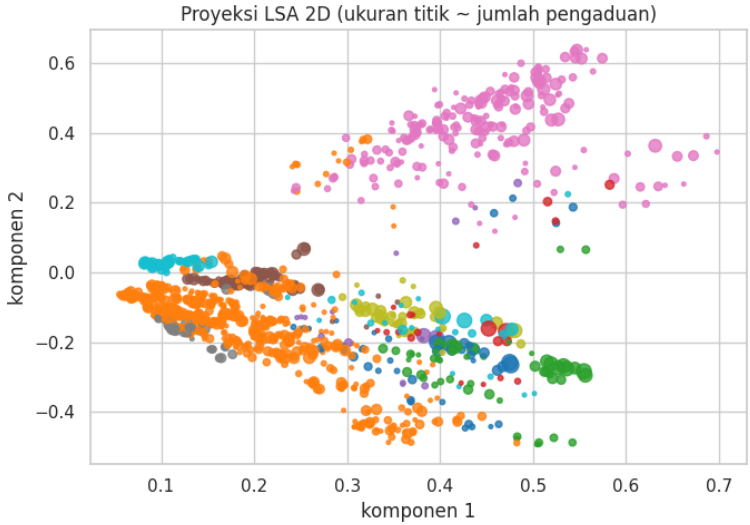
Silhouette 0,0312 (k = 2) → 0,1599 (k = 12); ARI turun dari 1,0 ke 0,7561.

Gambar 12. Distribusi target per cluster (%)



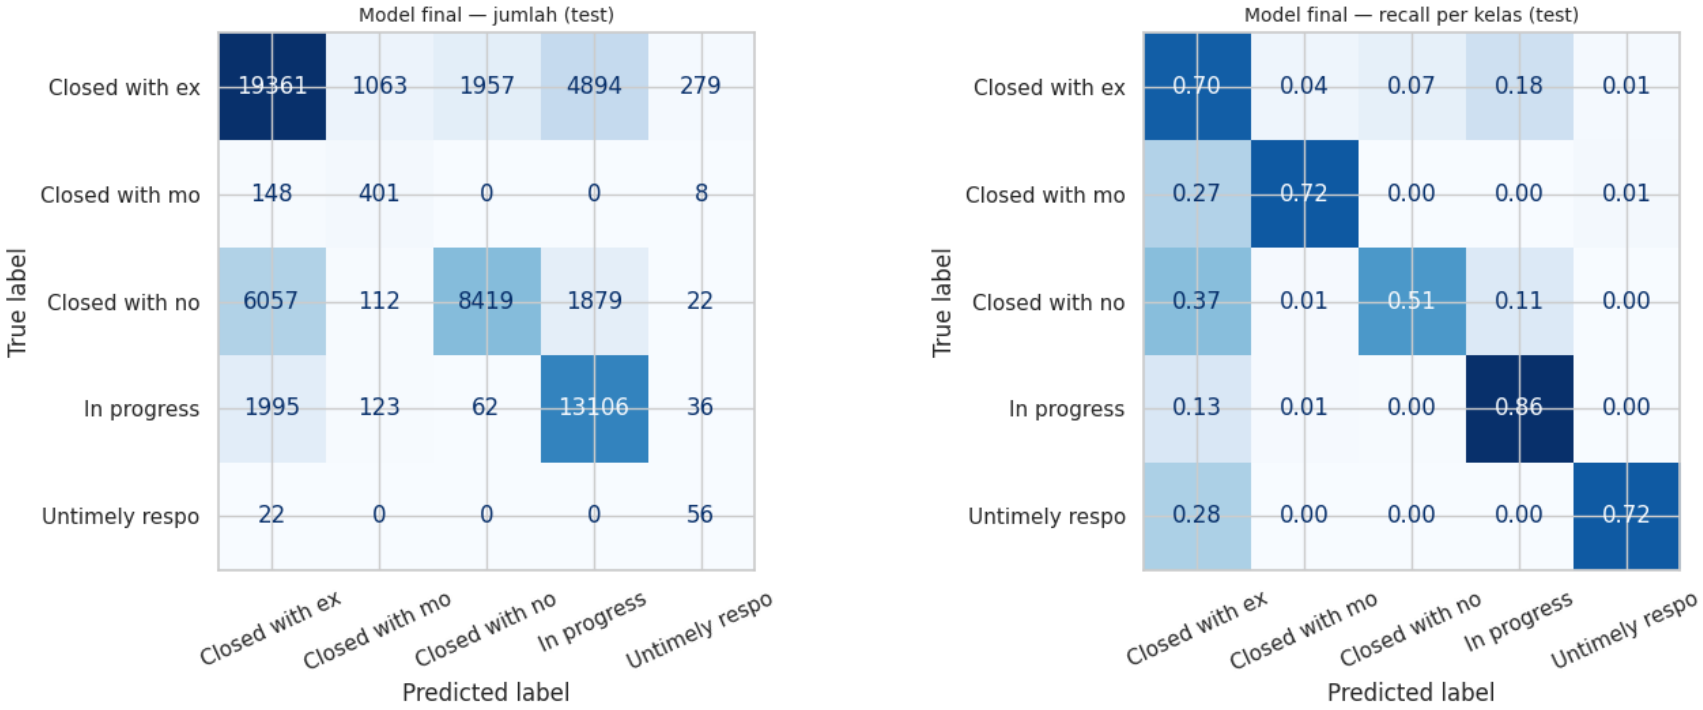
Cluster 2, 6, 8, dan 11 didominasi Closed with explanation (74–82%); NMI 0,0472.

Gambar 13. Proyeksi LSA 2D



Titik besar = jenis masalah dengan banyak pengaduan; pemisahan antar cluster masih tumpang-tindih.

Gambar 14. Model terbaik sementara (tuned): confusion matrix pada test set (dibuka sekali)



Recall per kelas: explanation 0,70; monetary relief 0,72; non-monetary 0,51; in progress 0,86; untimely 0,72; precision kelas kecil rendah (0,24 dan 0,14).