Prediksi Respons Perusahaan terhadap Pengaduan Konsumen CFPB Menggunakan TF-IDF dan Classical Machine Learning

LAPORAN PROYEK
UJIAN TENGAH SEMESTER

Mata Kuliah Pembelajaran Mesin — Proyek Text Mining

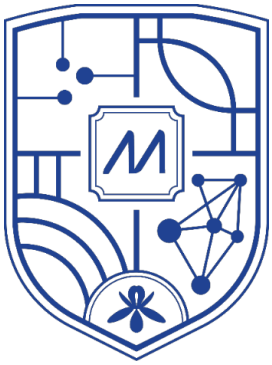
Kelompok: A12

Anggota:

231110937 – Fauzan Ramadhan Harahap

231111582 – Eka Satria

231111710 – Mhd. Hatami



PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN

2026

DAFTAR ISI

Daftar Gambar ii
Daftar Tabel iii
Pembagian Tugas iv
Bagian A. Laporan Teknis Proyek 1
1. PENDAHULUAN 2
1.1 Latar Belakang 2
1.2 Identifikasi dan Rumusan Masalah 2
1.3 Tujuan, Kontribusi, dan Luaran 2
1.4 Ruang Lingkup dan Batasan 3
1.5 Mengapa Masalah Ini Kompleks 3
2. TINJAUAN PUSTAKA DAN LANDASAN METODE 3
2.1 Text Mining dan Klasifikasi Multikelas 3
2.2 TF-IDF dan One-Hot Encoding 3
2.3 Algoritma Klasifikasi Kandidat 3
2.4 Ketidakseimbangan Kelas dan Metrik Evaluasi 4
2.5 Validasi, Data Leakage, dan Eksplorasi Tanpa Label 4
3. METODOLOGI PENELITIAN 4
3.1 Alur Penelitian dan Pemetaan Milestone 4
3.2 Sumber, Unit Observasi, dan Struktur Dataset 5
3.3 Kamus Data, Peran Kolom, dan Kebocoran 6
3.4 Audit Kualitas dan Keterbatasan Data 6
3.5 Eksplorasi Data Awal 7
3.6 Kapasitas Informasi Fitur 8
3.7 Preprocessing Teks dan Rekayasa Fitur 9
3.8 Pembagian Data dan Protokol Anti-Leakage 9
3.9 Rancangan Model dan Validasi 10
4. HASIL DAN PEMBAHASAN 10
4.1 Kinerja Dummy dan Baseline 10
4.2 Kontribusi Fitur Terstruktur dan Perbandingan Algoritma 11
4.3 Kestabilan melalui Stratified Cross-Validation 12
4.4 Evaluasi Voting Ensemble 13
4.5 Strategi Penanganan Ketidakseimbangan Kelas 14
4.6 Ketahanan terhadap Jenis Masalah Baru 14
4.7 Eksplorasi Unsupervised: LSA, KMeans, dan NMF 15
4.8 Seleksi Fitur Chi-Square 17
4.9 Hyperparameter Tuning dan Model Sementara 18
4.10 Analisis Kesalahan pada Data Validasi 18
4.11 Evaluasi Akhir pada Test Set Terkunci 18
4.12 Evaluasi terhadap Tujuan Penelitian 19
5. KETERBATASAN, REPRODUSIBILITAS, DAN RENCANA LANJUTAN 20
5.1 Keterbatasan Penelitian 20
5.2 Teknologi, Konfigurasi, dan Reprodusibilitas 20
5.3 Keterlacakan Temuan dan Eksperimen 21
5.4 Rencana Pengembangan Menuju UAS 21
6. KESIMPULAN DAN SARAN 22
6.1 Kesimpulan 22
6.2 Saran 22
DAFTAR PUSTAKA 22
LAMPIRAN: KONFIGURASI NOTEBOOK 23
A. Variabel Utama Notebook 23

Bagian B. Tautan 24

DAFTAR GAMBAR

Gambar 1. Tahapan penelitian berdasarkan notebook Milestone 1 5
Gambar 2. Distribusi jumlah pengaduan per bulan dalam berkas; rentan bias pemotongan 6
Gambar 3. Distribusi lima kelas target pada seluruh data valid 7
Gambar 4. Panjang teks pada seluruh sampel dan menurut kelas target 7
Gambar 5. Proporsi kelas target untuk sepuluh perusahaan dengan volume tertinggi 8
Gambar 6. Kata dan bigram yang paling sering pada data latih 9
Gambar 7. Kata dominan pada masing-masing kelas target 9
Gambar 8. Confusion matrix baseline pada data validasi (normalisasi recall) 11
Gambar 9. Confusion matrix kandidat K1 pada data validasi 12
Gambar 10. Sebaran skor F1-macro antar fold kandidat model 13
Gambar 11. Confusion matrix E2 voting soft pada data validasi 14
Gambar 12. Pemilihan jumlah klaster: silhouette dan kestabilan antar seed 15
Gambar 13. Komposisi kelas respons di tiap klaster hasil eksplorasi 16
Gambar 14. Visualisasi LSA dua dimensi dari jenis masalah 17
Gambar 15. Confusion matrix hasil akhir: frekuensi dan recall per kelas 19

DAFTAR TABEL

Tabel 1. Pembagian tugas anggota kelompok iv
Tabel 2. Rumusan tujuan, indikator, dan luaran Milestone 1 2
Tabel 3. Keterkaitan pertemuan, kegiatan, dan hasil 5
Tabel 4. Identitas dataset dan batasan penggunaan 5
Tabel 5. Peran fitur dan kekuatan asosiasi dengan target 6
Tabel 6. Distribusi lima kelas target setelah cleaning 7
Tabel 7. Hasil tabel-lookup eksploratif menurut penambahan fitur 8
Tabel 8. Konfigurasi pemisahan data dan pelatihan 10
Tabel 9. Baseline dan kandidat yang diuji 10
Tabel 10. Hasil model tunggal pada validation set 60.000 baris 10
Tabel 11. Hasil F1-macro per fold dan rerata 12
Tabel 12. Ringkasan model pada Stratified 5-Fold 13
Tabel 13. Perbandingan strategi class weighting 14
Tabel 14. Perbandingan validasi stratified dan grouped 14
Tabel 15. Seleksi fitur chi-square pada 3-fold 17
Tabel 16. Ringkasan keputusan tahap penyempurnaan 18
Tabel 17. Perbandingan model pada test set akhir 18
Tabel 18. Precision, recall, dan F1 per kelas pada test set 19
Tabel 19. Pemeriksaan tujuan dan bukti capaian Milestone 1 19
Tabel 20. Lingkungan dan komponen implementasi 20
Tabel 21. Keterkaitan pembahasan dengan bagian notebook 21
Tabel 22. Agenda prioritas pasca-UTS 21
Tabel 23. Variabel utama pada konfigurasi notebook 23
Tabel 24. Daftar tautan proyek 24

PEMBAGIAN TUGAS

Pembagian tugas antaranggota kelompok pada pengerjaan Milestone 1 dirinci pada Tabel 1. Pembagian disusun agar beban kerja seimbang, baik pada pengerjaan notebook (Cell 1–36) maupun penyusunan laporan.

Tabel 1. Pembagian tugas anggota kelompok

NIM	Nama	Peran	Rincian pekerjaan
231110937	Fauzan Ramadhan Harahap	Problem Formulation, Data Understanding, EDA, dan Preprocessing Teks	**Notebook:** setup dan konfigurasi (Cell 1–2); audit struktur, pemotongan berkas, kolom berpotensi bocor, dan target (Cell 3–6); EDA distribusi kelas, panjang teks, kapasitas informasi fitur, dan hubungan perusahaan–target (Cell 7–10); sampel stratified (Cell 11); preprocessing teks *stateless* (Cell 12); kata dan bigram teratas (Cell 16). **Laporan:** Abstrak dan Abstract; Bab 1; subbab 3.1–3.7; subbab 5.2; Lampiran A.
231111582	Eka Satria	Pemodelan Baseline, Kandidat Model, dan Validasi	**Notebook:** pembagian data, fungsi pipeline, dan metrik (Cell 13–14); baseline dan dummy (Cell 15); temuan awal baseline (Cell 17); kandidat K1–K4 (Cell 18–19); Stratified 5-Fold dan ensemble voting (Cell 20–22); analisis ketidakseimbangan kelas (Cell 23); confusion matrix CV dan `GroupKFold` (Cell 24). **Laporan:** Bab 2; subbab 3.8–3.9; subbab 4.1–4.6; Bab 6 (Kesimpulan dan Saran).
231111710	Mhd. Hatami	Eksplorasi Unsupervised, Tuning, Analisis Kesalahan, Evaluasi Akhir, dan Dokumentasi	**Notebook:** keputusan perbaikan berbasis bukti (Cell 25); LSA, KMeans, dan NMF (Cell 26–28); seleksi fitur chi-square (Cell 29); `RandomizedSearchCV` dan model hasil tuning (Cell 30–31); error analysis dan interpretabilitas (Cell 32–33); evaluasi akhir test set, sintesis, dan penyimpanan hasil (Cell 34–36). **Laporan:** subbab 4.7–4.12; subbab 5.1, 5.3, dan 5.4; Daftar Pustaka; Bagian B (repositori GitHub dan tautan notebook); pemeriksaan konsistensi laporan dengan notebook.

Sumber: Notebook `A12_Keluhan_Pelanggan.ipynb`; nomor Cell merujuk pada penomoran [CELL n] pada notebook.

Bagian A. Laporan Teknis Proyek

Prediksi Respons Perusahaan terhadap Pengaduan Konsumen CFPB Menggunakan TF-IDF dan Classical Machine Learning

Fauzan Ramadhan Harahap[1], Eka Satria[2], Mhd. Hatami[3]

[123] Program Studi Teknik Informatika, Fakultas Informatika, Universitas Mikroskil, Medan

Kelompok A12 | NIM: 231110937, 231111582, 231111710

fauzan.ramadhan@students.mikroskil.ac.id; eka.satria@students.mikroskil.ac.id; mhd.hatami@students.mikroskil.ac.id

Laporan Milestone 1 (UTS) | Mata Kuliah Pembelajaran Mesin | Proyek Text Mining

Abstrak

Pengaduan konsumen terkait laporan kredit pada Consumer Financial Protection Bureau (CFPB) menghasilkan data historis berskala besar, tetapi kategori respons perusahaan tidak selalu dapat ditentukan hanya dari jenis pengaduan. Penelitian ini mengembangkan pendekatan klasifikasi multikelas untuk memprediksi Company response to consumer dengan classical machine learning. Data kerja berasal dari 1.048.575 baris dan 15 kolom, dengan 1.048.573 baris setelah mengeluarkan dua target kosong. Sampel stratified sebanyak 300.000 baris dibagi 60% data latih, 20% validasi, dan 20% uji. Teks tersusun dari Product, Sub-product, Issue, dan Sub-issue karena kolom narasi konsumen tidak tersedia; informasi Company, State, Submitted via, dan Tags ditambahkan melalui one-hot encoding. Representasi TF-IDF dan Logistic Regression digunakan sebagai baseline, kemudian dibandingkan dengan Multinomial Naive Bayes, Linear SVM, Random Forest, serta voting ensemble. Validasi dilakukan dengan Stratified 5-Fold dan `GroupKFold`, dengan F1-macro sebagai metrik utama karena rasio ketidakseimbangan kelas sekitar 350,2. Hasil akhir pada 60.000 data uji memberikan F1-macro 0,5323, balanced accuracy 0,7013, dan akurasi 0,6891, lebih tinggi dibanding baseline F1-macro 0,3277. Penelitian juga menemukan keterbatasan penting berupa indikasi pemotongan berkas pada batas Excel, dominasi teks terstruktur yang berulang, dan label berbeda pada fitur identik. Temuan ini menjadi dasar perbaikan data dan evaluasi lanjutan menuju UAS.

Kata kunci: text mining; TF-IDF; klasifikasi multikelas; Logistic Regression; ketidakseimbangan kelas; CFPB.

Abstract

The Consumer Financial Protection Bureau (CFPB) provides a large collection of historical consumer complaints, but the company response category cannot always be determined from complaint characteristics alone. This project develops a multiclass classification approach for predicting Company response to consumer using classical machine learning. The source file contains 1,048,575 observations and 15 columns; after excluding two missing targets, 1,048,573 records remain. A stratified working sample of 300,000 observations is partitioned into training, validation, and test sets at 60/20/20. Complaint text is composed of Product, Sub-product, Issue, and Sub-issue because consumer narratives are unavailable. TF-IDF is combined with one-hot encoded company and submission attributes. Logistic Regression is adopted as a baseline and compared against Multinomial Naive Bayes, Linear SVM, Random Forest, and voting ensembles. Models are evaluated using stratified cross-validation and grouped stress testing, with macro F1 as the main metric due to severe class imbalance. The selected provisional model achieves 0.5323 macro F1, 0.7013 balanced accuracy, and 0.6891 accuracy on the locked test set, versus 0.3277 macro F1 for the baseline. The analysis highlights a likely Excel-induced file truncation, substantial repetition in structured complaint text, and conflicting labels for identical features. These constraints guide the next phase of data and model development.

Keywords: text classification; TF-IDF; multiclass learning; consumer complaints; class imbalance.

1. PENDAHULUAN

1.1 Latar Belakang

Consumer Financial Protection Bureau (CFPB) menyediakan Consumer Complaint Database yang memuat informasi pengaduan konsumen dan respons perusahaan. Pengaduan tersebut mencakup berbagai produk dan layanan keuangan, termasuk laporan kredit. Pada data yang digunakan, perusahaan seperti TransUnion, Experian, dan Equifax merupakan pihak yang banyak menerima pengaduan, dengan isu antara lain investigasi yang memerlukan lebih dari 30 hari dan ketidaksesuaian informasi pada laporan kredit [1].

Pemeriksaan manual terhadap volume pengaduan yang besar membutuhkan waktu, sedangkan satu jenis masalah dapat berakhir dengan tanggapan perusahaan yang berbeda. Karena itu, diperlukan model prediksi untuk membantu mengidentifikasi kemungkinan kategori respons berdasarkan informasi yang tersedia pada saat pengaduan diterima. Model tidak dimaksudkan menggantikan keputusan perusahaan maupun otoritas, tetapi menjadi dukungan analitis dalam memahami pola pada data historis.

Tantangan penelitian ini tidak terbatas pada pemilihan algoritma. Data memiliki lima kelas dengan distribusi yang sangat tidak seimbang, sebagian kolom berpotensi mengandung informasi pasca-respons, dan berkas hasil pengumpulan menunjukkan indikasi terpotong pada batas Excel. Di sisi lain, tidak terdapat kolom narasi bebas sehingga teks yang dapat diolah adalah gabungan label masalah terstruktur. Kondisi tersebut penting dinyatakan sejak awal agar skor model tidak ditafsirkan melebihi kualitas data yang mendukungnya.

1.2 Identifikasi dan Rumusan Masalah

Kesulitan utama adalah mempelajari hubungan antara jenis pengaduan, identitas perusahaan, kanal penyampaian, dan kategori respons tanpa menggunakan informasi yang baru tersedia setelah perusahaan menjawab. Beragam kombinasi kategori membuat aturan if–else sederhana tidak cukup untuk menangani seluruh variasi data. Selain itu, ketidakseimbangan kelas dapat mendorong model untuk mengutamakan prediksi kelas mayoritas.

Rumusan masalah penelitian adalah: bagaimana membangun, membandingkan, dan memvalidasi model klasifikasi teks berbasis TF-IDF dan classical machine learning untuk memprediksi kategori Company response to consumer dari atribut yang diketahui saat pengaduan masuk, serta bagaimana menafsirkan hasilnya ketika data dan kelas memiliki keterbatasan?

1.3 Tujuan, Kontribusi, dan Luaran

Tabel 2. Rumusan tujuan, indikator, dan luaran Milestone 1

Aspek	Uraian	Bukti/luaran
Pemahaman data	Memeriksa sumber, struktur, *missing values*, kelas, dan keterbatasan berkas.	Audit data dan visualisasi EDA
Perancangan fitur	Membentuk teks terstruktur dan fitur kategorikal tanpa kolom pasca-respons.	`Pipeline` TF-IDF dan one-hot
Pemodelan	Membangun dummy, baseline, dan kandidat classical ML.	Matriks metrik validasi
Validasi	Menguji performa antar-*fold* dan generalisasi jenis masalah baru.	Stratified 5-Fold dan `GroupKFold`
Penyempurnaan	Menguji pembobotan kelas, seleksi fitur, serta tuning awal.	Perbandingan konfigurasi

Aspek	Uraian	Bukti/luaran
Hasil sementara	Mengevaluasi model terpilih pada test set terkunci.	Metrik uji dan error analysis

Sumber: Notebook, bagian P1 (Problem Formulation) dan ringkasan checkpoint tiap pertemuan.

Kontribusi Milestone 1 terletak pada pengujian yang menekankan keterlacakan hasil. Setiap pengembangan fitur dan model disandingkan dengan baseline, faktor kebocoran data diaudit sebelum pelatihan, dan performa tidak hanya dinilai melalui akurasi. Hasil akhir proyek tahap UTS adalah model terbaik sementara beserta catatan batas generalisasi dan rencana perbaikan untuk tahap UAS.

1.4 Ruang Lingkup dan Batasan

Ruang lingkup eksperimen adalah supervised text classification dengan classical machine learning, bukan pendekatan deep learning. Satu observasi merepresentasikan satu pengaduan atau Complaint ID. Label target merupakan kategori respons dalam berkas historis, bukan pengukuran kepuasan konsumen atau keberhasilan final penyelesaian sengketa.

Data mentah tidak diubah demi mengejar metrik yang lebih tinggi. Data kerja menggunakan sampel stratified 300.000 baris dari berkas yang tersedia; sampel ini mempertahankan proporsi target di dalam berkas, tetapi tidak menjamin representativitas terhadap seluruh basis data CFPB. Model yang dinyatakan terbaik bersifat sementara karena perbandingan beberapa kandidat belum disetarakan sepenuhnya dan test set telah digunakan satu kali pada UTS.

1.5 Mengapa Masalah Ini Kompleks

Pertama, target lima kelas mempunyai rasio jumlah kelas mayoritas terhadap minoritas sekitar 350,21. Model dengan akurasi tinggi belum tentu mengenali kelas langka. Kedua, berbagai kombinasi jenis pengaduan dapat memperoleh respons berbeda, sehingga batas prediksi berasal dari informasi dalam fitur, bukan hanya dari kompleksitas algoritma.

Ketiga, banyak fitur secara semantik berhubungan dengan respons, tetapi sebagian baru tersedia sesudah tindakan perusahaan. Kolom seperti Timely response? justru berkorelasi tinggi dengan target dan berisiko menimbulkan *data leakage*. Keempat, validasi acak dapat memberi hasil berbeda dari evaluasi terhadap jenis masalah yang benar-benar baru; karena itu digunakan dua skema validasi. Kelima, representasi teks bersumber dari kategori yang berulang, bukan narasi bebas, sehingga generalisasi bahasa yang diuji masih terbatas.

2. TINJAUAN PUSTAKA DAN LANDASAN METODE

2.1 Text Mining dan Klasifikasi Multikelas

Text mining merupakan proses menemukan pola dari dokumen atau atribut berbentuk teks. Dalam penelitian ini teks yang digunakan tidak berasal dari uraian bebas konsumen, melainkan hasil penggabungan empat kolom yang mendeskripsikan produk dan masalah. Konsekuensinya, kemampuan model terutama berkaitan dengan representasi kategori masalah dan kombinasi dengan atribut perusahaan, bukan pemahaman narasi yang panjang.

Klasifikasi multikelas memetakan satu observasi ke tepat satu dari lima kelas target. Kategori yang digunakan adalah Closed with explanation, Closed with monetary relief, Closed with non-monetary relief, In progress, dan Untimely response. Dua kelas terakhir perlu ditafsirkan secara hati-hati karena merupakan status proses, bukan selalu hasil final penyelesaian.

2.2 TF-IDF dan One-Hot Encoding

Term Frequency–Inverse Document Frequency (TF-IDF) memberi bobot pada istilah berdasarkan frekuensinya dalam suatu dokumen dan kelangkaannya pada kumpulan dokumen [2]. Pembobotan ini berguna untuk mengurangi dominasi kata yang muncul di hampir semua jenis pengaduan. Eksperimen

memakai sublinear term frequency, `min_df`, dan batas jumlah fitur yang diatur dalam pipeline. Variasi unigram dan bigram kemudian diuji pada tuning.

Selain fitur teks, Company, State, Submitted via, dan Tags direpresentasikan menggunakan one-hot encoding. Encoder dikonfigurasi untuk menangani kategori tidak dikenal atau jarang, sehingga data baru tidak langsung menyebabkan kegagalan transformasi. Teks dan fitur kategorikal digabung melalui `ColumnTransformer`, sedangkan parameter transformasi dipelajari hanya dari data latih.

2.3 Algoritma Klasifikasi Kandidat

Logistic Regression menjadi baseline karena umum digunakan pada matriks fitur teks berdimensi tinggi, efisien, serta menghasilkan skor probabilitas yang dapat dimanfaatkan dalam evaluasi. Multinomial Naive Bayes adalah model probabilistik yang cepat dan sesuai sebagai pembanding pada fitur bernilai non-negatif. Linear Support Vector Machine (SVM) digunakan karena dikenal efektif pada kategorisasi teks berdimensi tinggi [3]. Random Forest menguji apakah hubungan non-linear antarfitur memberikan manfaat [4].

Dua model ensemble juga diuji. Voting hard menggabungkan prediksi kelas dari Logistic Regression, Naive Bayes, dan Linear SVM, sedangkan voting soft menggabungkan probabilitas Logistic Regression dan Naive Bayes. Ensemble tidak otomatis menjadi pilihan terbaik karena biaya komputasi dan perilaku terhadap kelas minoritas tetap perlu dibandingkan secara setara.

2.4 Ketidakseimbangan Kelas dan Metrik Evaluasi

Akurasi adalah proporsi prediksi yang tepat, tetapi tidak cukup ketika sebagian besar observasi berada dalam beberapa kelas. F1-macro menghitung rata-rata F1 setiap kelas tanpa memberi bobot menurut ukuran kelas. Balanced accuracy menghitung rata-rata recall per kelas. Matthews Correlation Coefficient (MCC) menjadi ukuran korelasi antara prediksi dan label yang mempertimbangkan seluruh matriks kebingungan, sedangkan PR-AUC menyoroti *trade-off* presisi–recall [5], [6].

Untuk memperbaiki pembelajaran kelas langka, penelitian membandingkan tanpa bobot, `class_weight` balanced, dan sqrt-balanced. Strategi sqrt-balanced mengurangi perbedaan bobot ekstrem dibanding balanced penuh, sehingga diharapkan memberi kompromi antara mengingat kelas kecil dan menjaga ketepatan kelas mayoritas.

2.5 Validasi, Data Leakage, dan Eksplorasi Tanpa Label

Data *leakage* terjadi ketika model dilatih menggunakan informasi yang seharusnya tidak tersedia pada waktu prediksi [7]. Karena itu, kolom pasca-respons dibuang, dan `TfidfVectorizer` maupun `OneHotEncoder` diletakkan di dalam `Pipeline`. Stratified *cross-validation* menjaga distribusi kelas pada setiap *fold*, sedangkan `GroupKFold` berdasarkan jenis teks masalah menjadi *stress test* terhadap kombinasi yang tidak muncul selama pelatihan.

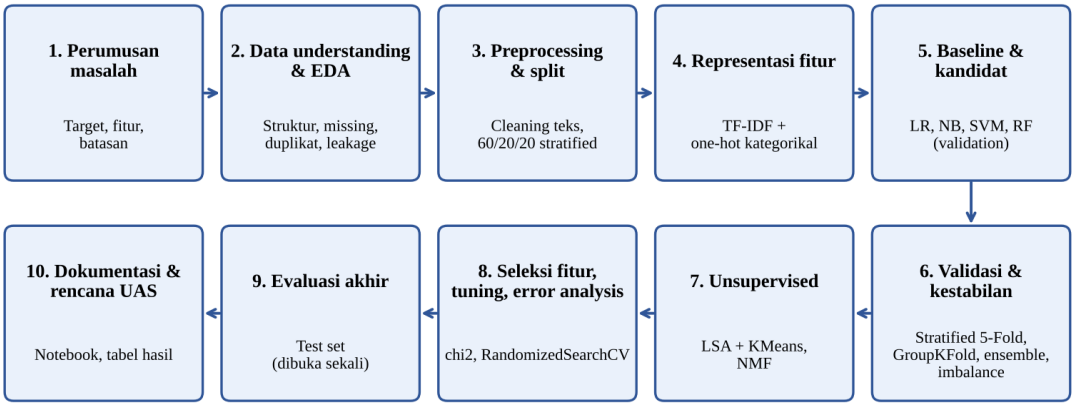
Sebagai eksplorasi pendamping, `TruncatedSVD` atau Latent Semantic Analysis (LSA) digunakan untuk mereduksi matriks TF-IDF [8], lalu KMeans mempelajari pengelompokan tema. Koefisien silhouette [9], Adjusted Rand Index antar seed, dan Normalized Mutual Information terhadap target membantu membedakan struktur topik dari kemampuan untuk memprediksi kategori respons. Seluruh pemrosesan menggunakan scikit-learn [10].

3. METODOLOGI PENELITIAN

3.1 Alur Penelitian dan Pemetaan Milestone

Pelaksanaan penelitian mengacu pada urutan Pertemuan 1 hingga UTS. Tahap awal merumuskan masalah, dilanjutkan pemeriksaan dataset, EDA, cleaning, representasi fitur, pembangunan baseline, pengujian kandidat, validasi, eksperimen tanpa label, seleksi fitur, tuning, dan evaluasi akhir. Setiap

tahap dijalankan dalam notebook Colab agar hasil pada laporan dapat ditelusuri ke keluaran komputasi.



Gambar 1. Tahapan penelitian berdasarkan notebook Milestone 1

Sumber: disusun dari struktur notebook (P1–UTS).

Tabel 3. Keterkaitan pertemuan, kegiatan, dan hasil

Tahap	Fokus	Hasil yang dilaporkan
P1	Problem formulation	Tujuan, fitur, target, dan jenis masalah
P2	Data understanding dan EDA	Audit struktur, distribusi kelas, panjang teks, kekuatan fitur
P3	Preprocessing dan baseline	Cleaning, split, TF-IDF, Dummy, Logistic Regression
P4	Feature engineering dan kandidat	One-hot, Logistic Regression, NB, SVM, RF
P5	Validasi dan stabilitas	Stratified 5-Fold, `GroupKFold`, ensemble
P6	Eksplorasi unsupervised	LSA, KMeans, NMF
P7	Seleksi fitur dan tuning	Chi-square, `RandomizedSearchCV`, analisis kesalahan
UTS	Finalisasi sementara	Evaluasi test set dan dokumentasi

Sumber: Struktur notebook (P1–UTS).

3.2 Sumber, Unit Observasi, dan Struktur Dataset

Dataset berasal dari Consumer Complaint Database yang dipublikasikan CFPB [1]. Dalam berkas kerja, satu baris adalah satu pengaduan terhadap perusahaan tertentu, dengan Complaint ID sebagai identitas. Data yang dimuat berjumlah 1.048.575 baris dengan 15 kolom. Audit notebook tidak menemukan baris duplikat penuh maupun Complaint ID ganda. Dua observasi dengan target kosong dikeluarkan sehingga tersisa 1.048.573 baris untuk analisis.

Tabel 4. Identitas dataset dan batasan penggunaan

Aspek	Keterangan
Sumber	CFPB Consumer Complaint Database

Aspek	Keterangan
Format masukan	CSV (hasil berkas yang dipakai dalam Colab)
Ukuran	1.048.575 baris, 15 kolom sebelum cleaning
Target	Company response to consumer
Observasi	Satu Complaint ID = satu pengaduan
Rentang tanggal	3 April 2014 – 21 September 2026
Mode teks	Structured: gabungan Product, Sub-product, Issue, Sub-issue
Data pemodelan	300.000 observasi hasil stratified sampling
Catatan	Jumlah data tepat pada batas baris Excel; indikasi data terpotong

Sumber: Notebook, Cell 3–4 (P2).

3.3 Kamus Data, Peran Kolom, dan Kebocoran

Pemilihan fitur didasarkan pada ketersediaan informasi ketika pengaduan masuk. Empat kolom jenis masalah disatukan menjadi teks. Empat kolom lain menjadi fitur kategorikal. Kolom Date received, ZIP code, Date sent to company, serta Complaint ID tidak digunakan sebagai prediktor dalam konfigurasi model; ID khususnya hanya berperan sebagai pengenal. Kolom Timely response? dan Company public response dikeluarkan karena bersifat pasca-respons.

Tabel 5. Peran fitur dan kekuatan asosiasi dengan target

Kolom	Peran	Cramér's V
Product	Komponen teks	0,3916
Sub-product	Komponen teks	0,2282
Issue	Komponen teks	0,2959
Sub-issue	Komponen teks	0,2671
Company	Kategorikal	0,3682
State	Kategorikal	0,0600
Submitted via	Kategorikal	0,0730
Tags	Kategorikal	0,0880
Timely response?	Dikeluarkan: pasca-respons	0,6626
Company public response	Dikeluarkan: pasca-respons	0,2730

Sumber: Notebook, Cell 5 (P2); Cramér's V terkoreksi bias.

Asosiasi tinggi belum berarti sebuah fitur layak dipakai. Timely response? memiliki nilai Cramér's V 0,6626, lebih tinggi daripada fitur yang dipertahankan. Dalam audit crosstab, label Untimely response muncul sebesar 43,9% pada kelompok dengan Timely response? = No, tetapi 0% pada kelompok Yes. Informasi semacam ini tidak valid sebagai masukan prediksi awal karena mencerminkan kondisi sesudah respons.

3.4 Audit Kualitas dan Keterbatasan Data

Notebook menandai jumlah 1.048.575 baris tepat sama dengan batas baris data pada Excel ketika satu baris digunakan untuk header. Kondisi ini merupakan indikasi kuat bahwa file mungkin telah dipotong ketika disimpan ulang, bukan pembuktian bahwa populasi CFPB hanya berjumlah demikian. Rentang tanggal pun tidak tersusun kronologis: 564.644 baris berasal dari 2023 dan 483.467 dari 2026, sedangkan tahun lain hanya memiliki jumlah sangat sedikit. Karena itu, perhitungan tren waktu tidak boleh digeneralisasikan ke keseluruhan populasi CFPB.



Gambar 2. Distribusi jumlah pengaduan per bulan dalam berkas; rentan bias pemotongan

Sumber: Notebook, Cell 4 (P2).

Keterbatasan kedua adalah tidak adanya kolom Consumer complaint narrative. Notebook otomatis menggunakan empat kolom terstruktur untuk membentuk teks; sesudah cleaning terdapat 1.483 kombinasi teks unik dari 1.048.573 baris. Tingkat pengulangan mencapai sekitar 99,9%, tetapi tidak diperlakukan sebagai duplikasi baris yang harus dibuang karena jenis masalah yang sama dapat dialami banyak konsumen dan menerima respons berbeda.

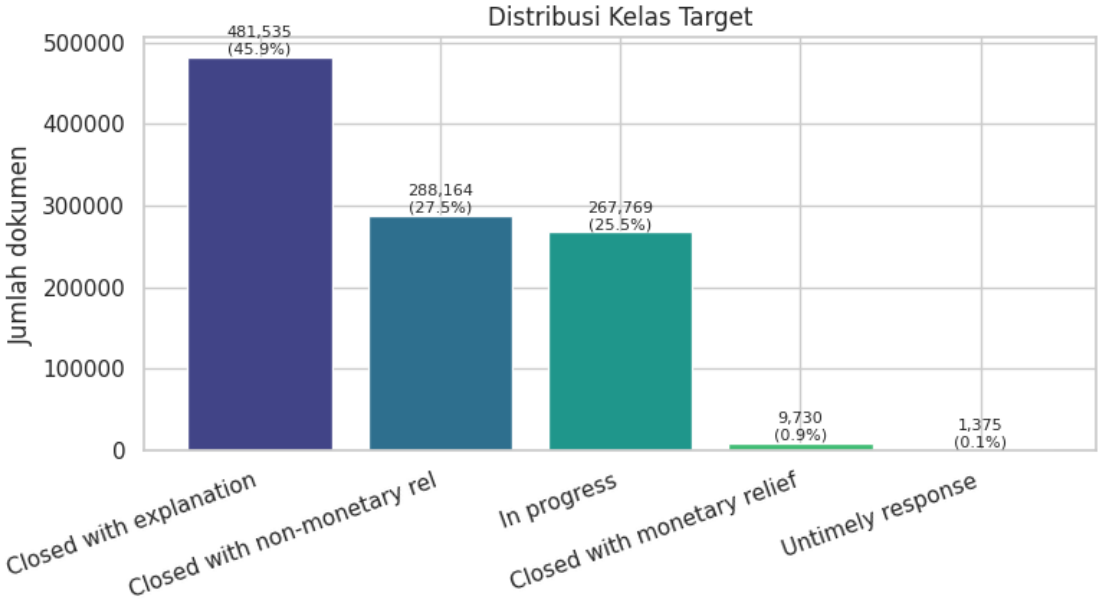
3.5 Eksplorasi Data Awal

EDA dilakukan untuk memahami profil kelas dan mendukung keputusan pemodelan. Lima kelas target berbeda jauh jumlahnya, dengan Closed with explanation sebagai mayoritas (481.535 baris atau 45,9%) dan Untimely response sebagai minoritas (1.375 baris atau 0,13%). Rasio sekitar 350,21 menunjukkan ketidakseimbangan berat. Prediktor yang selalu memilih kelas mayoritas sudah memperoleh akurasi 0,4592, tetapi F1-macro hanya 0,1259.

Tabel 6. Distribusi lima kelas target setelah cleaning

Kelas	Jumlah	Proporsi
Closed with explanation	481.535	45,92%
Closed with non-monetary relief	288.164	27,48%
In progress	267.769	25,54%
Closed with monetary relief	9.730	0,93%
Untimely response	1.375	0,13%

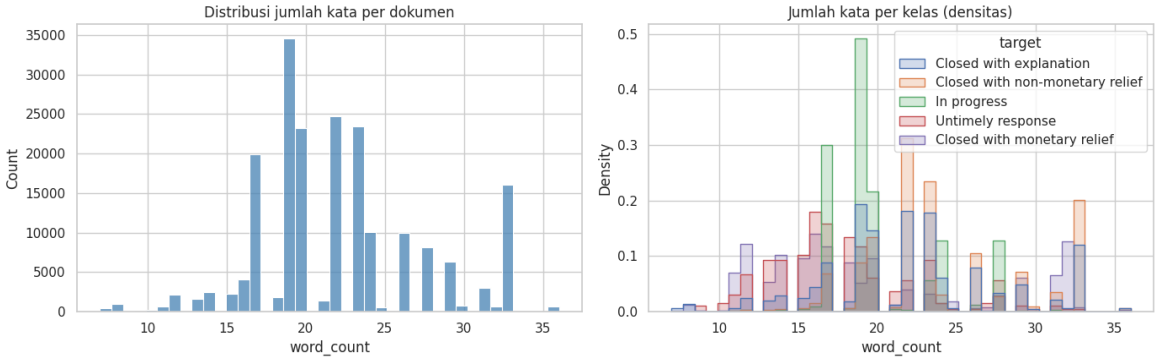
Sumber: Notebook, Cell 7 (P2).



Gambar 3. Distribusi lima kelas target pada seluruh data valid

Sumber: Notebook, Cell 7 (P2).

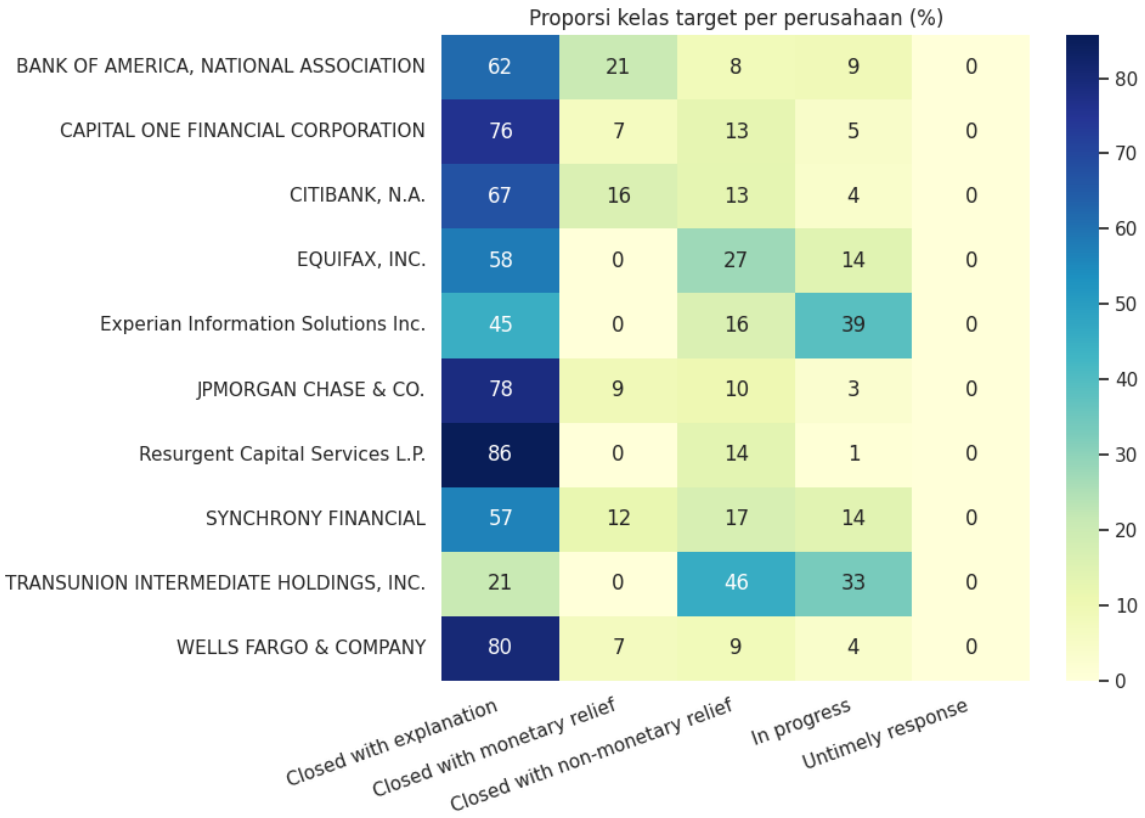
Distribusi panjang teks pada sampel EDA 200.000 baris memiliki rata-rata 22,09 kata, simpangan baku 5,17, median 22, dan panjang antara 7 hingga 36 kata. Tidak ada teks di bawah lima kata. Kelas Closed with non-monetary relief rata-rata sekitar 24,12 kata, sedangkan Untimely response 17,91 kata. Meski terlihat perbedaan rerata, histogram antar kelas saling tumpang tindih sehingga panjang teks saja belum cukup menjadi pembeda.



Gambar 4. Panjang teks pada seluruh sampel dan menurut kelas target

Sumber: Notebook, Cell 8 (P2).

Analisis perusahaan memperlihatkan perubahan komposisi target yang besar. Pada beberapa perusahaan, Closed with explanation sangat dominan, sedangkan pada perusahaan lain respons non-monetary relief dan status In progress lebih besar. Selisih proporsi antarperusahaan mencapai 64,7 poin persentase pada Closed with explanation, 37,9 pada In progress, dan 37,2 pada Closed with non-monetary relief. Temuan ini menjadi alasan empiris untuk mempertahankan Company sebagai masukan model.



Gambar 5. Proporsi kelas target untuk sepuluh perusahaan dengan volume tertinggi

Sumber: Notebook, Cell 10 (P2).

3.6 Kapasitas Informasi Fitur

Sebelum membangun model akhir, notebook menguji tabel-lookup eksploratif. Prinsipnya adalah menentukan label mayoritas untuk kombinasi fitur yang sama dalam data pelatihan dan menerapkannya pada sampel pengujian eksploratif. Uji ini bukan model final, tetapi membantu menilai seberapa informatif suatu kelompok fitur dan sejauh mana kombinasi baru muncul.

Tabel 7. Hasil tabel-lookup eksploratif menurut penambahan fitur

Kombinasi	Akurasi	F1-macro	Cakupan
Teks saja	0,5761	0,3670	0,9989
Teks + Company	0,7125	0,5484	0,9619
+ State	0,7061	0,4902	0,8908
+ Submitted via	0,7064	0,4851	0,8846
+ Tags	0,7054	0,4837	0,8723

Sumber: Notebook, Cell 9 (P2).

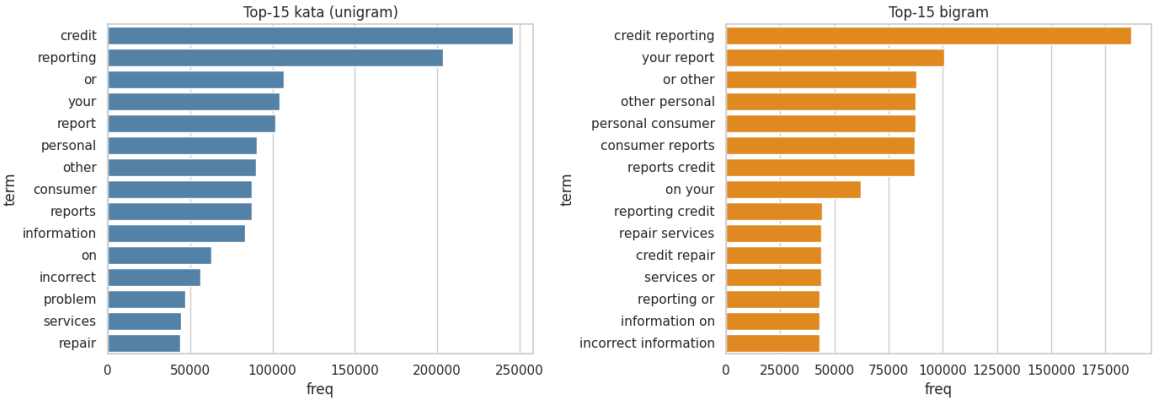
Peningkatan terbesar didapat saat Company ditambahkan: F1-macro dari 0,3670 menjadi 0,5484. Sebaliknya, penambahan kategori lainnya menciptakan kombinasi yang semakin jarang sehingga cakupan turun. Hasil ini tidak membuktikan bahwa fitur lain harus dibuang dari semua model; model dengan generalisasi yang lebih baik masih dapat memanfaatkannya. Namun hasil tersebut menunjukkan pentingnya membedakan nilai informasi tambahan dan masalah kelangkaan kombinasi.

3.7 Preprocessing Teks dan Rekayasa Fitur

Pembersihan teks dilakukan melalui *case folding*, penghapusan URL, penghapusan token sensor XXXX, penghapusan angka/tanda baca, dan normalisasi spasi. Stopword tidak dibuang karena teks relatif pendek dan kata negasi seperti not atau no dapat membawa makna. Stemming dan

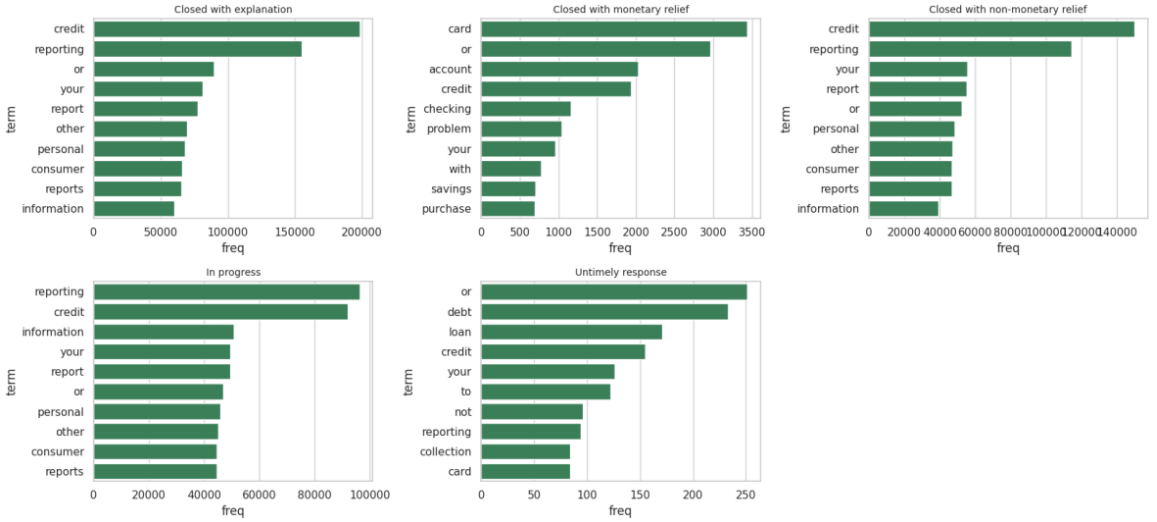
lemmatization tidak digunakan pada baseline, sehingga pengaruhnya belum dapat disimpulkan dari Milestone 1.

Sesudah cleaning pada sampel 300.000 baris, tidak ada baris yang menjadi teks kosong. Kolom kategorikal yang hilang diisi Unknown. TF-IDF menggunakan default unigram, `sublinear_tf=True`, `max_features=5.000`, dan `min_df=2` pada baseline. `OneHotEncoder` mengelompokkan kategori dengan frekuensi di bawah 20 ke kategori infrequent. Tahap transformasi dan model berada dalam pipeline yang sama.



Gambar 6. Kata dan bigram yang paling sering pada data latih

Sumber: Notebook, Cell 16 (P3).



Gambar 7. Kata dominan pada masing-masing kelas target

Sumber: Notebook, Cell 16 (P3).

Dominasi kata seperti credit reporting, your report, dan other personal sesuai dengan karakter berkas, yakni berisi label pengaduan terstruktur yang berulang. Kemunculan istilah khusus, misalnya card, charge, dan checking, dapat membantu membedakan subtema, tetapi bukan bukti bahwa kata tersebut menyebabkan kategori respons tertentu.

3.8 Pembagian Data dan Protokol Anti-Leakage

Data kerja sebanyak 300.000 observasi dipilih secara stratified agar proporsi lima kelas tetap mengikuti berkas awal. Setelah itu, data dibagi menjadi pengembangan 80% dan test 20%; bagian pengembangan dibagi lagi menjadi train 75% dan validation 25%. Secara keseluruhan proporsinya adalah train 60%, validation 20%, dan test 20%, masing-masing 180.000, 60.000, dan 60.000 observasi.

Tabel 8. Konfigurasi pemisahan data dan pelatihan

Parameter	Nilai	Tujuan
`RANDOM_STATE`	42	Eksperimen dapat diulang
`SAMPLE_N`	300.000	Ukuran data kerja
TRAIN / VALIDATION / TEST	180.000 / 60.000 / 60.000	Seleksi dan evaluasi terpisah
`CV_SAMPLE_N`	60.000	Validasi silang kandidat
`TUNE_SAMPLE_N`	60.000	Tuning dan seleksi fitur
`CV_FOLDS`	5	Stratified 5-Fold
`N_ITER_TUNE`	12	Kombinasi randomized search
`MAX_FEATURES`	5.000	Batas dasar TF-IDF

Sumber: Notebook, Cell 2 (konfigurasi) dan Cell 13 (P3).

Teks dibersihkan menggunakan operasi *stateless*, yaitu transformasi deterministik per observasi tanpa mempelajari statistik dari data. Sebaliknya, kosakata TF-IDF serta kategori yang diketahui encoder dipelajari dari bagian latih saja melalui `Pipeline`. Pada *cross-validation*, setiap *fold* mempelajari ulang transformasi dari partisi pelatihannya. Data uji dipertahankan tertutup hingga satu kali evaluasi akhir setelah pemilihan model.

3.9 Rancangan Model dan Validasi

Tabel 9. Baseline dan kandidat yang diuji

Kode	Fitur	Algoritma	Peran
Dummy	—	Kelas mayoritas	Batas bawah
Baseline	TF-IDF teks	Logistic Regression	Acuan pembanding
K1	TF-IDF + one-hot	Logistic Regression	Uji kontribusi fitur
K2	TF-IDF + one-hot	Multinomial Naive Bayes	Pembanding probabilistik
K3	TF-IDF + one-hot	Linear SVM (C=0,5)	Model linear alternatif
K4	TF-IDF + one-hot	Random Forest (50 pohon)	Hubungan non-linear
E1	TF-IDF + one-hot	Voting hard LR+NB+SVM	Ensemble voting kelas
E2	TF-IDF + one-hot	Voting soft LR+NB	Ensemble probabilitas

Sumber: Notebook, Cell 15 dan Cell 18 (P3–P4).

Skema A menggunakan Stratified 5-Fold pada sampel data pengembangan dan bertujuan memperkirakan performa ketika jenis masalah lama tetap muncul dalam pengaduan baru. Skema B menggunakan `GroupKFold` dengan grup berupa teks masalah; observasi dari kategori teks yang sama tidak berada bersamaan pada train dan validation dalam *fold* yang sama. Skema B lebih sulit karena menguji generalisasi ke kombinasi masalah yang sebelumnya belum pernah terlihat.

Metrik utama ditetapkan F1-macro, dilengkapi accuracy, balanced accuracy, precision/recall macro, MCC, dan PR-AUC macro. Untuk eksplorasi tanpa label digunakan silhouette, ARI, serta NMI. Uji paired t-test pada *fold* diperlakukan sebagai bukti indikatif karena sampel pelatihan antar-*fold* tidak sepenuhnya independen.

4. HASIL DAN PEMBAHASAN

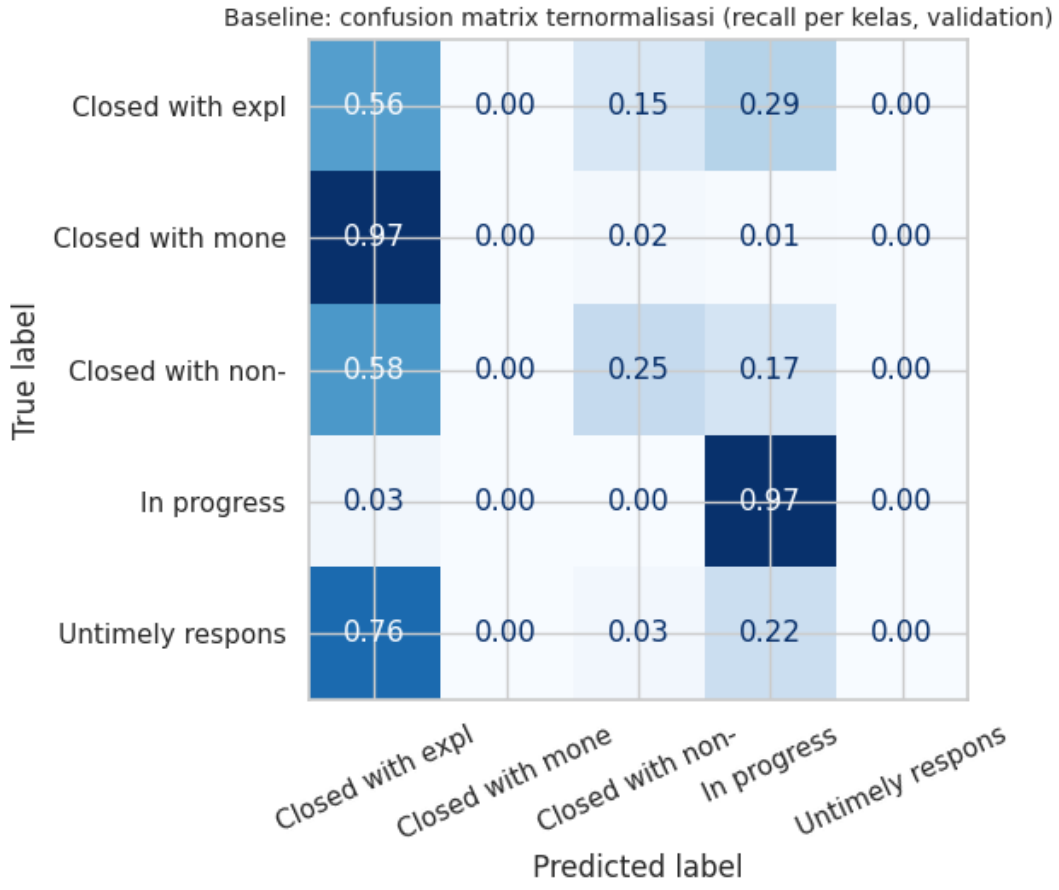
4.1 Kinerja Dummy dan Baseline

Model Dummy selalu memprediksi Closed with explanation dan memperoleh akurasi 0,4592 namun F1-macro 0,1259. Logistic Regression dengan TF-IDF teks saja meningkatkan akurasi menjadi 0,5698 dan F1-macro 0,3242 pada data validasi. Kenaikan ini menunjukkan bahwa representasi masalah memiliki informasi prediktif, tetapi performanya masih terbatas untuk menangani semua kelas.

Tabel 10. Hasil model tunggal pada validation set 60.000 baris

Model	Accuracy	Bal. Acc	F1-macro	MCC	PR-AUC
Dummy	0,4592	0,2000	0,1259	0,0000	0,2000
Baseline: LR teks	0,5698	0,3539	0,3242	0,3557	0,4031
K1: LR + struktur	0,7096	0,4611	0,4866	0,5540	0,5567
K2: NB + struktur	0,5931	0,6339	0,4308	0,4032	0,4665
K3: SVM + struktur	0,7102	0,4544	0,4762	0,5550	0,5506
K4: RF + struktur	0,7137	0,4457	0,4480	0,5692	0,5364

Sumber: Notebook, Cell 15 dan Cell 18 (P3–P4).



Gambar 8. Confusion matrix baseline pada data validasi (normalisasi recall)

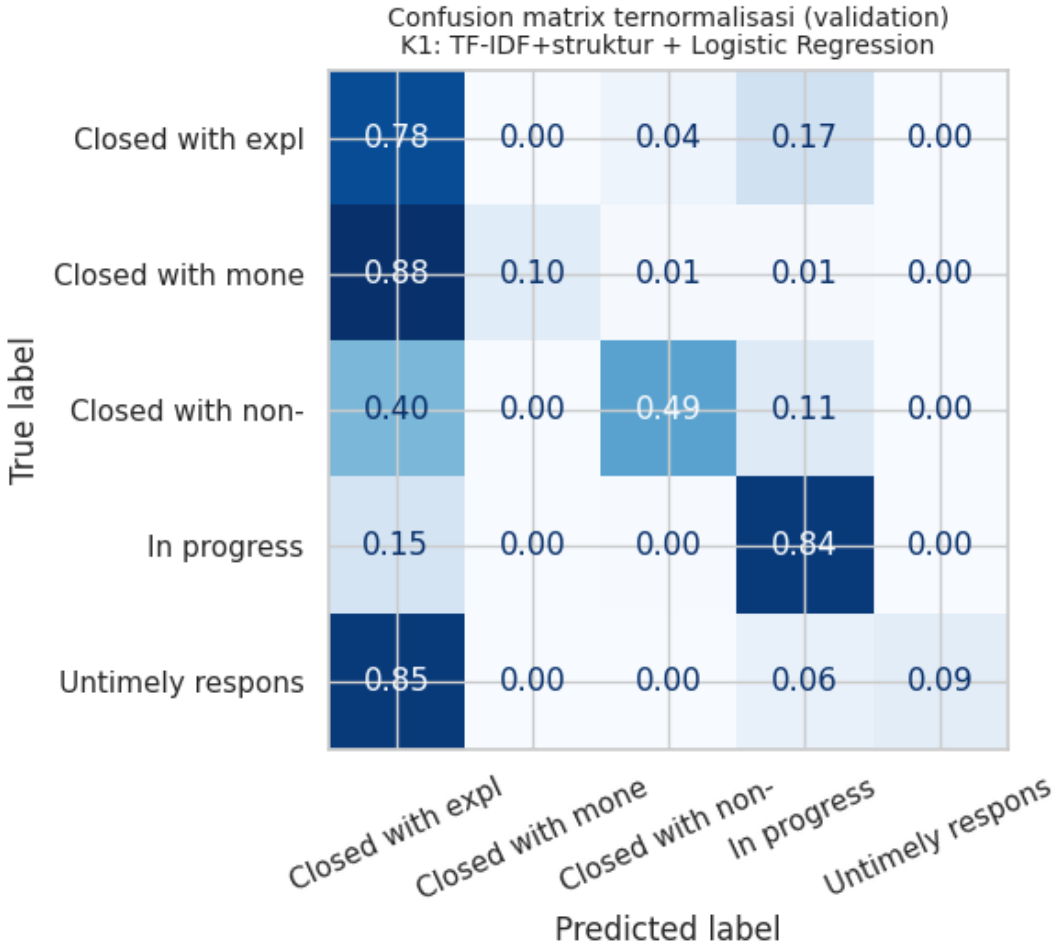
Sumber: Notebook, Cell 15 (P3).

Confusion matrix baseline memperlihatkan bahwa model lebih baik mengidentifikasi kelas dominan daripada kelas kecil. Dalam laporan sebelumnya, sekitar 97% observasi Closed with monetary relief salah diprediksi sebagai Closed with explanation, sedangkan In progress memiliki recall sekitar 0,97. Artinya, skor global tidak menggambarkan ketepatan yang merata antar kelas. F1-macro menjadi landasan pemilihan model dibanding hanya melihat akurasi.

4.2 Kontribusi Fitur Terstruktur dan Perbandingan Algoritma

K1 menggunakan Logistic Regression yang sama dengan baseline tetapi menambahkan fitur kategorikal. F1-macro meningkat dari 0,3242 menjadi 0,4866 pada validasi (selisih +0,1624), disertai kenaikan MCC dari 0,3557 menjadi 0,5540. Dengan mengganti satu komponen utama, yakni kelompok fitur, percobaan ini menunjukkan bahwa penambahan konteks perusahaan dan atribut pengaduan berperan besar pada peningkatan kinerja.

SVM dan Random Forest memiliki akurasi hampir setara K1, tetapi F1-macro masing-masing 0,4762 dan 0,4480. Random Forest memperoleh akurasi tertinggi 0,7137, sedangkan Naive Bayes memperoleh balanced accuracy tertinggi 0,6339 dengan accuracy 0,5931. Perbedaan urutan metrik mencerminkan *trade-off*: model yang lebih agresif mengenali kelas minoritas belum tentu presisinya setinggi model yang memilih kelas besar.



Gambar 9. Confusion matrix kandidat K1 pada data validasi

Sumber: Notebook, Cell 19 (P4).

Pada kandidat K1, recall dua kelas kecil masih terbatas, sekitar 0,10 untuk Closed with monetary relief dan 0,09 untuk Untimely response. Ini menunjukkan bahwa penambahan fitur saja belum menyelesaikan ketidakseimbangan target, sehingga strategi bobot kelas diuji pada eksperimen lanjutan.

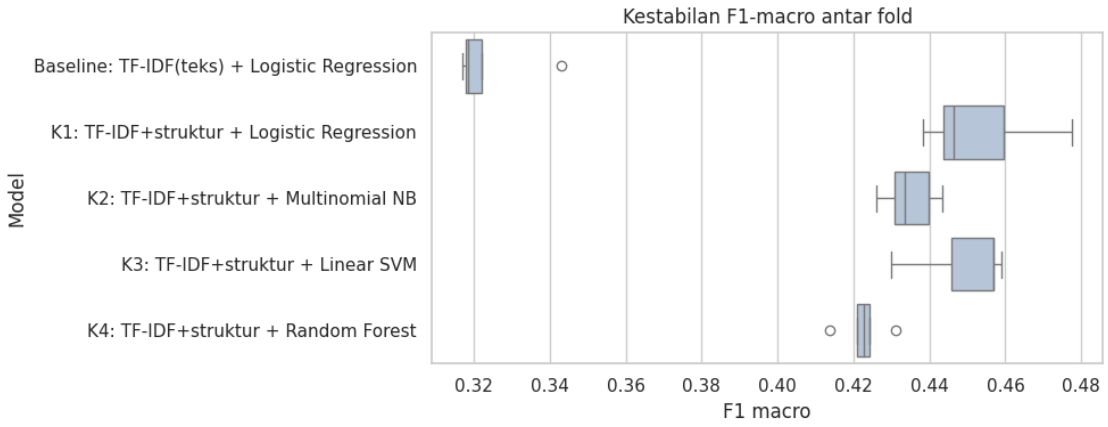
4.3 Kestabilan melalui Stratified Cross-Validation

Cross-validation dilakukan pada sampel 60.000 data pengembangan dengan lima *fold*. Masing-masing model dilatih ulang dan diuji pada partisi yang berbeda. Rerata F1-macro untuk baseline adalah 0,3237 ± 0,0110, sedangkan K1 mencapai 0,4531 ± 0,0158. Kandidat lain memperoleh K2 0,4347 ± 0,0069, K3 0,4497 ± 0,0121, dan K4 0,4225 ± 0,0063.

Tabel 11. Hasil F1-macro per fold dan rerata

Fold	Baseline	K1	K2	K3	K4
1	0,3186	0,4595	0,4309	0,4458	0,4241
2	0,3178	0,4435	0,4334	0,4299	0,4137
3	0,3220	0,4776	0,4261	0,4589	0,4209
4	0,3170	0,4384	0,4397	0,4568	0,4227
5	0,3431	0,4464	0,4433	0,4568	0,4310
Rerata	0,3237	0,4531	0,4347	0,4497	0,4225

Sumber: Notebook, Cell 21 (P5).



Gambar 10. Sebaran skor F1-macro antar fold kandidat model

Sumber: Notebook, Cell 21 (P5).

Simpangan baku antarfold relatif terbatas pada skema stratified, sehingga posisi baseline sebagai model paling rendah konsisten. Meski demikian, skor validasi silang K1 lebih rendah daripada skor pada validation set terpisah (0,4531 dibanding 0,4866). Salah satu kemungkinan yang dicatat dalam notebook ialah ukuran data pelatihan per *fold* dan jumlah sangat kecil pada kelas Untimely response dalam sampel validasi silang. Perbedaan ini tidak boleh langsung ditafsirkan sebagai bukti penurunan kualitas tanpa mengendalikan ukuran sampel.

4.4 Evaluasi Voting Ensemble

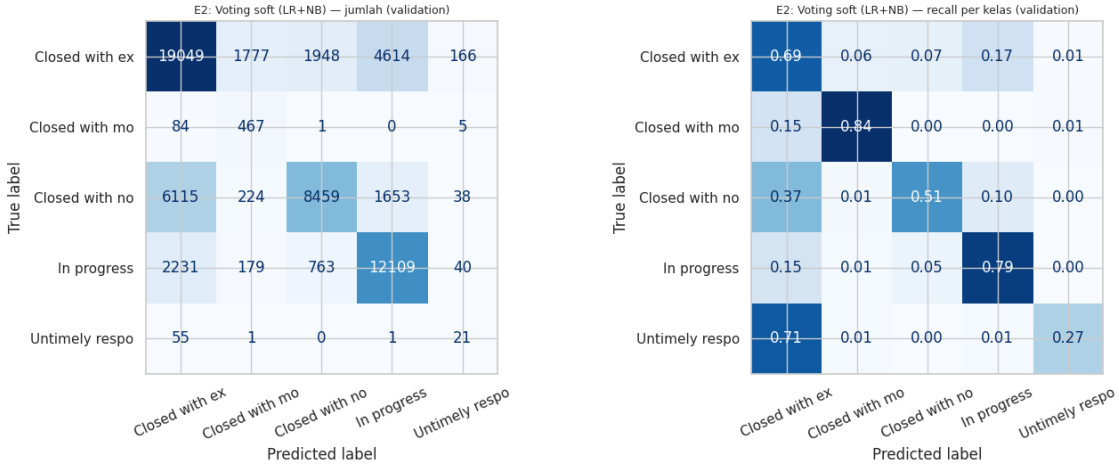
Kombinasi model dieksplorasi melalui voting hard (E1) dan voting soft (E2). Pada Stratified 5-Fold, E1 menghasilkan F1-macro 0,4617 ± 0,0119, sedangkan E2 mencapai 0,4954 ± 0,0196. Hasil E2 lebih tinggi 0,0423 dibanding model tunggal K1 pada konfigurasi *cross-validation* awal. Namun E2 belum dibandingkan secara setara dengan Logistic Regression berbobot kelas dan model hasil tuning, sehingga E2 tidak otomatis dipilih sebagai model akhir.

Tabel 12. Ringkasan model pada Stratified 5-Fold

Model	F1-macro CV	Selisih dari baseline
Baseline LR teks	0,3237 ± 0,0110	—
K1 LR + struktur	0,4531 ± 0,0158	+0,1294
K2 NB + struktur	0,4347 ± 0,0069	+0,1110

Model	F1-macro CV	Selisih dari baseline
K3 SVM + struktur	0,4497 ± 0,0121	+0,1259
K4 RF + struktur	0,4225 ± 0,0063	+0,0988
E1 voting hard	0,4617 ± 0,0119	+0,1380
E2 voting soft	0,4954 ± 0,0196	+0,1716

Sumber: Notebook, Cell 21–22 (P5).



Gambar 11. Confusion matrix E2 voting soft pada data validasi

Sumber: Notebook, Cell 24 (P5).

Hasil ensemble menunjukkan bahwa keputusan dari algoritma berbeda dapat saling melengkapi. Walaupun demikian, penyatuan prediksi tidak menjamin perbaikan semua kelas; confusion matrix perlu dibaca bersama dengan metrik macro. Penggunaan nilai p dari paired t-test pada *fold* merupakan pembanding awal saja dan bukan konfirmasi inferensi statistik yang sepenuhnya independen.

4.5 Strategi Penanganan Ketidakseimbangan Kelas

Eksperimen *class weighting* dilakukan khususnya pada Logistic Regression dengan fitur terstruktur. Tanpa bobot, model mencatat F1-macro 0,4531 dan recall Untimely response 0,0125. Bobot balanced meningkatkan recall kelas tersebut menjadi 0,5933 dan balanced accuracy menjadi 0,6993, tetapi menurunkan akurasi menjadi 0,6288 serta F1-macro menjadi 0,4591. Hal ini menunjukkan penekanan terlalu kuat pada kelas kecil dapat menghasilkan lebih banyak kesalahan pada kelas lain.

Tabel 13. Perbandingan strategi class weighting

Strategi	F1-macro	Bal. Acc	Accuracy	Recall Untimely
Tanpa bobot	0,4531	0,4417	0,7054	0,0125
Balanced	0,4591	0,6993	0,6288	0,5933
Sqrt-balanced	0,4994	0,5907	0,6856	0,2517

Sumber: Notebook, Cell 23 (P5). Baris strategi terpilih diberi warna.

Sqrt-balanced mencapai F1-macro tertinggi 0,4994 dengan akurasi 0,6856 dan recall Untimely response 0,2517. Strategi ini dipilih karena menyeimbangkan performa antar kelas menurut metrik utama. Namun keputusan tersebut adalah pilihan metrik akademik, bukan klaim bahwa semua kesalahan memiliki biaya operasional yang sama. Jika kegagalan mendeteksi Untimely response dianggap jauh lebih mahal, balanced penuh dapat dipertimbangkan dengan batasan precision yang jelas.

4.6 Ketahanan terhadap Jenis Masalah Baru

Pada `GroupKFold`, teks masalah dipakai sebagai grup sehingga satu kombinasi masalah tidak muncul sekaligus di partisi latih dan validasi. Skor turun tajam: baseline dari 0,3237 menjadi 0,1435, K1 dari 0,4531 menjadi 0,3202, dan K2 dari 0,4347 menjadi 0,2230. Simpangan baku K1 pada uji grup mencapai 0,0929, menandakan sensitivitas terhadap kumpulan jenis masalah yang dikeluarkan pada suatu *fold*.

Tabel 14. Perbandingan validasi stratified dan grouped

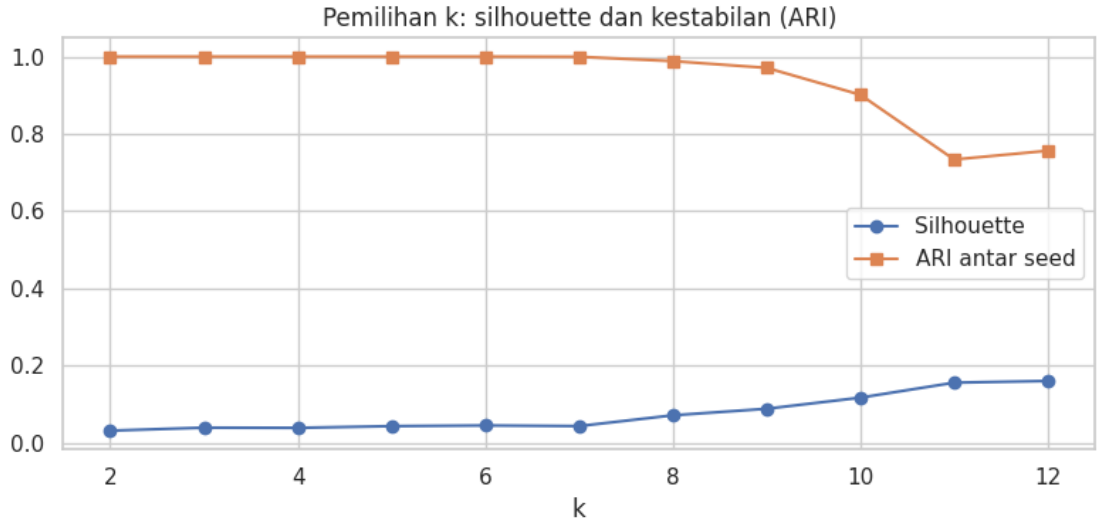
Model	F1 Stratified	F1 Group	Std Group	Selisih
Baseline LR teks	0,3237	0,1435	0,0300	−0,1802
K1 LR + struktur	0,4531	0,3202	0,0929	−0,1328
K2 NB + struktur	0,4347	0,2230	0,0697	−0,2117

Sumber: Notebook, Cell 21 dan Cell 24 (P5).

Skema A mewakili tugas prediksi ketika kategori pengaduan lama berulang pada data berikutnya. Skema B merupakan *stress test* bagi masalah yang benar-benar baru. Turunnya nilai F1 pada skema kedua menunjukkan generalisasi semantik masih terbatas. Hal ini selaras dengan penggunaan teks terstruktur pendek dan jumlah kombinasi teks unik yang kecil. Kedua skema menjawab pertanyaan evaluasi yang berbeda dan sebaiknya selalu dilaporkan berdampingan.

4.7 Eksplorasi Unsupervised: LSA, KMeans, dan NMF

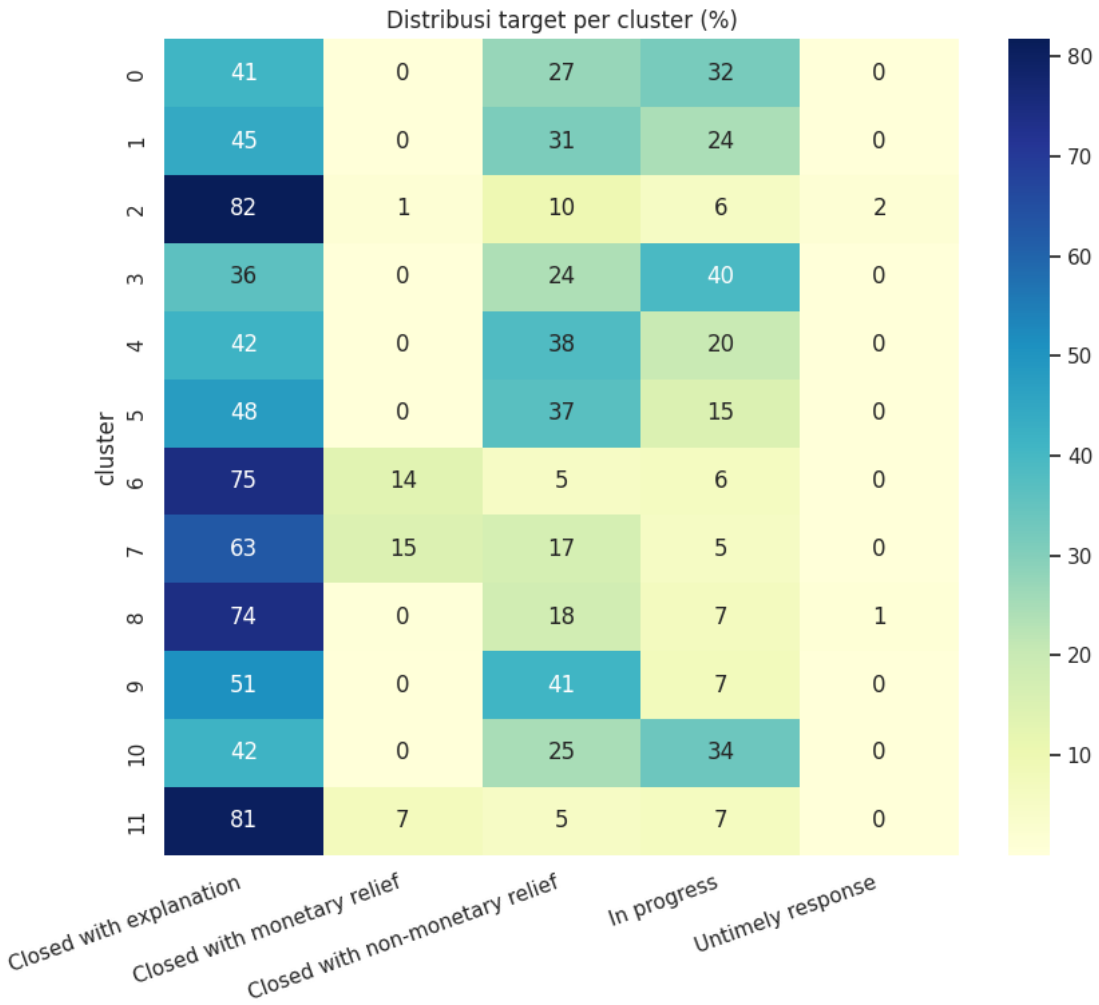
Notebook melakukan eksplorasi tanpa label terhadap jenis masalah unik pada data pengembangan, bukan terhadap seluruh pengaduan sebagai titik yang terpisah. Sebanyak 1.140 teks unik direpresentasikan menggunakan TF-IDF unigram dan bigram dengan 1.990 fitur, lalu direduksi menjadi 50 komponen LSA. Variansi yang dijelaskan berjumlah sekitar 59,02%. Pengelompokan KMeans menggunakan pembobotan jumlah pengaduan dan dibandingkan pada k = 2 hingga 12.



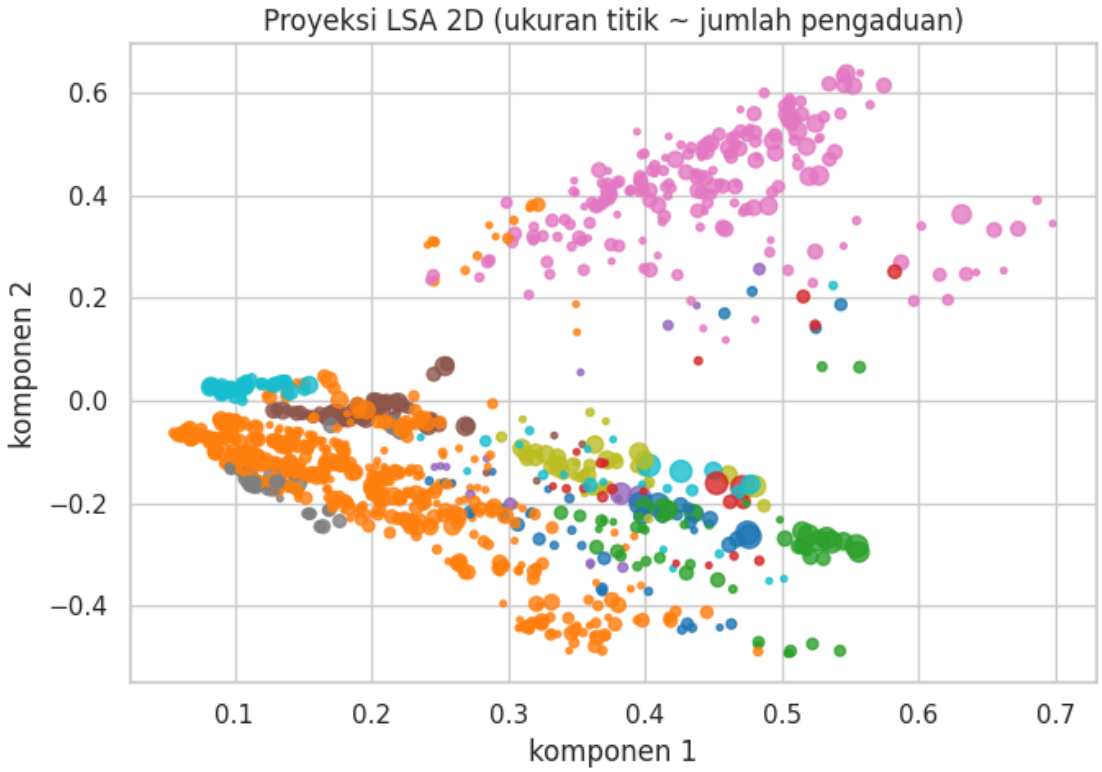
Gambar 12. Pemilihan jumlah klaster: silhouette dan kestabilan antar seed

Sumber: Notebook, Cell 26 (P6).

Nilai silhouette meningkat dari 0,0312 pada k=2 hingga 0,1599 pada k=12. Akan tetapi, ARI antar seed yang semula 1,0000 pada k hingga 6 turun menjadi 0,7334 pada k=11 dan 0,7561 pada k=12. k=12 merupakan nilai silhouette tertinggi hanya dalam rentang yang diuji, sekaligus berada di batas atas rentang; karena itu hasil tidak boleh dinyatakan sebagai jumlah klaster alami yang pasti.



Gambar 13. Komposisi kelas respons di tiap klaster hasil eksplorasi
Sumber: Notebook, Cell 27 (P6).



Gambar 14. Visualisasi LSA dua dimensi dari jenis masalah

Sumber: Notebook, Cell 27 (P6).

Klaster terutama menggambarkan tema produk dan isu, misalnya pelaporan kredit, penagihan utang, hipotek, kartu kredit, rekening, serta transfer uang. NMF dengan enam topik menghasilkan tema yang berdekatan. Namun NMI klaster dengan target hanya sekitar 0,0472, sehingga pengelompokan tema memiliki hubungan sangat kecil dengan kategori respons perusahaan. Hal ini menjelaskan mengapa identitas perusahaan dan atribut lain lebih membantu untuk tugas prediksi target daripada hanya memakai tema teks.

4.8 Seleksi Fitur Chi-Square

Seleksi fitur diuji dengan `SelectKBest` chi-square terhadap data tuning berukuran 60.000 baris. Dalam eksperimen 3-*fold* dengan 626 fitur, k=300 mencapai F1-macro 0,5026 dibandingkan 0,4949 tanpa membatasi fitur, dengan waktu komputasi 17,0 detik dibanding 19,5 detik. Selisih F1-macro relatif kecil dan belum cukup untuk disimpulkan sebagai perbaikan yang pasti karena berada dalam rentang variasi antar-*fold*.

Tabel 15. Seleksi fitur chi-square pada 3-fold

Jumlah fitur	F1-macro	Std	Bal. Acc	Waktu (s)
50	0,4959	0,0185	0,5787	10,7
100	0,4983	0,0130	0,5915	12,3
300	0,5026	0,0055	0,6033	17,0
Seluruh 626	0,4949	0,0134	0,5809	19,5

Sumber: Notebook, Cell 29 (P7). Baris k = 300 diberi warna.

Fitur bernilai chi-square tinggi terdiri dari kata seperti card, charge, checking, fees, incorrect, dan repair, serta kategori perusahaan besar termasuk Bank of America, Citibank, Equifax, Experian, TransUnion, dan Wells Fargo. Secara konseptual, nilai tinggi menunjukkan asosiasi fitur dengan target dalam sampel tersebut, bukan hubungan sebab-akibat.

4.9 Hyperparameter Tuning dan Model Sementara

`RandomizedSearchCV` menguji 12 kombinasi dengan 3-*fold* pada sampel tuning. Konfigurasi terbaik memiliki C sekitar 0,0635, `ngram_range=(1,2)`, `max_features=20.000`, `min_df=1`, persentil seleksi 100, dan bobot sqrt-balanced. Rerata F1-macro terbaik pada proses search adalah 0,5012 dan waktu search sekitar 267,5 detik. Empat konfigurasi peringkat teratas menggunakan sqrt-balanced, sehingga bobot kelas terbukti penting dalam ruang pencarian ini.

Pada validation set, model hasil tuning mencapai F1-macro 0,5215 dan MCC 0,5344. Logistic Regression berbobot sqrt-balanced tanpa tuning memiliki F1-macro hampir sama, yaitu 0,5215, dan MCC 0,5356. Kenaikan F1 hanya sekitar +0,0001, sehingga optimasi hiperparameter pada tahap ini lebih berperan memeriksa konfigurasi daripada memberikan peningkatan kualitas yang berarti.

Tabel 16. Ringkasan keputusan tahap penyempurnaan

Eksperimen	Temuan	Interpretasi
Penambahan fitur Company	Lookup F1 0,3670 → 0,5484	Informasi perusahaan penting
Stratified CV K1	F1 0,4531	Model tanpa bobot masih lemah pada minoritas
Voting soft E2	F1 0,4954	Peningkatan awal, belum setara bobot
LR sqrt-balanced	F1 0,4994	Kompromi F1 dan recall minoritas
Chi-square k=300	F1 0,5026	Efisiensi dimensi, keunggulan kecil
`RandomizedSearchCV`	F1 CV 0,5012	Tuning belum memberi kenaikan berarti

Sumber: Notebook, Cell 25 dan Cell 29–31 (P5, P7).

4.10 Analisis Kesalahan pada Data Validasi

Model hasil tuning menghasilkan 18.608 kesalahan dari 60.000 observasi validation set, atau sekitar 31,0%. Tingkat kesalahan paling tinggi dilaporkan pada Closed with non-monetary relief sebesar 0,483 dan Untimely response 0,449; diikuti Closed with explanation 0,299, Closed with monetary relief 0,293, dan In progress 0,144.

Dua pola kesalahan terbesar adalah Closed with non-monetary relief yang diprediksi Closed with explanation sebanyak 5.885 kasus, serta Closed with explanation yang diprediksi In progress sebanyak 4.840 kasus. Kedekatan representasi antar kasus membuat keputusan sulit, terutama ketika jenis masalah, perusahaan, dan kanal sama tetapi label berbeda.

Audit ambigu menunjukkan 13.302 baris dengan proporsi label mayoritas di kombinasi fitur yang sama kurang dari 60%. Tingkat kesalahan kelompok ini mencapai 0,491, dibanding 0,259 pada 46.698 baris yang lebih tidak ambigu. Sebanyak 86,32% baris validasi memiliki seluruh fitur identik dengan setidaknya satu baris pelatihan, sedangkan hanya 4,3% kombinasi tidak pernah dijumpai dalam train. Temuan tersebut memberikan batas informasi alami: tidak ada classifier deterministik yang dapat selalu membedakan dua target berbeda bila seluruh fitur yang tersedia sama.

Analisis perusahaan pada kelompok besar memperlihatkan perbedaan tingkat kesalahan, antara lain Citibank 0,601, Bank of America 0,546, Wells Fargo 0,440, Equifax 0,423, TransUnion 0,257, dan Experian 0,274. Angka ini mengindikasikan bahwa distribusi kelas dan pola atribut berbeda antarperusahaan; belum membuktikan kualitas layanan suatu perusahaan.

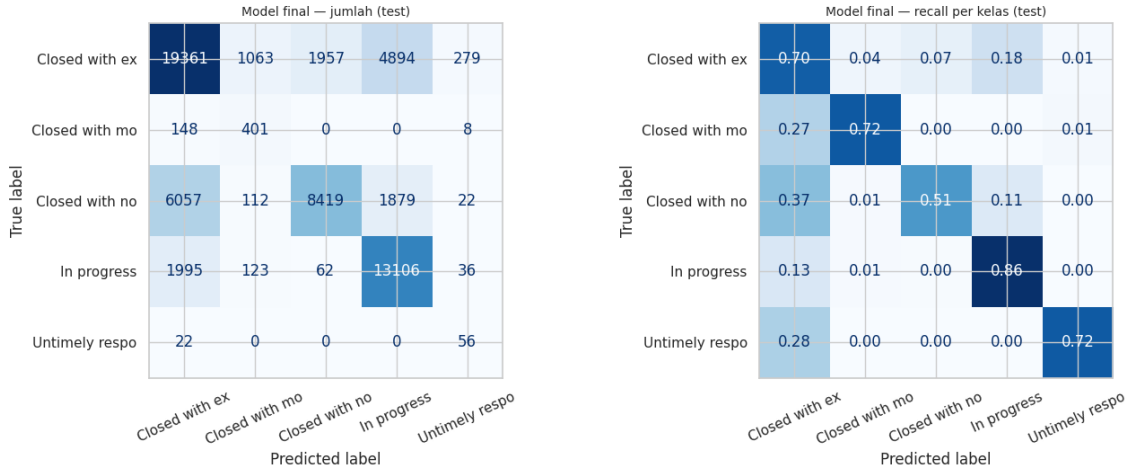
4.11 Evaluasi Akhir pada Test Set Terkunci

Setelah seluruh pemilihan dan pemeriksaan konfigurasi dilakukan pada data pengembangan, model terbaik sementara dibekukan dan dilatih ulang pada 240.000 baris train+validation. Data uji sebanyak 60.000 observasi yang sebelumnya tidak digunakan untuk menyeleksi konfigurasi kemudian dibuka satu kali. Model terpilih adalah Logistic Regression dengan bobot sqrt-balanced dan konfigurasi hasil tuning.

Tabel 17. Perbandingan model pada test set akhir

Model	Accuracy	Bal. Acc	Precision	F1-macro	MCC	PR-AUC
Dummy	0,4592	0,2000	0,0918	0,1259	0,0000	0,2000
Baseline LR teks	0,5690	0,3554	0,4455	0,3277	0,3534	0,4090
Model terbaik sementara	0,6891	0,7013	0,5087	0,5323	0,5328	0,5765

Sumber: Notebook, Cell 34 (UTS). Baris model terpilih diberi warna.



Gambar 15. Confusion matrix hasil akhir: frekuensi dan recall per kelas

Sumber: Notebook, Cell 34 (UTS).

Model terbaik sementara mencapai accuracy 0,6891, balanced accuracy 0,7013, precision macro 0,5087, F1-macro 0,5323, MCC 0,5328, dan PR-AUC macro 0,5765. F1-macro ini meningkat 0,2046 dibanding baseline uji 0,3277 dan 0,4064 dibanding Dummy 0,1259. Perbedaan dari F1-macro validation 0,5215 sebesar +0,0108 tidak menunjukkan penurunan tajam pada test set, tetapi belum membuktikan generalisasi pada data CFPB yang lebih representatif.

Tabel 18. Precision, recall, dan F1 per kelas pada test set

Kelas	Precision	Recall	F1	Support
Closed with explanation	0,70	0,70	0,70	27.554
Closed with monetary relief	0,24	0,72	0,36	557
Closed with non-monetary relief	0,81	0,51	0,63	16.489
In progress	0,66	0,86	0,74	15.322
Untimely response	0,14	0,72	0,23	78

Kelas	Precision	Recall	F1	Support
Macro average	0,51	0,70	0,53	60.000
Weighted average	0,71	0,69	0,69	60.000

Sumber: Notebook, Cell 34 (UTS).

Recall sekitar 0,72 pada dua kelas paling jarang menunjukkan keberhasilan menangkap lebih banyak pengaduan minoritas dibanding baseline. Namun precision masing-masing hanya 0,24 dan 0,14, sehingga banyak prediksi pada kelas tersebut adalah *false positive*. Kelas Untimely response hanya berisi 78 sampel uji, dengan sekitar 56 terprediksi benar; evaluasinya masih sensitif terhadap perubahan beberapa kasus. Karena itu, nilai per kelas perlu dilihat bersama ukuran support.

4.12 Evaluasi terhadap Tujuan Penelitian

Tabel 19. Pemeriksaan tujuan dan bukti capaian Milestone 1

Tujuan	Bukti	Status
Audit sumber dan kualitas data	1.048.575 baris; deteksi batas Excel dan narasi tidak ada	Tercapai dengan catatan
Mencegah *data leakage*	Kolom pasca-respons dibuang, TF-IDF di dalam `Pipeline`	Tercapai dalam desain
Membuat baseline dan kandidat	Dummy, LR, NB, SVM, RF, ensemble	Tercapai
Validasi dan stabilitas	Stratified CV serta `GroupKFold`	Tercapai, generalisasi terbatas
Memperbaiki minoritas	sqrt-balanced dan tuning awal	Tercapai sebagian
Model sementara pada test	F1-macro 0,5323 pada 60.000 data uji	Tercapai pada sampel tersedia

Sumber: Notebook, Cell 35 (UTS).

Secara keseluruhan, tujuan akademik Milestone 1 telah dipenuhi pada dataset dan protokol yang digunakan. Namun keberhasilan pengujian pada sampel yang tersedia tidak otomatis menghapus masalah data yang terpotong, perbedaan periode, maupun risiko target yang mencampurkan hasil final dan status proses. Kesimpulan dikaitkan dengan bukti pada notebook, bukan dengan klaim penerapan operasional yang belum diuji.

5. KETERBATASAN, REPRODUSIBILITAS, DAN RENCANA LANJUTAN

5.1 Keterbatasan Penelitian

Keterbatasan paling mendasar adalah indikasi pemotongan file pada batas Excel, sehingga distribusi tanggal dan kelas mungkin tidak mewakili keseluruhan arsip CFPB. Walaupun sampel kerja dipilih secara stratified, stratifikasi hanya mempertahankan proporsi label dari file yang diterima, bukan menyelesaikan bias file awal. Karena itu, hasil tidak boleh ditafsirkan sebagai performa pasti pada semua pengaduan CFPB.

Keterbatasan kedua adalah absennya narasi bebas. Penggabungan empat kolom menghasilkan teks yang sangat berulang, dengan banyak kasus berbeda berbagi representasi identik. Model lebih mendekati klasifikasi atas atribut kategori masalah daripada pemahaman bahasa alami yang kaya. Keterbatasan ketiga adalah keberadaan status In progress dan Untimely response dalam target, yang tidak sepenuhnya setara dengan kategori respons penyelesaian akhir.

Keterbatasan eksperimen lainnya meliputi sampel validasi silang 60.000 baris, perbandingan model kandidat awal yang tidak semuanya menggunakan *class weighting*, ruang tuning relatif

terbatas, serta penggunaan test set sekali pada tahap UTS. Nilai p dari uji antar-*fold* juga harus dipahami sebagai indikatif, bukan konfirmasi final. Keseluruhan batasan tersebut tidak membatalkan hasil, tetapi menentukan cakupan klaimnya.

5.2 Teknologi, Konfigurasi, dan Reproducibilitas

Tabel 20. Lingkungan dan komponen implementasi

Komponen	Penggunaan
Google Colab	Menjalankan notebook dan visualisasi
Python	Bahasa pemrograman
pandas 2.2.3	Membaca, membersihkan, serta mengaudit data
scikit-learn 1.6.1	`Pipeline`, vectorizer, classifier, CV, dan metrik
NumPy dan SciPy	Operasi numerik serta pengujian statistik
Matplotlib dan Seaborn	Histogram, heatmap, evaluasi visual
joblib	Menyimpan model hasil pemodelan
Random state	42 untuk hasil eksperimen yang konsisten

Sumber: Notebook, Cell 1 dan Cell 36.

Reproduksi eksperimen dilakukan dengan menyediakan file `complaints.csv` pada `DATA_PATH` yang dikonfigurasi dalam notebook, memastikan library terpasang, lalu menjalankan seluruh cell berurutan melalui Google Colab. File sumber data perlu cocok dengan berkas yang digunakan agar jumlah dan nilai evaluasi identik. Notebook disertai variabel konfigurasi seperti `SAMPLE_N`, `CV_SAMPLE_N`, `TUNE_SAMPLE_N`, dan `N_ITER_TUNE` untuk mengendalikan jumlah baris dan biaya komputasi.

Tautan repositori, dataset, dan notebook dicantumkan pada Bagian B (Tabel 24). Keluaran eksperimen meliputi tabel metrik, grafik, dan model hasil akhir. Penyajian tabel dalam laporan ini menggunakan nilai yang tercatat dalam notebook dan laporan sebelumnya; grafik mempertahankan keluaran eksperimen yang sudah ada, bukan hasil pelatihan baru.

5.3 Keterlacakan Temuan dan Eksperimen

Tabel 21. Keterkaitan pembahasan dengan bagian notebook

Materi laporan	Tahap notebook	Bukti
Sumber dan audit berkas	P2 Data understanding	Jumlah baris, tanggal, *missing values*
Kelas dan pola teks	P2 EDA	Distribusi kelas dan word count
Pembersihan dan split	P3 Preprocessing	Cleaning, 60/20/20, pipeline
Baseline dan kandidat	P3–P4	Confusion matrix dan skor validasi
Stabilitas dan ensemble	P5	Skor tiap *fold* dan model voting
Unsupervised	P6	LSA, KMeans, NMF, silhouette, NMI
Seleksi dan tuning	P7	Chi-square, randomized search, error analysis
Evaluasi akhir	UTS	Test metrics dan classification report

Sumber: Struktur notebook (P2–UTS).

Prinsip utama keterlacakan adalah membedakan hasil eksperimen yang benar-benar dilakukan dengan usulan perbaikan. Misalnya penggunaan kolom narasi, pengunduhan ulang dataset resmi, dan *holdout* baru belum diklaim sebagai hasil yang sudah tercapai. Selain itu, selisih skor terhadap baseline disebutkan bersama jenis partisinya agar nilai validasi tidak tercampur dengan hasil data uji.

5.4 Rencana Pengembangan Menuju UAS

Prioritas pertama adalah memperbaiki kualitas data sumber dengan mengunduh ulang CSV resmi dari CFPB secara langsung melalui pandas, tanpa menyimpan ulang melalui Excel. Alternatifnya adalah mengunduh file berdasarkan tahun atau produk, lalu menggabungkannya secara terprogram. Setelah itu audit kualitas data, distribusi tanggal, EDA, dan baseline harus diulang agar hasil baru dapat dibandingkan secara benar.

Prioritas kedua adalah memanfaatkan Consumer complaint narrative apabila tersedia, setelah memeriksa kelengkapan dan persyaratan penggunaannya. Jika model masih harus memakai fitur saat pengaduan masuk, ketersediaan narasi perlu dipastikan pada kondisi prediksi sebenarnya. Perubahan target, misalnya memfokuskan pada kategori penyelesaian Closed, akan dikonsultasikan sesuai ruang lingkup proyek.

Prioritas ketiga adalah menyiapkan strategi *holdout* baru, idealnya berbasis waktu atau file baru setelah perbaikan data, karena test set lama telah dibuka pada UTS. Seluruh model kandidat akan diuji dengan konfigurasi bobot kelas yang sebanding dan pencarian hiperparameter yang lebih luas. Fokus tambahan ialah kalibrasi probabilitas, analisis *false positive* dan *false negative* pada kelas langka, serta evaluasi kinerja menurut periode dan perusahaan.

Tabel 22. Agenda prioritas pasca-UTS

Prioritas	Pekerjaan	Indikator hasil
1	Unduh ulang berkas CFPB dan audit representativitas	Tidak lagi terpotong pada batas Excel
2	Periksa ketersediaan narrative dan batasan label	Desain fitur serta target terdefinisi jelas
3	Buat test/*holdout* baru	Evaluasi independen untuk UAS
4	Samakan perlakuan *class weighting* semua model	Perbandingan kandidat lebih adil
5	Perluas tuning dan uji kalibrasi	Analisis precision-recall kelas kecil
6	Perbarui notebook, README, dan laporan	Hasil dapat direproduksi dan diaudit

Sumber: Notebook, bagian 13 (Keterbatasan dan Langkah Lanjut).

6. KESIMPULAN DAN SARAN

6.1 Kesimpulan

Penelitian berhasil merumuskan prediksi Company response to consumer sebagai masalah klasifikasi multikelas menggunakan classical machine learning. Audit menunjukkan bahwa file terdiri atas 1.048.575 baris dan 15 kolom, dua target kosong dikeluarkan, distribusi lima kelas sangat tidak seimbang, dan dua kolom pasca-respons perlu dikeluarkan untuk mencegah *data leakage*. Tidak tersedianya kolom narasi dan indikasi pemotongan pada batas Excel membatasi lingkup generalisasi.

Penambahan atribut terstruktur terutama Company memberi peningkatan lebih besar daripada mengganti classifier saja. Pada Stratified 5-Fold, F1-macro Logistic Regression meningkat dari

0,3237 pada baseline teks menjadi 0,4531 setelah penambahan fitur. Voting soft mencapai 0,4954, sedangkan pembobotan sqrt-balanced pada LR menghasilkan 0,4994. Penyetelan hiperparameter berikutnya memberi perbedaan sangat kecil terhadap LR berbobot tanpa tuning dalam data validasi.

Model terbaik sementara mencapai F1-macro 0,5323, balanced accuracy 0,7013, dan accuracy 0,6891 pada 60.000 data uji, dibanding F1-macro 0,3277 pada baseline. Meskipun recall kelas langka meningkat, precision pada kelas tersebut masih rendah. Pada `GroupKFold`, performa semua kandidat turun, sehingga kemampuan menghadapi jenis masalah yang belum terlihat tetap menjadi tantangan utama.

6.2 Saran

Pengembangan selanjutnya perlu memprioritaskan perbaikan representativitas data, pemanfaatan narasi bila tersedia, dan desain *holdout* baru. Perbandingan antaralgoritma sebaiknya distandarkan pada perlakuan fitur dan *class weighting* yang sama. Selain memperbesar cakupan tuning, evaluasi perlu memperhatikan precision-recall per kelas, khususnya kelas dengan support kecil, serta menghindari klaim kausalitas dari hubungan perusahaan dan respons.

DAFTAR PUSTAKA

[1] Consumer Financial Protection Bureau, “Consumer Complaint Database,” https://www.consumerfinance.gov/data-research/consumer-complaints/ (diakses Nov. 2026).

[2] G. Salton dan C. Buckley, “Term-weighting approaches in automatic text retrieval,” Information Processing & Management, vol. 24, no. 5, hlm. 513–523, 1988.

[3] T. Joachims, “Text categorization with support vector machines: Learning with many relevant features,” dalam Machine Learning: ECML-98, Springer, 1998, hlm. 137–142.

[4] L. Breiman, “Random forests,” Machine Learning, vol. 45, no. 1, hlm. 5–32, 2001.

[5] M. Sokolova dan G. Lapalme, “A systematic analysis of performance measures for classification tasks,” Information Processing & Management, vol. 45, no. 4, hlm. 427–437, 2009.

[6] D. Chicco dan G. Jurman, “The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation,” BMC Genomics, vol. 21, art. 6, 2020.

[7] S. Kaufman, S. Rosset, C. Perlich, dan O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” ACM Transactions on Knowledge Discovery from Data, vol. 6, no. 4, art. 15, 2012.

[8] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, dan R. Harshman, “Indexing by latent semantic analysis,” Journal of the American Society for Information Science, vol. 41, no. 6, hlm. 391–407, 1990.

[9] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” Journal of Computational and Applied Mathematics, vol. 20, hlm. 53–65, 1987.

[10] F. Pedregosa dkk., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, hlm. 2825–2830, 2011.

LAMPIRAN: KONFIGURASI NOTEBOOK

A. Variabel Utama Notebook

Tabel 23. Variabel utama pada konfigurasi notebook

Variabel	Nilai
DATA_PATH	/content/drive/MyDrive/Dataset/complaints.csv
TARGET_COL	Company response to consumer
TEXT_COLS	Product; Sub-product; Issue; Sub-issue
CAT_COLS	Company; State; Submitted via; Tags
LEAKY_COLS	Timely response?; Company public response
MIN_CLASS_COUNT	50
SAMPLE_N	300000
CV_SAMPLE_N	60000
TUNE_SAMPLE_N	60000
N_ITER_TUNE	12
TEST_SIZE	0.20
VAL_SIZE	0.25
MAX_FEATURES	5000

Sumber: Notebook, Cell 2 (konfigurasi).

Bagian B. Tautan

Seluruh tautan berikut harus dapat dibuka tanpa meminta akses.

Tabel 24. Daftar tautan proyek

No	Tautan	URL / keterangan
1	Source code (GitHub)	https://github.com/Tcerz/ML-UTS_A12Keluhan-Pelanggan.git
2	Notebook eksperimen (Colab/Drive)	https://colab.research.google.com/drive/1b_MgtxZP_ucVyCVzXMG8B01P8WVU-pnn?usp=sharing
3	Dataset sumber (CFPB)	https://www.consumerfinance.gov/data-research/consumer-complaints/

Sumber: Repositori dan berkas proyek kelompok A12.