Prediksi Respons Perusahaan terhadap Pengaduan Konsumen CFPB Menggunakan TF-IDF dan Classical Machine Learning

Fauzan Ramadhan Harahap[1], Eka Satria[2], Mhd. Hatami[3]

[1,2,3]Informatika, Teknik Informatika, Universitas Mikroskil, Medan
Kelompok A12| NIM: 231110937, 231111582, 231111710
e-mail: fauzan.ramadhan@students.mikroskil.ac.id, eka.satria@students.mikroskil.ac.id, mhd.hatami@students.mikroskil.ac.id

Laporan Milestone 1 (UTS) | Mata Kuliah Pembelajaran Mesin | Proyek Text Mining

Abstrak

Pengaduan konsumen atas laporan kredit yang diterima *Consumer Financial Protection Bureau* (CFPB) berjumlah besar sehingga penanganannya perlu dibantu otomatisasi. Penelitian ini merumuskan prediksi kategori tanggapan perusahaan (*Company response to consumer*) sebagai klasifikasi multikelas dengan lima kelas yang sangat tidak seimbang (rasio 350,2). Data terdiri atas 1.048.575 pengaduan; sampel *stratified* 300.000 baris dibagi 60/20/20 untuk latih, validasi, dan uji. Kolom pasca-respons dikeluarkan untuk mencegah *data leakage*. Karena kolom narasi tidak tersedia, teks dibentuk dari Product, Sub-product, Issue, dan Sub-issue, direpresentasikan dengan TF-IDF, lalu digabung dengan fitur kategorikal *one-hot*. Baseline TF-IDF dan *Logistic Regression* dibandingkan dengan *Multinomial Naive Bayes*, *Linear SVM*, *Random Forest*, dan *voting ensemble* melalui *Stratified 5-Fold* dan *GroupKFold*. Fitur terstruktur menaikkan F1-macro validasi silang dari 0,3237 menjadi 0,4531, dan pembobotan kelas sqrt-balanced menaikkannya menjadi 0,4994. Model terbaik sementara memperoleh F1-macro 0,5323 pada data uji, dibanding 0,3277 pada baseline. Skor dibatasi oleh data: tidak ada kolom narasi, berkas terpotong pada batas baris Excel, dan fitur identik dapat berlabel berbeda. Hasil ini menjadi dasar pengembangan menuju UAS.

Kata kunci: klasifikasi teks; TF-IDF; *Logistic Regression*; ketidakseimbangan kelas; pengaduan konsumen

Abstract

Consumer complaints about credit reporting received by the Consumer Financial Protection Bureau (CFPB) are numerous, so their handling needs automation support. This study formulates the prediction of the company response category (Company response to consumer) as a multiclass classification task with five imbalanced classes (imbalance ratio 350.2). The data contain 1,048,575 complaints; a 300,000-row stratified sample is split 60/20/20 into training, validation, and test sets. Post-response columns are excluded to prevent data leakage. Because the narrative column is unavailable, the text is built from Product, Sub-product, Issue, and Sub-issue, represented with TF-IDF, and combined with one-hot categorical features. A TF-IDF and Logistic Regression baseline is compared with Multinomial Naive Bayes, Linear SVM, Random Forest, and voting ensembles using Stratified 5-Fold and GroupKFold validation. Structured features raise the cross-validated macro F1 from 0.3237 to 0.4531, and sqrt-balanced class weighting raises it to 0.4994. The current best model obtains a macro F1 of 0.5323 on the test set, against 0.3277 for the baseline. Performance is bounded by the data: there is no narrative column, the file is truncated at the Excel row limit, and identical features can carry different labels. These results form the basis for further development toward the final project.

***Keywords**: text classification; TF-IDF; Logistic Regression; class imbalance; consumer complaints**

1. PENDAHULUAN

1.1 Latar Belakang

Consumer Financial Protection Bureau (CFPB) menerima pengaduan konsumen terhadap lembaga keuangan, dan pengaduan beserta tanggapan perusahaan dipublikasikan dalam *Consumer Complaint Database* [1]. Pada data yang dianalisis, pengaduan terbanyak ditujukan kepada tiga biro kredit (TransUnion, Experian, dan Equifax) dengan masalah seperti investigasi yang berlangsung lebih

dari 30 hari atau informasi yang tidak benar pada laporan kredit. Membaca dan mengklasifikasikan pengaduan semacam itu secara manual lambat dan cenderung tidak konsisten. Model klasifikasi dapat membantu memprioritaskan pengaduan dan memperkirakan bagaimana pengaduan akan diselesaikan.

Hubungan antara jenis pengaduan, perusahaan, dan hasil penyelesaian sulit ditulis sebagai aturan *if-else* sederhana karena kombinasi fiturnya banyak dan hasilnya bersifat probabilistik. Pendekatan *machine learning* mempelajari pola tersebut dari data historis.

1.2 Rumusan Masalah

Bagaimana memprediksi kategori tanggapan perusahaan kepada konsumen (*Company response to consumer*) dari informasi yang sudah diketahui saat pengaduan masuk, yaitu teks jenis masalah (Product, Sub-product, Issue, Sub-issue) dan atribut kategorikal (Company, State, Submitted via, Tags), dengan *classical machine learning* berbasis TF-IDF? Masalah ini berjenis klasifikasi teks multikelas dengan lima kelas yang tidak seimbang. Targetnya adalah kolom *Company response to consumer*.

1.3 Tujuan dan Kontribusi

Tujuan Milestone 1 adalah (1) merumuskan masalah dan memeriksa sumber, struktur, serta kualitas dataset; (2) membangun baseline dan model kandidat awal; (3) merancang evaluasi yang mencegah *data leakage* dan menguji kestabilan hasil; serta (4) menjelaskan batas performa yang dapat dicapai dari informasi yang tersedia. Kontribusi laporan ini adalah audit kolom yang berpotensi bocor, audit pemotongan berkas data, perbandingan beberapa strategi penanganan ketidakseimbangan kelas, dan uji ketahanan model pada jenis masalah yang belum pernah dilihat.

1.4 Batasan

Penelitian ini dibatasi pada *classical machine learning* sesuai ruang lingkup mata kuliah. Dataset dan masalah tidak diganti setelah melihat hasil awal. Tuning menyeluruh dan pemilihan model final merupakan tahap lanjutan, sehingga model pada laporan ini disebut model terbaik sementara.

2. TINJAUAN PUSTAKA

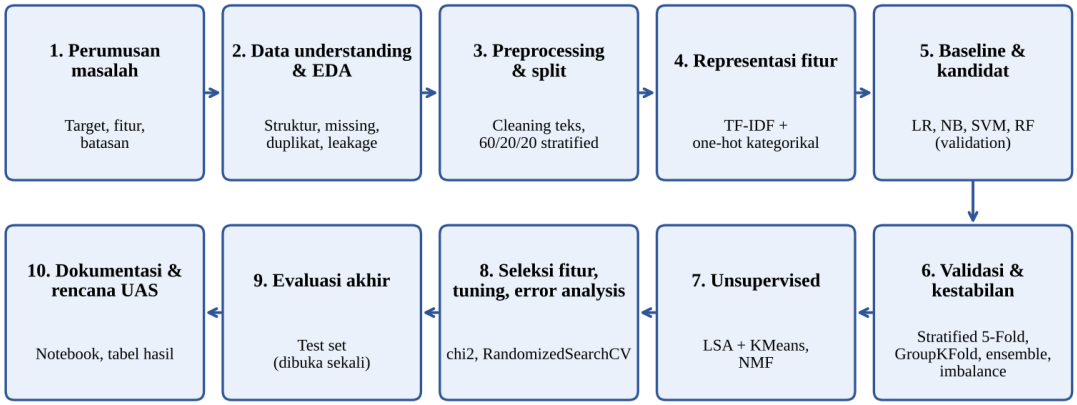
Representasi teks pada penelitian ini memakai pembobotan TF-IDF, yang memberi bobot tinggi pada istilah yang sering muncul di suatu dokumen tetapi jarang di dokumen lain [2]. Representasi ini lazim dipasangkan dengan pengklasifikasi linear. *Support Vector Machine* linear dikenal kuat untuk data teks berdimensi tinggi [3], sedangkan *Random Forest* menguji apakah hubungan non-linear membantu [4]. *Logistic Regression* dan *Multinomial Naive Bayes* dipilih sebagai model yang sederhana, cepat, dan mudah diinterpretasikan.

Pada data yang kelasnya sangat tidak seimbang, akurasi dapat menyesatkan. Karena itu metrik yang memperhatikan semua kelas, yaitu F1-macro, *balanced accuracy*, dan *Matthews Correlation Coefficient* (MCC), digunakan bersama akurasi [5], [6]. *Data leakage*, yaitu penggunaan informasi yang tidak tersedia saat prediksi, membuat skor tampak baik tetapi tidak valid [7], sehingga penelitian ini mengaudit kolom pasca-respons dan memfit TF-IDF hanya pada data latih.

Untuk eksplorasi tanpa label, *Latent Semantic Analysis* (LSA) mereduksi dimensi matriks TF-IDF melalui dekomposisi nilai singular [8], dan kualitas klaster diukur dengan koefisien *silhouette* [9]. Seluruh eksperimen dijalankan dengan pustaka *scikit-learn* [10]. Dibanding penggunaan umum basis data CFPB, penelitian ini menekankan audit data (kebocoran, pemotongan berkas, duplikasi teks) dan uji ketahanan validasi sebelum menafsirkan skor model.

3. METODE PENELITIAN

Tahapan penelitian mengikuti alur Pertemuan 1 sampai UTS dan ditunjukkan pada Gambar 1. Seluruh tahap dijalankan dalam satu *notebook* Google Colab sehingga angka pada laporan dapat ditelusuri ke keluaran kode.



Gambar 1. Tahapan penelitian

3.1 Dataset dan Pemahaman Data

Dataset adalah *CFPB Consumer Complaint Database* [1]. Satu baris mewakili satu pengaduan konsumen terhadap satu perusahaan (*Complaint ID*). Berkas yang digunakan berisi 1.048.575 baris dan 15 kolom, tanpa baris duplikat penuh maupun *Complaint ID* ganda, dan tanpa kolom konstan. Dua baris tanpa target dibuang sehingga tersisa 1.048.573 baris. Tabel 1 merangkum peran tiap kolom, nilai hilang, dan kekuatan asosiasi (Cramér's V terkoreksi bias) terhadap target. Kolom *Date received*, *ZIP code*, *Date sent to company*, dan *Complaint ID* tidak dipakai sebagai fitur.

Tabel 1. Peran kolom, nilai hilang, dan asosiasi terhadap target

Kolom	Peran	Hilang (%)	Cramér's V
Product	Teks	0,00	0,3916
Sub-product	Teks	0,00 (21 baris)	0,2282
Issue	Teks	0,00	0,2959
Sub-issue	Teks	2,37	0,2671
Company	Kategorikal (1.611 kategori)	0,00	0,3682
State	Kategorikal	0,19	0,0600
Submitted via	Kategorikal	0,00	0,0730
Tags	Kategorikal	95,17	0,0880
Timely response?	Dikeluarkan (pasca-respons)	0,00	0,6626
Company public response	Dikeluarkan (pasca-respons)	56,86	0,2730
Company response to consumer	Target	0,00 (2 baris)	–

Dua masalah kualitas data menentukan cara hasil ditafsirkan. **Pertama**, jumlah baris sama dengan batas baris Excel (1.048.575), yang mengindikasikan berkas terpotong akibat disimpan ulang melalui Excel. Tanggal pengaduan berkisar dari 2014-04-03 sampai 2026-09-21 dan tidak berurutan; 564.644 baris berasal dari 2023 dan 483.467 baris dari 2026, sedangkan tahun lain hanya memiliki 1 sampai 239 baris (Gambar 2). Sampel ini karenanya bukan sampel acak dari populasi penuh CFPB. **Kedua**, kolom narasi pengaduan tidak tersedia, sehingga teks hanya berupa gabungan empat kolom jenis masalah. Akibatnya hanya terdapat 1.483 teks unik dari 1.048.573 baris (duplikasi 99,9%). Duplikasi ini wajar karena banyak pengaduan memiliki jenis masalah yang sama, tetapi berarti informasi tekstual sangat terbatas.



Gambar 2. Jumlah pengaduan per bulan pada berkas yang digunakan

3.2 Preprocessing dan Pencegahan Data Leakage

Langkah pembersihan teks bersifat *stateless* (per dokumen) sehingga aman dilakukan sebelum pemisahan data: (1) *case folding*; (2) penghapusan URL; (3) penghapusan token sensor "XXXX" yang dipakai CFPB untuk menyamarkan data pribadi; (4) penghapusan angka dan tanda baca; serta (5) normalisasi spasi. *Stopword* tidak dihapus karena teks sangat pendek dan kata negasi seperti "not" membawa makna (misalnya "debt is not yours"). *Stemming* dan lematisasi tidak diterapkan agar baseline tetap sederhana. Baris dengan target kosong dibuang, dan kelas dengan kurang dari 50 sampel akan dibuang (tidak ada kelas yang memenuhi kriteria ini). Nilai kategorikal yang hilang diisi "Unknown".

Pencegahan *data leakage* dilakukan melalui empat langkah. Pertama, kolom *Timely response?* dan *Company public response* dikeluarkan dari fitur karena dihasilkan bersamaan dengan atau setelah tanggapan perusahaan. Alasannya terlihat pada Tabel 1: *Timely response?* memiliki Cramér's V tertinggi (0,6626); pengaduan bernilai "No" berlabel *Untimely response* pada 43,9% kasus, sedangkan yang bernilai "Yes" tidak pernah berlabel *Untimely response* (0,0%). Kedua, data kerja berupa sampel *stratified* 300.000 baris dibagi menjadi latih/validasi/uji dengan proporsi 60/20/20 (180.000/60.000/60.000) dan proporsi kelas yang sama di setiap bagian. Ketiga, *TfidfVectorizer* dan *OneHotEncoder* berada di dalam *Pipeline* sehingga hanya difit pada data latih (dan difit ulang pada tiap *fold*). Keempat, data uji dikunci dan baru dibuka satu kali pada evaluasi akhir.

3.3 Feature Engineering Awal

Fitur teks dibentuk dari gabungan Product, Sub-product, Issue, dan Sub-issue yang direpresentasikan dengan TF-IDF (*sublinear term frequency*, maksimum 5.000 fitur, *min_df* = 2). Upaya awal pengembangan fitur adalah menambahkan atribut kategorikal Company, State, Submitted via, dan Tags dengan *one-hot encoding* (kategori yang jarang, kurang dari 20 kemunculan, digabung sebagai kategori infrequent). Dampak yang diharapkan adalah peningkatan informasi, karena respons perusahaan sangat bergantung pada perusahaan yang menangani pengaduan.

3.4 Baseline dan Model Kandidat

Baseline adalah TF-IDF teks dengan *Logistic Regression*, ditambah *Dummy classifier* (kelas mayoritas) sebagai batas bawah. Model kandidat menambahkan fitur terstruktur dan membandingkan beberapa algoritma, dua di antaranya berupa *voting ensemble* (Tabel 2). Semua model berada di dalam *Pipeline* scikit-learn.

Tabel 2. Baseline dan model kandidat

Kode	Fitur	Algoritma	Alasan pemilihan
Baseline	TF-IDF teks	*Logistic Regression*	Acuan standar klasifikasi teks, mudah diinterpretasi
K1	TF-IDF + *one-hot*	*Logistic Regression*	Model sama dengan baseline untuk mengisolasi efek fitur terstruktur
K2	TF-IDF + *one-hot*	*Multinomial Naive Bayes*	Probabilistik dan cepat untuk fitur frekuensi
K3	TF-IDF + *one-hot*	*Linear SVM* (C = 0,5)	Kuat untuk data berdimensi tinggi [3]
K4	TF-IDF + *one-hot*	*Random Forest* (50 pohon)	Menguji apakah non-linearitas membantu [4]
E1	TF-IDF + *one-hot*	*Voting hard* (LR+NB+SVM)	Menguji apakah gabungan model meningkatkan hasil
E2	TF-IDF + *one-hot*	*Voting soft* (LR+NB)	Menggabungkan probabilitas dua model yang berbeda sifat

3.5 Rancangan Evaluasi

Model dibandingkan pada data validasi (Pertemuan 3 dan 4), sedangkan kestabilan diukur dengan validasi silang pada data pengembangan (latih + validasi). Skema A (utama) adalah *Stratified 5-Fold* pada sampel 60.000 baris karena pengaduan baru tetap bertipe kategori masalah yang sudah dikenal dan proporsi kelas dijaga pada tiap *fold*. Skema B (*stress test*) adalah *GroupKFold* dengan grup berupa teks jenis masalah, yang mengukur generalisasi ke kombinasi masalah yang belum pernah terlihat. Skema B lebih ketat dan tidak menggantikan Skema A.

Metrik utama adalah **F1-macro** karena rasio ketidakseimbangan 350,2 dan karena tebakan "selalu kelas mayoritas" sudah mencapai akurasi 0,4592. Metrik pendamping adalah *balanced accuracy*, MCC, PR-AUC (macro), dan akurasi [5], [6]. Perbedaan terhadap baseline diuji dengan *paired t-test* pada skor tiap *fold*. Nilai p bersifat indikatif karena *fold* validasi silang tidak sepenuhnya independen. Pada eksplorasi tanpa label digunakan *silhouette* [9], *Adjusted Rand Index* (ARI) antar *seed* untuk kestabilan, dan *Normalized Mutual Information* (NMI) terhadap target.

3.6 Dokumentasi dan Reprodusibilitas

Seluruh eksperimen berada dalam satu *notebook* Google Colab dengna tautan [https://github.com/Tcerz/ML-UTS_A12Keluhan-Pelanggan.git] tautan tersebut termasuk dengan dokumentasi lainnya. Untuk menjalankan ulang, berkas CSV CFPB ditempatkan pada *DATA_PATH* lalu dipilih *Runtime → Run all*. Konfigurasi utama: *RANDOM_STATE* = 42, *SAMPLE_N* = 300.000, *CV_SAMPLE_N* = 60.000, *TUNE_SAMPLE_N* = 60.000, *N_ITER_TUNE* = 12, *CV_FOLDS* = 5, *TEST_SIZE* = 0,20, *VAL_SIZE* = 0,25, *MAX_FEATURES* = 5.000. Lingkungan: pandas 2.2.3 dan scikit-learn 1.6.1. Tabel hasil dan model disimpan sebagai berkas CSV dan *model_final.joblib*. Dataset bersumber dari situs resmi CFPB [1] dan dapat diunduh bebas; berkas yang digunakan tersedia pada [Consumer Complaint Database | Consumer Financial Protection Bureau].

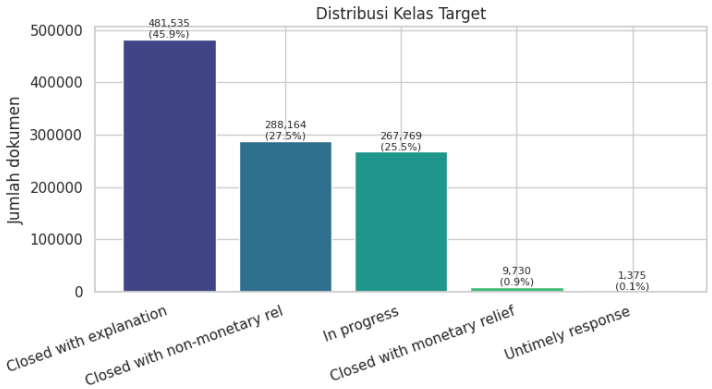
4. HASIL DAN PEMBAHASAN

4.1 Temuan Awal pada Data

Distribusi kelas sangat tidak seimbang (Tabel 3 dan Gambar 3): kelas mayoritas *Closed with explanation* 45,9% dan kelas minoritas *Untimely response* hanya 0,13%, dengan rasio 350,2. Tebakan selalu kelas mayoritas menghasilkan akurasi 0,4592 tetapi F1-macro hanya 0,1259, sehingga akurasi saja tidak memadai.

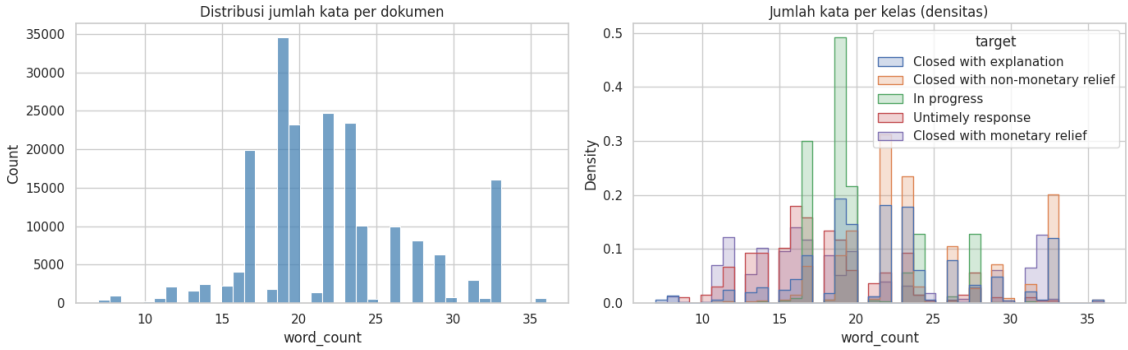
Tabel 3. Distribusi kelas target (1.048.573 baris)

Kelas	Jumlah	Persen
Closed with explanation	481.535	45,9
Closed with non-monetary relief	288.164	27,5
In progress	267.769	25,5
Closed with monetary relief	9.730	0,9
Untimely response	1.375	0,13



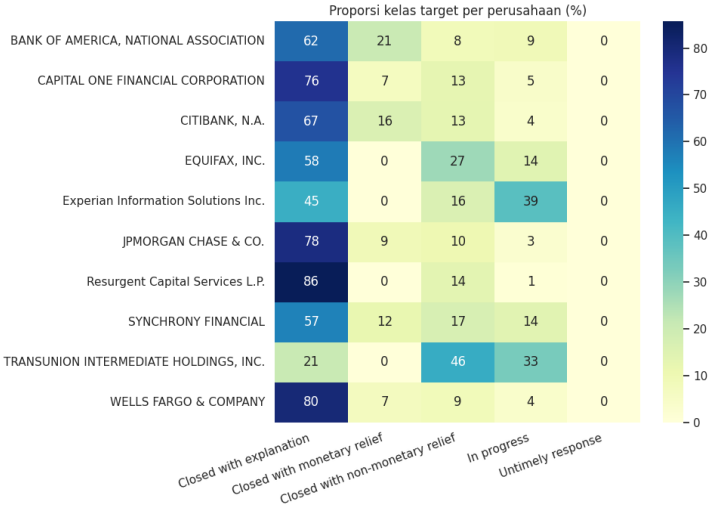
Gambar 3. Distribusi kelas target

Panjang teks pendek dan sempit: pada sampel 200.000 dokumen, rerata 22,09 kata (simpangan baku 5,17), median 22, minimum 7, maksimum 36, dan tidak ada dokumen di bawah 5 kata (Gambar 4). Kelas *Closed with non-monetary relief* cenderung lebih panjang (rerata 24,12 kata) daripada *Untimely response* (17,91 kata), tetapi tumpang tindih distribusi besar sehingga panjang teks bukan pembeda yang kuat.



Gambar 4. Distribusi jumlah kata per dokumen (kiri) dan per kelas (kanan)

Perusahaan sangat menentukan hasil (Gambar 5). Misalnya 86% pengaduan terhadap Resurgent Capital Services berakhir *Closed with explanation*, sedangkan untuk TransUnion hanya 21% dengan 46% *Closed with non-monetary relief* dan 33% *In progress*; Experian memiliki 39% *In progress*. Selisih proporsi tertinggi dan terendah antar perusahaan mencapai 64,7 poin persen untuk *Closed with explanation*, 37,9 untuk *In progress*, dan 37,2 untuk *Closed with non-monetary relief*. Temuan ini mendukung penggunaan Company sebagai fitur.



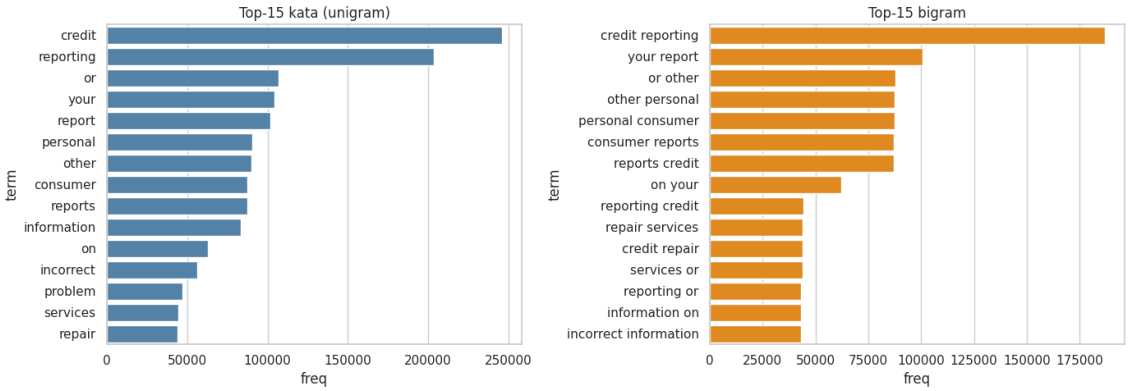
Gambar 5. Proporsi kelas target pada sepuluh perusahaan dengan pengaduan terbanyak (%)

Kapasitas informasi tiap kelompok fitur diperiksa dengan tabel-lookup eksploratif (prediksi berupa kelas mayoritas pada kombinasi fitur yang sama), bukan sebagai model akhir (Tabel 4). Penambahan Company menaikkan F1-macro dari 0,3670 menjadi 0,5484, sedangkan penambahan atribut lain justru menurunkannya karena kombinasi menjadi jarang (cakupan kombinasi pada data uji turun dari 0,9619 menjadi 0,8723). Artinya Company adalah tambahan paling informatif, dan model perlu menggeneralisasi pada kombinasi yang jarang, yang merupakan alasan memakai *machine learning* dibanding tabel-lookup.

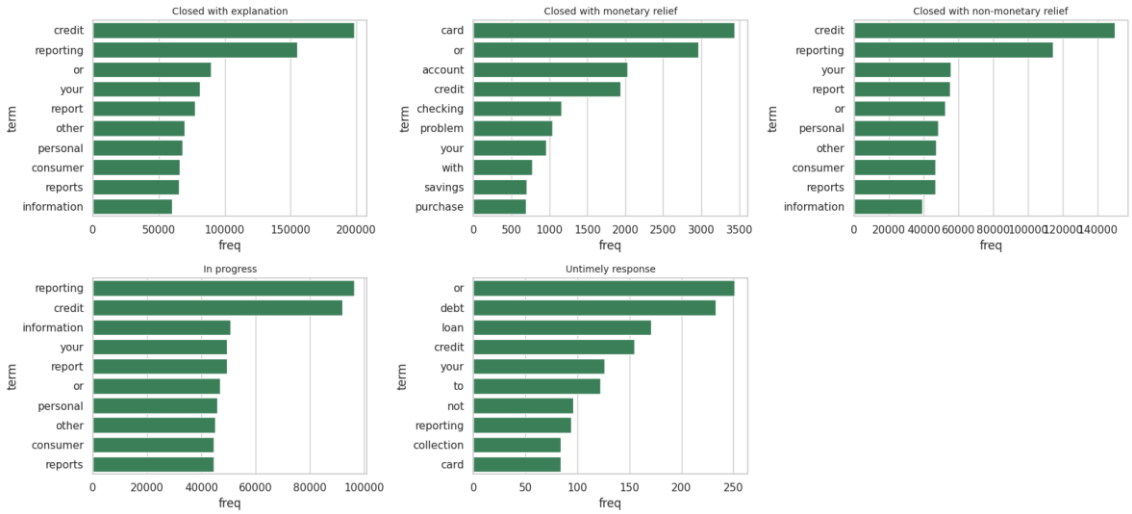
Tabel 4. Kapasitas informasi fitur (tabel-lookup eksploratif)

Fitur	Kombinasi unik	Akurasi	F1-macro	Bal. Acc	Cakupan uji
Teks saja	1.125	0,5761	0,3670	0,3801	0,9989
+ Company	14.228	0,7125	0,5484	0,5147	0,9619
+ Company, State	34.382	0,7061	0,4902	0,4704	0,8908
+ Company, State, Submitted via	35.822	0,7064	0,4851	0,4656	0,8846
+ Company, State, Submitted via, Tags	38.854	0,7054	0,4837	0,4643	0,8723

Setelah pembersihan, kata dan *bigram* teratas didominasi istilah umum seperti *credit reporting*, *your report*, dan *other personal* (Gambar 6 dan Gambar 7), yang wajar karena teks hanya berupa jenis masalah dan sebagian besar pengaduan berkaitan dengan laporan kredit. Istilah yang khas tiap kelas, misalnya *card* dan *account* pada *Closed with monetary relief*, terlihat pada Gambar 7.



Gambar 6. Lima belas kata (kiri) dan *bigram* (kanan) teratas pada data latih



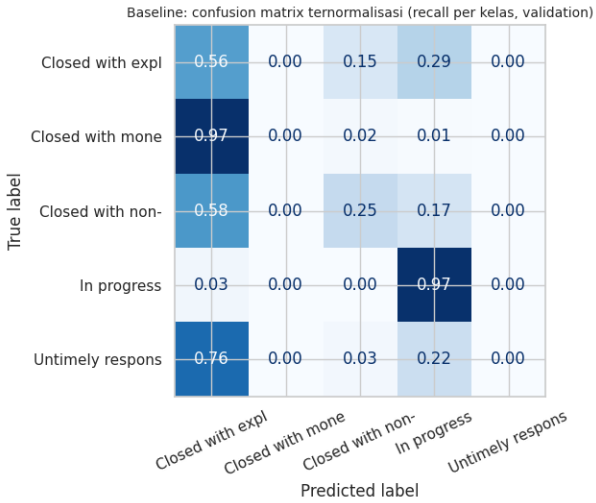
Gambar 7. Kata teratas pada tiap kelas target (data latih)

4.2 Hasil Baseline dan Model Kandidat

Tabel 5 menyajikan hasil pada data validasi. Baseline mencapai akurasi 0,5698 dan F1-macro 0,3242, jauh di atas *Dummy* (F1-macro 0,1259), tetapi recall kelas *Closed with monetary relief* dan *Untimely response* sama dengan 0. Selisih akurasi dan F1-macro sebesar 0,2456 menunjukkan model condong ke kelas besar. Gambar 8 memperlihatkan 97% kasus *Closed with monetary relief* diprediksi sebagai *Closed with explanation*, sedangkan kelas *In progress* memiliki recall 0,97 dengan presisi 0,58.

Tabel 5. Hasil pada data validasi (60.000 baris)

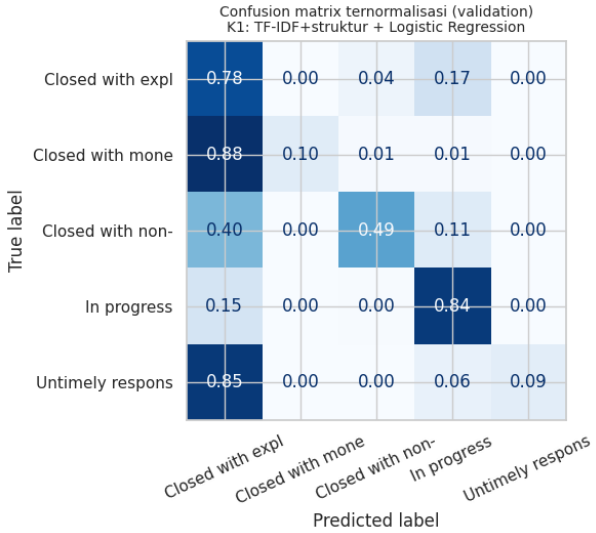
Model	Acc	Bal. Acc	Prec	Rec	F1-macro	MCC	PR-AUC	Waktu (s)
Dummy (mayoritas)	0,4592	0,2000	0,0918	0,2000	0,1259	0,0000	0,2000	–
Baseline (LR, teks)	0,5698	0,3539	0,3313	0,3539	0,3242	0,3557	0,4031	17,1
K1 (LR + struktur)	0,7096	0,4611	0,6978	0,4611	0,4866	0,5540	0,5567	33,9
K2 (NB + struktur)	0,5931	0,6339	0,4116	0,6339	0,4308	0,4032	0,4665	4,9
K3 (SVM + struktur)	0,7102	0,4544	0,7002	0,4544	0,4762	0,5550	0,5506	34,8
K4 (RF + struktur)	0,7137	0,4457	0,6629	0,4457	0,4480	0,5692	0,5364	34,0



Gambar 8. Confusion matrix baseline pada data validasi (recall per kelas)

Penambahan fitur terstruktur pada model yang sama (K1 terhadap baseline) menaikkan F1-macro sebesar 0,1624 menjadi 0,4866 dan MCC dari 0,3557 menjadi 0,5540. Dengan demikian peningkatan terbesar berasal dari fitur, bukan dari pergantian algoritma: K1, K3, dan K4 saling berdekatan pada akurasi (0,7096 sampai 0,7137). Metrik yang paling informatif adalah F1-macro, *balanced accuracy*,

dan MCC. Metrik-metrik ini memberi urutan yang berbeda dari akurasi: K4 memiliki akurasi dan MCC tertinggi tetapi F1-macro rendah (0,4480), sedangkan K2 memiliki *balanced accuracy* tertinggi (0,6339) karena lebih banyak menebak kelas minoritas, tetapi presisinya rendah (0,4116). Dari sisi biaya, K2 paling cepat (4,9 detik). Pada K1 recall kelas minoritas masih rendah: 0,10 untuk *Closed with monetary relief* dan 0,09 untuk *Untimely response* (Gambar 9).



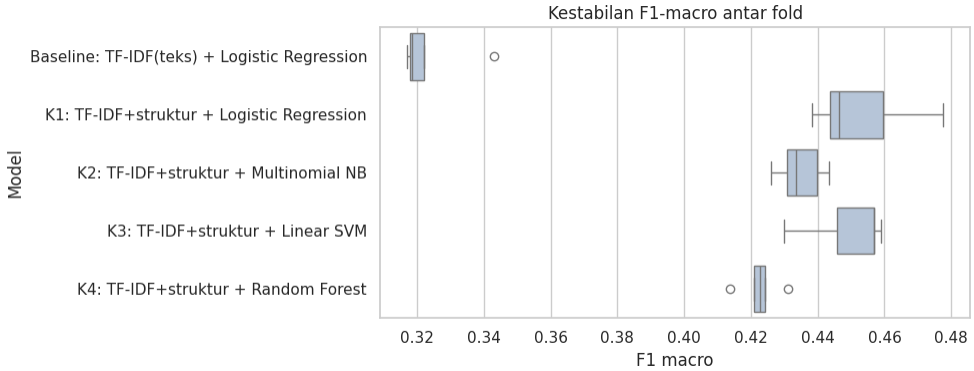
Gambar 9. Confusion matrix K1 pada data validasi (recall per kelas)

4.3 Kestabilan Validasi Silang dan Ensemble

Validasi silang *Stratified 5-Fold* pada 60.000 baris menghasilkan skor F1-macro tiap *fold* pada Tabel 6. Simpangan baku antar *fold* berkisar 0,0063 sampai 0,0196 sehingga urutan model relatif stabil; baseline berada di bawah semua model lain pada setiap *fold* (Gambar 10). Nilai validasi silang untuk K1 (0,4531) lebih rendah daripada pada data validasi (0,4866); perbedaan ini kemungkinan berkaitan dengan ukuran latih yang lebih kecil dan hanya 79 sampel *Untimely response* pada sampel validasi silang, sehingga perlu diperiksa pada tahap berikutnya.

Tabel 6. Skor F1-macro tiap *fold* (Stratified 5-Fold, 60.000 baris)

Fold	Baseline	K1	K2	K3	K4
1	0,3186	0,4595	0,4309	0,4458	0,4241
2	0,3178	0,4435	0,4334	0,4299	0,4137
3	0,3220	0,4776	0,4261	0,4589	0,4209
4	0,3170	0,4384	0,4397	0,4568	0,4227
5	0,3431	0,4464	0,4433	0,4568	0,4310
Rerata ± std	**0,3237 ± 0,0110**	**0,4531 ± 0,0158**	**0,4347 ± 0,0069**	**0,4497 ± 0,0121**	**0,4225 ± 0,0063**

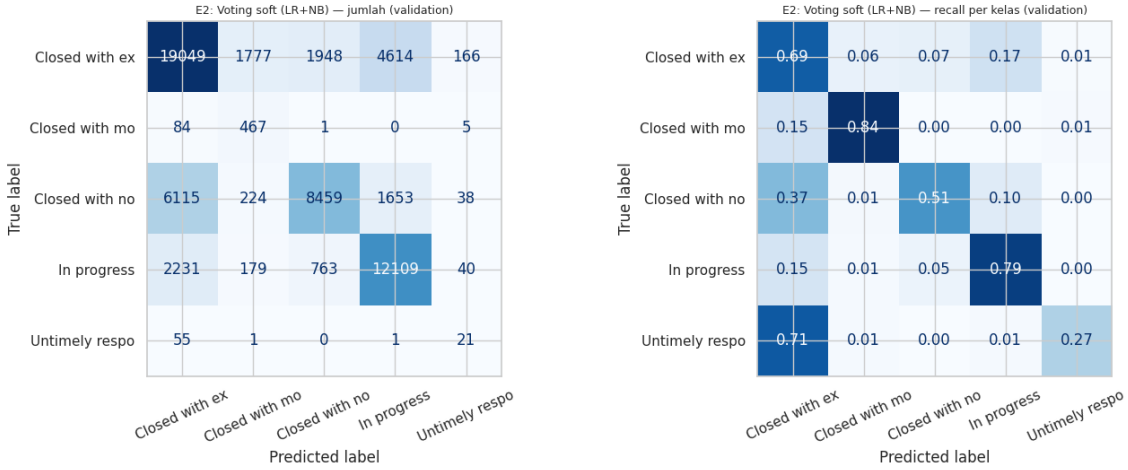


Gambar 10. Kestabilan F1-macro antar *fold* untuk model tunggal

Tabel 7 merangkum seluruh model beserta metode validasinya. Semua model yang menambahkan fitur terstruktur meningkat atas baseline (selisih F1-macro 0,0988 sampai 0,1716; $p < 0,05$ pada *paired t-test*, indikatif). *Ensemble* E2 (*voting soft* LR+NB) menjadi yang terbaik pada validasi silang (0,4954), unggul 0,0423 atas model tunggal terbaik (K1). Gambar 11 menunjukkan *confusion matrix* E2 pada data validasi. Namun *ensemble* ini belum dibandingkan secara setara dengan LR berbobot kelas (lihat 4.4), karena model tunggal K1–K4 dan *ensemble* tidak memakai bobot kelas.

Tabel 7. Ringkasan hasil eksperimen awal: baseline, model kandidat, metode validasi, dan metrik

Model	F1 val	F1 CV (rerata ± std)	Bal. Acc CV	Acc CV	Δ F1 vs baseline	p
Baseline (LR, teks)	0,3242	0,3237 ± 0,0110	0,3551	0,5724	–	–
K1 (LR + struktur)	0,4866	0,4531 ± 0,0158	0,4417	0,7054	+0,1294	0,0001
K2 (NB + struktur)	0,4308	0,4347 ± 0,0069	0,6022	0,5988	+0,1110	< 0,001
K3 (SVM + struktur)	0,4762	0,4497 ± 0,0121	0,4383	0,7060	+0,1259	< 0,001
K4 (RF + struktur)	0,4480	0,4225 ± 0,0063	0,4300	0,7050	+0,0988	< 0,001
E1 (voting hard)	–	0,4617 ± 0,0119	–	–	+0,1380	< 0,001
E2 (voting soft)	–	0,4954 ± 0,0196	–	–	+0,1716	< 0,001



Gambar 11. Confusion matrix E2 (*voting soft*) pada data validasi: jumlah (kiri) dan recall per kelas (kanan)

4.4 Analisis Ketidakseimbangan Kelas

Tiga strategi bobot kelas dibandingkan pada LR dengan fitur terstruktur (Tabel 8). Tanpa bobot, recall kelas terkecil (*Untimely response*) hanya 0,0125. Bobot *balanced* menaikkannya menjadi 0,5933 dan *balanced accuracy* menjadi 0,6993, tetapi akurasi turun ke 0,6288 dan F1-macro hanya 0,4591. Bobot *sqrt-balanced* (akar dari bobot *balanced*) memberi F1-macro tertinggi (0,4994) dengan akurasi 0,6856 dan recall kelas terkecil 0,2517. Strategi *sqrt-balanced* dipilih karena F1-macro paling tinggi; konsekuensinya recall kelas minoritas masih lebih rendah daripada pada bobot *balanced*, yang dapat dipertimbangkan kembali bila biaya melewatkan kelas langka dinilai lebih besar.

Tabel 8. Strategi penanganan ketidakseimbangan (LR + struktur, Stratified 5-Fold)

Strategi	F1-macro (rerata)	F1-macro (std)	Bal. Acc	Akurasi	Recall *Untimely*
Tanpa bobot	0,4531	0,0158	0,4417	0,7054	0,0125
balanced	0,4591	0,0062	0,6993	0,6288	0,5933
sqrt-balanced	0,4994	0,0103	0,5907	0,6856	0,2517

4.5 Uji Ketahanan pada Jenis Masalah yang Belum Terlihat

Pada Skema B, semua model turun tajam (Tabel 9). Baseline turun dari 0,3237 menjadi 0,1435, K1 dari 0,4531 menjadi 0,3202, dan K2 dari 0,4347 menjadi 0,2230. K1 paling tahan, tetapi simpangan bakunya besar (0,0929), yaitu hasil sangat bergantung pada kelompok jenis masalah yang dikeluarkan.

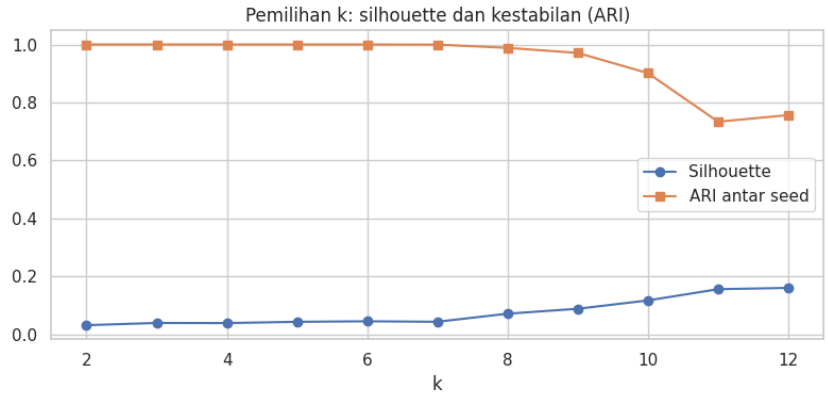
Skema B memaksa model menebak kombinasi masalah yang belum pernah dilihat, sehingga penurunan ini menunjukkan ketergantungan model pada kategori yang sudah dikenal. Karena pengaduan baru umumnya bertipe sama dengan pengaduan lama, Skema A tetap dipakai sebagai evaluasi utama dan Skema B sebagai uji ketahanan.

Tabel 9. Perbandingan Skema A (*stratified*) dan Skema B (*group*)

Model	F1 Skema A	F1 Skema B	Std B	Akurasi B	Selisih (B−A)
Baseline (LR, teks)	0,3237	0,1435	0,0300	0,4566	−0,1802
K1 (LR + struktur)	0,4531	0,3202	0,0929	0,5881	−0,1328
K2 (NB + struktur)	0,4347	0,2230	0,0697	0,3672	−0,2117

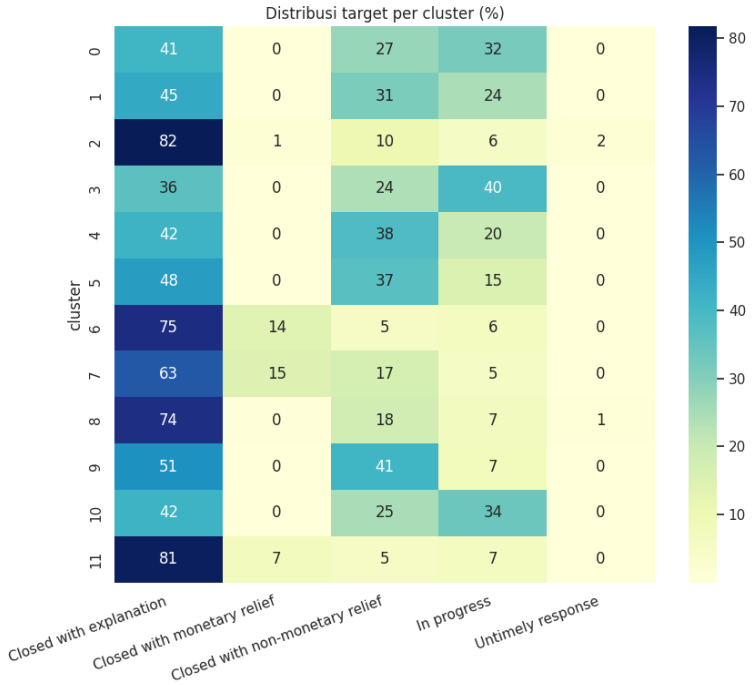
4.6 Eksplorasi Tanpa Label (LSA, KMeans, NMF)

Jenis masalah unik pada data pengembangan (1.140 teks) direpresentasikan dengan TF-IDF (*unigram* dan *bigram*, 1.990 fitur), direduksi dengan LSA menjadi 50 komponen (59,02% variansi), lalu dikelompokkan dengan *KMeans* berbobot jumlah pengaduan untuk k = 2 sampai 12. *Silhouette* naik dari 0,0312 (k = 2) menjadi 0,1599 (k = 12), tetapi ARI antar *seed* turun dari 1,0000 (k ≤ 6) menjadi 0,7334 (k = 11) dan 0,7561 (k = 12) (Gambar 12). Nilai k = 12 dipilih berdasarkan *silhouette* tertinggi, namun k = 12 adalah batas atas yang diuji dan strukturnya tergolong lemah serta kurang stabil; hasil ini sebaiknya dibaca sebagai eksplorasi, bukan pembuktian adanya klaster alami.

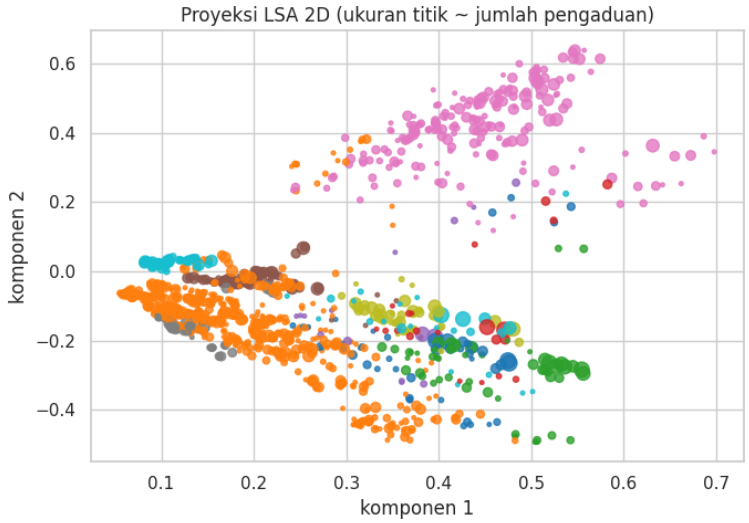


Gambar 12. Pemilihan k: *silhouette* dan kestabilan klaster (ARI antar *seed*)

Klaster mencerminkan tema produk: beberapa klaster berkaitan dengan pelaporan kredit (investigasi, informasi tidak benar, penggunaan laporan yang tidak semestinya), klaster lain dengan penagihan utang, hipotek, rekening giro atau tabungan, kartu kredit, dan transfer uang. NMF dengan enam topik menghasilkan tema serupa: pinjaman, kartu, penagihan utang, pelaporan kredit, rekening, dan informasi tidak benar. Namun NMI antara klaster dan target hanya 0,0472 (Gambar 13 dan Gambar 14), sehingga tema jenis masalah hampir tidak menjelaskan hasil penanganan. Hal ini sejalan dengan temuan 4.1 bahwa perusahaan lebih berpengaruh daripada jenis masalah. Representasi lanjutan seperti *word embedding* tidak digunakan karena batasan *classical machine learning* pada Milestone 1.



Gambar 13. Distribusi target pada tiap klaster (%)



Gambar 14. Proyeksi LSA 2D jenis masalah (ukuran titik sebanding dengan jumlah pengaduan)

4.7 Seleksi Fitur, Tuning, dan Analisis Kesalahan Awal

Seleksi fitur chi-kuadrat (*SelectKBest*) pada 60.000 baris dengan 626 fitur menunjukkan k = 300 memberi F1-macro tertinggi (0,5026) dibanding semua fitur (0,4949) (Tabel 10). Selisih ini masih berada dalam kisaran simpangan baku antar *fold*, sehingga seleksi fitur terutama mengurangi dimensi tanpa peningkatan yang jelas. Fitur dengan skor tertinggi berupa kata seperti *card*, *charge*, *checking*, *fees*, *incorrect*, dan *repair*, serta kategori Company seperti Bank of America, Bread Financial, Citibank, Equifax, Experian, TransUnion, dan Wells Fargo.

Tabel 10. Seleksi fitur chi-kuadrat (3-fold, 60.000 baris)

k fitur	F1-macro (rerata)	F1-macro (std)	Bal. Acc	Waktu (s)
50	0,4959	0,0185	0,5787	10,7
100	0,4983	0,0130	0,5915	12,3
300	0,5026	0,0055	0,6033	17,0
Semua (626)	0,4949	0,0134	0,5809	19,5

RandomizedSearchCV (12 kombinasi, 3-fold, 267,5 detik) menghasilkan F1-macro validasi silang terbaik 0,5012 dengan C ≈ 0,0635, *ngram* (1,2), *max_features* 20.000, *min_df* = 1, persentil seleksi 100, dan bobot kelas *sqrt-balanced*. Rentang skor antar kombinasi 0,0834, dan empat kombinasi terbaik semuanya memakai bobot *sqrt-balanced*, sehingga bobot kelas dan regularisasi paling berpengaruh. Namun pada data validasi, model hasil tuning (F1-macro 0,5215; MCC 0,5344) hampir sama dengan LR berbobot *sqrt-balanced* tanpa tuning (F1-macro 0,5215; MCC 0,5356); selisih F1-macro hanya +0,0001. Tuning dengan demikian belum memberi peningkatan yang berarti pada tahap ini. Terhadap baseline, kenaikan F1-macro validasi adalah +0,1973 (0,3242 menjadi 0,5215).

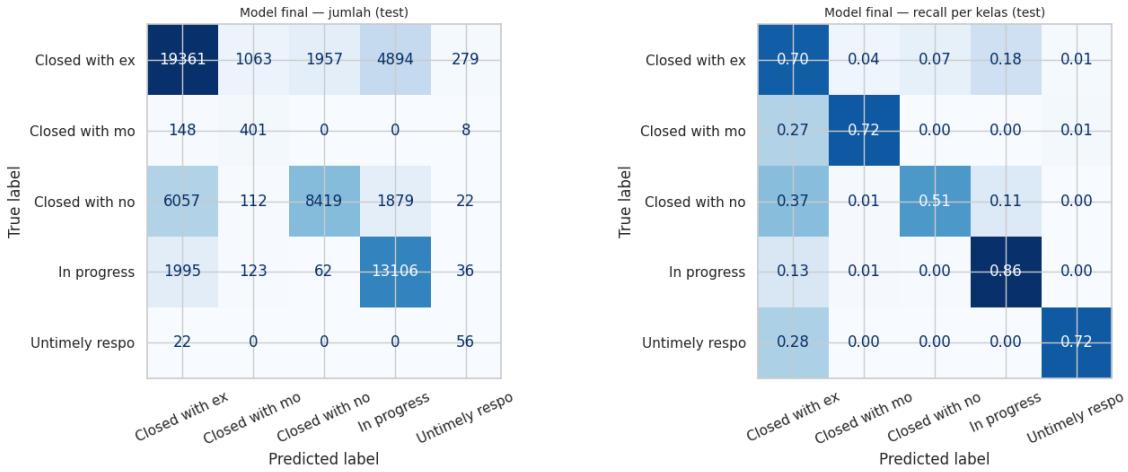
Analisis kesalahan pada data validasi menunjukkan 18.608 dari 60.000 prediksi salah (31,0%). Tingkat kesalahan tertinggi ada pada *Closed with non-monetary relief* (0,483), diikuti *Untimely response* (0,449), *Closed with explanation* (0,299), *Closed with monetary relief* (0,293), dan *In progress* (0,144). Kesalahan tersering adalah *Closed with non-monetary relief* diprediksi *Closed with explanation* (5.885 kasus) dan *Closed with explanation* diprediksi *In progress* (4.840 kasus). Pada kombinasi fitur yang ambigu (label mayoritas pada kombinasi sama kurang dari 60%; 13.302 baris), tingkat kesalahan 0,491, dibanding 0,259 pada kombinasi tidak ambigu (46.698 baris). Hanya 4,3% kombinasi validasi yang belum pernah muncul di data latih, dan 86,32% baris validasi memiliki seluruh fitur identik dengan baris di data latih. Selama fitur identik dapat berlabel berbeda, ada batas performa alami yang tidak dapat dilampaui oleh tuning. Pada tingkat perusahaan, tingkat kesalahan tertinggi di antara delapan perusahaan dengan pengaduan terbanyak terjadi pada Citibank (0,601), Bank of America (0,546), dan Wells Fargo (0,440); untuk Equifax 0,423, TransUnion 0,257, dan Experian 0,274.

4.8 Evaluasi Akhir pada Data Uji

Model terbaik sementara (LR berbobot *sqrt-balanced* dengan seleksi fitur dan hiperparameter hasil tuning) dibekukan sebelum data uji dibuka, lalu dilatih ulang pada data pengembangan (240.000 baris) dan dievaluasi satu kali pada 60.000 baris data uji (Tabel 11 dan Gambar 15). F1-macro mencapai 0,5323, lebih tinggi 0,2046 dari baseline (0,3277) dan 0,4064 dari *Dummy* (0,1259). Selisih dengan F1-macro validasi (0,5215) hanya 0,0108, sehingga tidak tampak tanda *overfitting* terhadap data validasi.

Tabel 11. Hasil akhir pada data uji (60.000 baris)

Model	Acc	Bal. Acc	Prec	Rec	F1-macro	MCC	PR-AUC
Dummy (mayoritas)	0,4592	0,2000	0,0918	0,2000	0,1259	0,0000	0,2000
Baseline (LR, teks)	0,5690	0,3554	0,4455	0,3554	0,3277	0,3534	0,4090
Model terbaik sementara	**0,6891**	**0,7013**	**0,5087**	**0,7013**	**0,5323**	**0,5328**	**0,5765**



Gambar 15. Confusion matrix model terbaik sementara pada data uji: jumlah (kiri) dan recall per kelas (kanan)

Per kelas (Tabel 12), recall kelas langka tinggi (0,72 untuk *Closed with monetary relief* dan *Untimely response*), tetapi presisinya rendah (0,24 dan 0,14); model mengorbankan presisi untuk menangkap kelas langka. Presisi *Closed with non-monetary relief* tinggi (0,81) dengan recall 0,51. Kelas

Untimely response hanya memiliki 78 sampel uji (56 terprediksi benar), sehingga estimasinya tidak stabil.

Tabel 12. Laporan klasifikasi model terbaik sementara pada data uji

Kelas	Presisi	Recall	F1	Dukungan
Closed with explanation	0,70	0,70	0,70	27.554
Closed with monetary relief	0,24	0,72	0,36	557
Closed with non-monetary relief	0,81	0,51	0,63	16.489
In progress	0,66	0,86	0,74	15.322
Untimely response	0,14	0,72	0,23	78
Macro avg	**0,51**	**0,70**	**0,53**	**60.000**
Weighted avg	**0,71**	**0,69**	**0,69**	**60.000**

4.9 Keterbatasan

1. **Data terpotong dan tidak acak.** Berkas berhenti pada batas baris Excel dan hanya memuat dua periode padat (2023 dan 2026), sehingga hasil berlaku untuk sampel ini dan generalisasi ke populasi penuh CFPB belum terbukti. Proporsi kelas seperti *In progress* dapat dipengaruhi oleh periode data.
2. **Informasi teks terbatas.** Tanpa kolom narasi, teks hanya berupa jenis masalah (1.483 teks unik), sehingga eksperimen ini lebih dekat ke klasifikasi atribut kategorikal daripada *text mining* atas narasi bebas.
3. **Batas performa alami.** Pengaduan dengan fitur identik dapat berlabel berbeda (86,32% baris validasi identik dengan baris latih), sehingga ada plafon skor.
4. **Definisi target.** *In progress* dan *Untimely response* adalah status proses, bukan hasil akhir penyelesaian; bila tujuan bisnisnya memprediksi hasil akhir, target perlu ditinjau ulang.
5. **Perbandingan belum sepenuhnya setara.** Model kandidat K1–K4 dan *ensemble* tidak memakai bobot kelas, sedangkan model terbaik sementara memakainya; hiperparameter kandidat sebagian besar nilai awal, validasi silang memakai sampel 60.000 baris, dan nilai p bersifat indikatif.
6. **Data uji sudah dipakai.** Data uji telah dibuka satu kali pada UTS sehingga untuk UAS diperlukan data *hold-out* baru.

5. KESIMPULAN

1. Masalah, target, dan fitur telah dirumuskan, dan audit data mengidentifikasi dua kolom pasca-respons yang dikeluarkan untuk mencegah *data leakage* serta pemotongan berkas pada batas baris Excel.
2. Penambahan fitur terstruktur (terutama Company) memberi peningkatan terbesar: F1-macro validasi silang naik dari 0,3237 (baseline) menjadi 0,4531 (K1), sedangkan pergantian algoritma memberi perbedaan yang lebih kecil.
3. Pembobotan kelas *sqrt-balanced* menaikkan F1-macro validasi silang menjadi 0,4994 dengan trade-off antara akurasi dan recall kelas langka; *ensemble voting soft* (LR+NB) mencapai 0,4954.
4. Model terbaik sementara memperoleh F1-macro 0,5323, *balanced accuracy* 0,7013, dan MCC 0,5328 pada data uji, dibanding F1-macro 0,3277 pada baseline. Tuning belum memberi peningkatan berarti (+0,0001 pada validasi).
5. Skor dibatasi oleh data: tidak ada kolom narasi, berkas terpotong, fitur identik dapat berlabel berbeda, dan performa turun tajam pada jenis masalah yang belum terlihat (K1: 0,4531 menjadi 0,3202).

6. SARAN DAN RENCANA PASCA-UTS

Rencana pekerjaan menuju UAS berdasarkan temuan di atas:

1. **Memperbaiki data.** Mengunduh ulang CSV asli dari CFPB tanpa melalui Excel (atau per tahun/produk lalu digabung) alasan kenapa akan menjalankan langsung tanpa perlu melalui excel dikarenakan excel menganggap data terlalu besar dan memotongnya otomatis, dan menjalankan ulang *notebook* agar sampel lebih representatif. Setelah itu seluruh angka pada laporan diperbarui.
2. **Memanfaatkan kolom narasi.** Bila kolom narasi tersedia pada data baru, menggunakannya sebagai sumber teks; *notebook* sudah dapat memakainya secara otomatis. Perubahan dataset atau rumusan target (misalnya hanya hasil akhir "Closed...") dikonsultasikan lebih dahulu dengan dosen beserta alasannya.
3. **Menyiapkan evaluasi baru.** Membuat data *hold-out* baru atau pemisahan berbasis waktu karena data uji sudah dibuka pada UTS.
4. **Menyetarakan perbandingan.** Menerapkan bobot kelas pada semua kandidat dan *ensemble* agar perbandingan adil, serta memperluas pencarian hiperparameter.
5. **Memperbaiki kelas langka.** Mengkalibrasi probabilitas dan menyesuaikan ambang keputusan per kelas untuk menyeimbangkan presisi dan recall.
6. **Eksperimen representasi teks.** Menguji *stemming*/lematisasi dan variasi *n-gram*; representasi lanjutan seperti *word embedding* hanya bila sesuai ketentuan UAS.
7. **Dokumentasi.** Menyiapkan repositori GitHub dengan README, instruksi menjalankan ulang, catatan eksperimen, dan tabel hasil yang konsisten dengan laporan.

DAFTAR PUSTAKA

[1] Consumer Financial Protection Bureau, "Consumer Complaint Database," *https://www.consumerfinance.gov/data-research/consumer-complaints/*. (accessed Nov. 2026).

[2] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.

[3] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Machine Learning: ECML-98*. Berlin: Springer, 1998, pp. 137–142.

[4] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[5] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.

[6] D. Chicco and G. Jurman, "The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation," *BMC Genomics*, vol. 21, art. 6, 2020, doi: 10.1186/s12864-019-6413-7.

[7] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, art. 15, 2012.

[8] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, and R. Harshman, "Indexing by latent semantic analysis," *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

[9] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.

[10] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.